

F30 — Investigación científica y tecnológica para el motor inteligente de reclutamiento

SaaS Reclutamiento Multiempresa · Caso Colegio Andino de Huancayo

Versión 1 · 30/09/2026 · auditada e integrada

Contenido

Contenido	2
F30 — Investigación científica y tecnológica para el motor inteligente de reclutamiento	4
Conclusión en una línea	4
Documentos	4
Fuentes en cifras	5
Cómo se reproduce	5
Límites	5
Siguiendo paso	6
F30 — Estado del arte de la IA en reclutamiento y selección	7
1. Resumen ejecutivo	7
2. Estrategia y alcance de la revisión	8
3. Estado del arte por tema	8
4. Perspectiva de recursos humanos	13
5. Prácticas recomendadas	13
6. Prácticas a evitar	14
F30 — Análisis de modelos y técnicas para el motor de reclutamiento	15
1. Punto de partida: lo que el sistema ya hace	15
2. Comparación de enfoques	15
3. Criterios de vacante y competencias	16
4. Cadena de procedencia de la evidencia	17
5. Pipeline seguro de audio y vídeo	17
6. Métricas por tarea	18
7. Arquitectura futura (conceptual)	19
8. Modelo de auditoría de una ejecución	19
F30 — Explicabilidad, equidad y gobernanza	21
1. Explicabilidad (XAI)	21
2. Equidad (fairness)	21
3. Supervisión humana y sesgo de automatización	22
4. Gobernanza	23
F30 — Análisis de herramientas, skills y servidores MCP	27
1. Método	27
2. Resultado	27
3. Comparación por necesidad	27
4. Datos verificados por herramienta	31
5. Skills, plugins y conectores del entorno local	34
6. Señales de alerta de cadena de suministro	35
7. Reglas de adopción para F33–F40	36
F30 — Recomendaciones y decisiones para F33–F40	37
1. Conclusión	37
2. Puerta G0	37

3. Tabla de decisiones	38
4. Plan por fase	41
5. Decisiones pendientes del equipo	41
6. Qué no se debe hacer en F33–F40 (resumen).....	41
F30 — Matriz de evidencia científica	43
1. Estrategia de búsqueda	43
2. Resumen de la matriz	45
3. Fichas de evidencia.....	47
4. Normas, documentos oficiales y fuentes secundarias	93
5. Avisos editoriales y exclusiones.....	95
F30 — Referencias	96
Trabajos científicos	96
Normas y documentos oficiales	102
Fuentes secundarias	103

F30 — Investigación científica y tecnológica para el motor inteligente de reclutamiento

Investigación documental para decidir **qué puede y qué no debe hacer** un futuro motor inteligente de reclutamiento en el SaaS (caso Colegio Andino de Huancayo), antes de que F33–F40 implementen algo.

Estado: versión 1 (30/09/2026), **auditada e integrada**. F30 **no implementa nada**: no hay modelos, embeddings, base vectorial, parsing, transcripción, scoring, endpoints, migraciones ni interfaz. Tampoco se instaló ninguna herramienta, skill ni servidor MCP.

Conclusión en una línea

La evidencia respalda un motor que **estructura y verifica la evidencia** que usan los evaluadores humanos (entrevista estructurada, rúbricas BARS, procedencia, acuerdo entre evaluadores). **No respalda scoring ni recomendación de candidatos para este caso, con los datos, el gobierno y las garantías actuales**; la calificación automática a escala existe [S89], pero en organizaciones con volúmenes de datos que el caso no tiene, y se registra como evidencia en tensión. La visión de «recomendar» choca con ADR-001 y el contrato 4, y el DS 115-2025-PCM clasifica este uso como de **riesgo alto** (art. 24.1 e). Por eso rige una puerta de gobierno:

Regla G0. F33 formula y aprueba ADR-005, que constituye la puerta G0. F34 puede avanzar en paralelo **solo con datos sintéticos** y sin scoring ni recomendación de personas. F35–F40 **no comienzan sin G0 aprobado**.

RECOMENDACIÓN DEL SISTEMA ≠ DECISIÓN FINAL DE CONTRATACIÓN (RF-23: la decisión es humana).

Documentos

Archivo	Contenido	Origen
F30_Estado_del_Arte_IA_Reclutamiento.md	Estado del arte por tema (A–T), perspectiva de RR. HH., prácticas recomendadas y a evitar	Redactado
F30_Matriz_Evidencia_Cientifica.md	Estrategia de búsqueda, flujo de selección y 89 fichas con 20 campos y nivel de evidencia; normas	Generado
F30_Analisis_Modelos_y_Tecnicas.md	Reglas, MCDM, ML, NLP y LLM comparados; criterios y competencias (ejemplo docente ilustrativo); cadena de procedencia; pipeline de audio; métricas; arquitectura; modelo de auditoría	Redactado
F30_Explainability_Fairness_Gobernanza.md	Explicabilidad, métricas de equidad y sus límites, sesgo de automatización, marco legal, conflicto con ADR-001, gobernanza del dataset	Redactado
F30_Analisis_Herramientas_Skills.md	49 herramientas y MCP con datos verificados y clasificación; skills locales; señales de cadena de suministro	Generado
F30_Recomendaciones_F33_F40.md	Puerta G0, 30 decisiones (DECISIÓN / EVIDENCIA / ALTERNATIVAS / RIESGO / RECOMENDACIÓN / FASE) y plan por fase	Redactado

Archivo	Contenido	Origen
REFERENCIAS.md	107 referencias: trabajos desde metadatos de Crossref y DataCite; normas desde su fuente oficial	Generado
F30_Investigacion_IA_Reclutamiento.docx · PDF	Consolidado de los documentos anteriores	Generado
datos/	busqueda_openalex.json, verificacion_fuentes.json, herramientas.json	Generado por los scripts

Fuentes en cifras

- **Búsqueda:** 20 consultas en OpenAlex, una por tema A–T, con 500 registros cribados (25 por consulta).
- **Trabajos científicos:** 89, de los cuales 35 vienen del cribado, 9 de una búsqueda complementaria 2021–2025 y 45 de bola de nieve y trabajos fundacionales.
- **Normas y documentos oficiales:** 16. **Fuentes secundarias de contraste:** 2.
- **Verificación:** las 107 fuentes están verificadas en Crossref, DataCite o por HTTP con palabra clave en el título; las normas de la UE, en el texto oficial del Diario Oficial.
- **Avisos y exclusiones:** un artículo retractado del cribado quedó excluido. Dos fuentes tienen avisos menores, una corrección (S08) y una errata (S21).

Cómo se reproduce

Desde la raíz del repositorio, con Python 3.12 y sin dependencias externas (solo biblioteca estándar y red):

```
python docs/academico/tools/f30/busqueda.py          # búsqueda OpenAlex →
datos/busqueda_openalex.json
python docs/academico/tools/f30/verificar.py [--abstracts DIR] # verificación →
datos/verificacion_fuentes.json
python docs/academico/tools/f30/herramientas.py [--completar] # GitHub, PyPI, npm y OSV →
datos/herramientas.json
python docs/academico/tools/f30/f30.py              # matriz, referencias, herramientas y
DOCX
powershell -ExecutionPolicy Bypass -File docs/academico/tools/f27b/topdf_toc.ps1
docs/academico/investigacion-ia/F30_Investigacion_IA_Reclutamiento.docx
python docs/academico/tools/f30/validate_f30.py      # validación de F30
```

- Los resúmenes de OpenAlex se descargan a una carpeta temporal (--abstracts) solo para la lectura del equipo. **No se versionan**, por derechos de autor.
- Las consultas a APIs públicas devuelven datos que cambian con el tiempo (citas, versiones, avisos). Cada JSON registra su fecha.

Límites

- La extracción se hizo sobre resúmenes, no sobre el texto completo. Si no hay resumen disponible, la matriz lo indica y no da cifras.
- El análisis normativo es técnico y **no es asesoría legal**.
- Algunos datos de herramientas dependen de la API de GitHub sin autenticación, limitada a 60 consultas por hora. Si faltan, el documento lo dice.

- El calendario de la Ley de IA de la UE se cita desde la fuente oficial, el Reglamento (UE) 2026/1744 [O16]: los requisitos de alto riesgo del Anexo III se aplican desde el 2/12/2027. X02 queda solo como contexto.
- DS 115-2025-PCM [O13]: el art. 24.1 e) está corroborado; los arts. 24, 30 y 31 (y los demás citados) requieren contraste artículo por artículo con la publicación normativa oficial antes de producir efectos jurídicos.
- El ejemplo de criterios docentes es **ilustrativo** y no está adoptado.

Siguiente paso

Auditoría de F30 por el equipo y, si se aprueba, apertura de F33. **Regla G0.** F33 formula y aprueba ADR-005, que constituye la puerta G0. F34 puede avanzar en paralelo **solo con datos sintéticos** y sin scoring ni recomendación de personas. F35–F40 **no comienzan sin G0 aprobado**.

F30 — Estado del arte de la IA en reclutamiento y selección

Fase F30, versión 1 (30/09/2026), auditada e integrada. Investigación documental: no implementa nada. Cada afirmación cita su fuente con el identificador de la matriz de evidencia ([S01]–[S89] trabajos científicos, [O01]–[O16] normas y documentos oficiales, [X01]–[X02] fuentes secundarias). Las referencias completas están en REFERENCIAS.md.

Convención de este documento. Se distinguen cuatro tipos de afirmación:

- **Evidencia:** lo que reporta una fuente, con su cita.
- **Recomendación de autores:** una guía o propuesta de la fuente, también citada.
- **Inferencia:** lo que el equipo deduce para el caso del Colegio Andino, marcado como tal.
- **Decisión:** las decisiones de ingeniería, que están en F30_Recomendaciones_F33_F40.md.

1. Resumen ejecutivo

- **Lo que funciona en selección no es la IA, es la estructura.** La entrevista estructurada es el procedimiento con mayor validez en la revisión metaanalítica más reciente [S13] y supera a la no estructurada [S14]. Sus componentes conocidos (mismas preguntas, escalas ancladas, calificación por pregunta) [S15, S16] y las escalas ancladas en conducta [S19] son la base más sólida para un «motor» de evaluación.
- **En docentes la predicción es débil.** Un metaanálisis de selección de docentes encontró una relación pequeña, aunque significativa, entre los métodos de selección y la eficacia docente posterior ($r = 0,12$) [S22]. Inferencia: ningún sistema puede prometer predecir al «mejor docente»; puede ordenar y documentar mejor la evidencia.
- **La IA aplicada a personas hereda y amplifica sesgos.**
- Los embeddings usados para cribar CV prefirieron nombres asociados a personas blancas en el 85,1 % de los casos [S11].
- Los LLM reprodujeron estereotipos de raza y género [S83] y de discapacidad [S87].
- El reconocimiento de voz comete casi el doble de errores con hablantes negros que con blancos (WER 0,35 frente a 0,19) [S10] y a veces inventa frases [S81].
- **El «humano en el circuito» no basta por sí solo.**
- En un experimento de contratación con 528 personas, los participantes siguieron recomendaciones sesgadas de una IA hasta en el 90 % de los casos, incluso cuando la consideraban de baja calidad [S84].
- En promedio, las combinaciones humano + IA rinden peor que el mejor de los dos por separado, sobre todo en tareas de decisión [S60].
- Las explicaciones aumentaron la aceptación de la recomendación fuera correcta o no [S58].
- **La evidencia disponible para inferir emociones o personalidad desde rostro o vídeo es insuficiente, mixta y no suficientemente fiable ni generalizable para un uso de alto impacto como la selección** [S07, S08, S09]. En entrevistas en vídeo, añadir rasgos visuales y paraverbales apenas mejora la exactitud y aumenta el sesgo [S85]. La Ley de IA de la UE prohíbe inferir emociones en el trabajo y en la educación (art. 5) [O01]. El reglamento peruano lo clasifica como uso de riesgo alto [O13].
- **El marco legal peruano ya clasifica este caso.** El DS 115-2025-PCM [O13] considera de riesgo alto los sistemas de IA usados para determinar la selección, evaluación, contratación o cese de postulantes (art. 24.1 e), corroborado). Según la lectura de F30, también les exige

transparencia, explicación, supervisión humana, evaluación de impacto previa al desarrollo y registro; esos artículos (24, 30 y 31, entre otros) se contrastan con la publicación oficial antes de producir efectos jurídicos. Los datos de postulantes están protegidos por la Ley 29733 [O15] y su reglamento [O09].

- **Hay evidencia en tensión.**
- Seis sistemas operativos de ML calificaron respuestas abiertas de selección con exactitud y fiabilidad comparables a las de jueces humanos y con poco o ningún impacto adverso [S89].
- Esos sistemas operan en organizaciones con grandes volúmenes de datos de calificación humana; el caso del colegio no tiene ese volumen [S04].
- La evidencia sobre cómo las personas usan esas sugerencias es preocupante [S84, S60].
- Esta tensión se registra como CONFLICTIVA y no se resuelve a favor de la automatización.

Conclusión del estado del arte (inferencia del equipo): la contribución defendible de la IA en este proyecto es **estructurar, documentar y verificar la evidencia** que usan los evaluadores humanos. Ejemplos: rúbricas, procedencia de cada nivel asignado, completitud y acuerdo entre evaluadores. La evidencia reunida **no respalda predecir, puntuar ni recomendar candidatos para este caso, con los datos, el gobierno y las garantías actuales**; las implementaciones a escala [S89] se registran como evidencia en tensión. Esta conclusión coincide con ADR-001 y con el contrato 4 del proyecto.

2. Estrategia y alcance de la revisión

- **Búsqueda y verificación:** veinte consultas en OpenAlex, una por tema A–T, con 500 registros cribados. Se añadieron búsqueda complementaria 2021–2025, bola de nieve y normas oficiales. Todo DOI se verificó en Crossref o DataCite, incluidos sus avisos de retractación. El detalle y el flujo de selección están en la sección 1 de la matriz.
- **Resultado:** 89 trabajos científicos, 16 normas o documentos oficiales y 2 fuentes secundarias de contraste, verificados los 107. Se excluyó un artículo retractado que apareció en el cribado.
- **Límite principal:** la extracción se hizo sobre los resúmenes publicados, no sobre el texto completo. Si un trabajo no tiene resumen disponible, la matriz lo indica y no le atribuye cifras.

3. Estado del arte por tema

A. IA en reclutamiento: prácticas, ética y discriminación

- **Evidencia:**
- Los proveedores de evaluaciones algorítmicas de preempleo eligen objetivos y datos de entrenamiento que pueden incorporar sesgo. Sus técnicas de des-sesgo interactúan de forma compleja con la ley antidiscriminación [S01].
- Dos revisiones sistemáticas, de 36 y 51 artículos, concluyen que la evidencia empírica es escasa y que los riesgos dominantes son discriminación, opacidad y privacidad [S02, S03].
- Los datos de RR. HH. son pequeños, las etiquetas débiles y la rendición de cuentas difícil [S04]. La analítica de personas tiene riesgos propios para organizaciones y empleados [S80].
- La discriminación algorítmica en reclutamiento nace de datos limitados y del diseño; se recomienda combinar medidas técnicas con gobernanza interna y supervisión externa [S05].

- **Evidencia (reacciones de postulantes):** las entrevistas altamente automatizadas reducen la aceptación de los postulantes por menor presencia social y equidad percibida [S06]. Las decisiones de diseño de un procedimiento de selección afectan a la vez su validez, la diversidad y la experiencia del postulante [S86]. La base de evidencia de los procedimientos digitales (pruebas en línea, entrevistas digitales, gamificación, redes sociales) es todavía desigual [S23].
- **Inferencia:** un colegio con pocas convocatorias al año está en el peor escenario para el ML supervisado sobre personas (pocos datos, etiquetas históricas sesgadas, alto impacto).

B. Ajuste persona-puesto (person-job fit)

- **Evidencia:** los modelos neuronales de ajuste persona-puesto aprenden de grandes históricos de postulaciones y decisiones [S25, S26].
- **Inferencia:** en el caso no hay ese histórico. Además, la etiqueta («fue contratado») refleja decisiones pasadas y no idoneidad, con el riesgo de sesgo por etiqueta proxy documentado en otros dominios [S42, S48]. Nivel de aplicabilidad: LIMITADA.

C. Evaluación por competencias y análisis del puesto

- **Recomendación de autores:**
- Hay 20 buenas prácticas para modelar competencias, que se derivan del análisis del puesto y se organizan para su uso en selección [S17].
- El análisis del trabajo ha evolucionado hacia modelos que incluyen actividades, atributos y contexto [S18].
- Las escalas ancladas en conducta (BARS) describen cada nivel con conductas observables [S19].
- **Evidencia:** la validez de la entrevista estructurada se explica en parte porque mide constructos más relacionados con el desempeño [S24].
- **Contexto peruano:** el Marco de Buen Desempeño Docente del MINEDU [O14] organiza dominios, competencias y desempeños del docente. Inferencia: es una fuente candidata de competencias para vacantes docentes, que el colegio debe validar.

D. Entrevistas estructuradas

- **Evidencia:**
- La entrevista estructurada supera a la no estructurada, y las preguntas situacionales y de conducta superan a las de tipo psicológico [S14].
- Tras corregir la sobrecorrección por restricción de rango, las validez se reducen entre 0,10 y 0,20, pero la entrevista estructurada queda primera [S13]. Esto matiza las estimaciones clásicas [S12], que por eso se marcan como CONFLICTIVA.
- La estructura tiene 15 componentes identificados [S15]; la revisión de 20 años confirma sus beneficios y deja preguntas abiertas [S16].
- **Recomendación de autores:** medir la fiabilidad entre evaluadores con el coeficiente de correlación intraclase (ICC), eligiendo la forma adecuada y reportándola con su intervalo [S20, S21].

E. Procesamiento de CV con NLP

- **Evidencia:**
- Los modelos de lenguaje y sus embeddings codifican sesgos sociales [S11, S32].
- Los LLM alucinan contenido [S34] y su escala tiene riesgos documentados [S35].

- Usados como evaluadores de CV, GPT-3.5 y GPT-4 mostraron sesgos de raza, género y discapacidad [S83, S87].
- **Recomendación de autores:** documentar la variedad lingüística y la población de los datos (data statements) [S33]. Definir qué daño se mide antes de medir el «sesgo» [S32].

F. Similitud semántica

- **Evidencia:** SBERT produce embeddings de oraciones comparables por coseno con un costo bajo [S31]. Ese tipo de similitud, usada para recuperar CV, mostró sesgos fuertes por nombre [S11].
- **Inferencia:** la similitud semántica puede servir para **encontrar** fragmentos de evidencia relacionados con un criterio, nunca para **puntuar** candidatos.

G. Extracción de información y habilidades

- **Evidencia:** existen conjuntos anotados y modelos para extraer habilidades de avisos de empleo [S29]. Una revisión de 108 artículos clasifica los métodos y sus retos [S30].
- **Límite:** son avisos de empleo en inglés, no CV en español.
- **Inferencia:** la extracción en español necesitaría datos propios y revisión humana.

H. Ranking y recomendación

- **Evidencia:** las revisiones de recomendadores de empleo identifican retos de datos, bidireccionalidad, equidad y explicabilidad [S27, S28].
- **Contexto del proyecto:** el ranking ya existe (RF-21). Es una suma ponderada normalizada de los puntajes que registran evaluadores humanos (A-24), sin desempate automático (A-26).

I. Decisión multicriterio (MCDM)

- **Evidencia:** AHP deriva pesos de comparaciones por pares con una razón de consistencia [S39]. TOPSIS se ha aplicado a la selección de personal [S40].
- **Inferencia:** el ranking actual ya es un método multicriterio transparente (suma ponderada). AHP puede servir para **justificar los pesos** de una vacante. Reemplazar la suma por TOPSIS u otro método no aporta evidencia de mejor selección y sí añade opacidad.

J. Explicabilidad (XAI)

- **Recomendación de autores:** en decisiones de alto impacto, usar modelos interpretables en lugar de explicar cajas negras [S51].
- **Evidencia:**
- LIME y SHAP explican predicciones localmente [S52, S53], pero en las organizaciones se usan sobre todo para que los ingenieros depuren modelos [S56].
- Las personas prefieren explicaciones contrastivas y selectivas [S55]. Los contrafactuales explican sin abrir el modelo [S54].
- Las explicaciones pueden aumentar la confianza ciega [S58] o reducirla cuando verificarlas cuesta poco [S59].

Detalle en F30_Explainability_Fairness_Gobernanza.md.

K. Equidad algorítmica

- **Evidencia:**

- Las definiciones de equidad (calibración por grupo, equilibrio de errores) no pueden cumplirse a la vez si las tasas base difieren [S44, S45].
- La igualdad de oportunidades exige una etiqueta válida [S43].
- El sesgo puede entrar por la etiqueta (proxy) [S48], por los datos históricos [S42] o en cualquiera de siete puntos del ciclo de vida [S47].
- Los resultados de las intervenciones de equidad son sensibles al preprocesamiento y a la partición [S46].
- Hay catálogos y herramientas de métricas [S41, S49]. Los equipos reales tienen necesidades que la investigación no cubre [S50].
- **Normas:** la regla de los cuatro quintos es un indicio de impacto adverso en EE. UU. [O11]. La Ley Local 144 de Nueva York exige auditorías de sesgo para herramientas automatizadas de empleo [O12].

L. IA responsable y gobernanza

- **Normas y marcos:**
- NIST AI RMF y NIST SP 1270 estructuran la gestión de riesgos y sesgos [O03, O04].
- ISO/IEC 42001 y 23894 son normas de gestión [O05, O06].
- La OCDE y la UNESCO fijan principios [O07, O08].
- **Normas aplicables:** la Ley 31814 y el DS 115-2025-PCM regulan la IA en Perú [O10, O13]. La Ley de IA de la UE clasifica el reclutamiento como alto riesgo y exige supervisión humana efectiva [O01, X01]. El Reglamento (UE) 2026/1744 (Digital Omnibus on AI), publicado en el Diario Oficial el 24/7/2026, aplaza al 2/12/2027 la aplicación de los requisitos de alto riesgo a los sistemas del Anexo III, y no modifica la prohibición de inferir emociones del art. 5.1.f [O16]. El análisis secundario [X02] coincide y queda solo como contexto.

M. Humano en el circuito y sesgo de automatización

- **Evidencia a favor de la cautela:**
- Seguimiento de IA sesgada hasta en el 90 % de los casos [S84].
- Pérdidas de desempeño al combinar humano e IA en tareas de decisión [S60].
- Interacciones dispares por raza [S57].
- La complacencia y el sesgo de automatización afectan a novatos y expertos [S63].
- **Evidencia que matiza:** en tres experimentos del sector público no se encontró sesgo de automatización general, pero sí adherencia selectiva a consejos alineados con estereotipos [S61]. Se marca CONFLICTIVA sobre el sesgo general y consistente sobre la adherencia selectiva.
- **Recomendación de autores:** 18 guías de interacción humano-IA [S62], entre ellas dejar claro qué hace el sistema y permitir corregirlo.

N. Incertidumbre y calibración

- **Evidencia:**
- Muchos clasificadores entregan probabilidades mal calibradas que pueden corregirse [S64, S65, S67].
- El puntaje de Brier mide la exactitud probabilística [S66].
- Con clases desbalanceadas, la curva PR informa más que la ROC [S68].
- **Recomendación de autores:** distinguir la incertidumbre aleatoria de la epistémica [S70].

- **Inferencia:** «evidencia insuficiente» debe representarse de forma explícita y no ocultarse tras un número.

O. Monitoreo y deriva

- **Evidencia:** la deriva de concepto requiere estrategias de detección y adaptación [S75]. Desplegar ML tiene problemas en cada etapa [S78]. MLOps define prácticas y roles [S77].
- **Recomendación de autores:** 28 pruebas de preparación para producción [S76].

P. Auditabilidad

- **Recomendación de autores:** documentar modelos con model cards, que incluyen evaluación por subgrupo [S71]. Documentar conjuntos de datos con datasheets [S72] y con un ciclo de vida auditable [S79]. Hacer una auditoría interna de extremo a extremo antes del despliegue [S73].
- **Evidencia:** la fuga de información del objetivo (leakage) invalida evaluaciones y tiene una taxonomía conocida [S74].
- **Contexto del proyecto:** ya tiene auditoría de solo inserción (AuditLogger y el trigger `audit_logs_append_only`).

Q. Analítica de reclutamiento

- **Evidencia:** la analítica de personas tiene riesgos de vigilancia y discriminación [S80] y depende de datos pequeños y difíciles [S04].
- **Exclusión:** el único trabajo del cribado sobre pérdida de decisión humana y pereza en educación está retractado y se excluyó (ver la matriz, sección 5).

R. Comprensión de documentos

- **Evidencia:** los modelos multimodales de texto, disposición e imagen mejoran la comprensión de documentos visualmente ricos [S37].
- **Inferencia:** los CV del caso son digitales (PDF o DOCX), así que basta extraer texto. El OCR y los modelos de disposición solo harían falta con documentos escaneados.

S. Voz a texto

- **Evidencia:**
- Whisper se entrenó con 680 000 horas de audio multilingüe y generaliza sin ajuste fino [S38].
- Alrededor del 1 % de sus transcripciones contenía frases inventadas, el 38 % de ellas con contenido dañino, más frecuentes con pausas largas [S81].
- Los sistemas de reconocimiento de voz tienen errores desiguales por grupo de hablantes [S10].
- La diarización usa embeddings de voz [S88].
- **Inferencia:** una transcripción no es evidencia hasta que una persona la revisa contra el audio. En el contexto andino deben medirse los errores por variedad de habla antes de usarla.

T. Evaluación de transcripciones y entrevistas

- **Evidencia:**
- Las evaluaciones de personalidad desde vídeo entrenadas con autoinformes tienen poca fiabilidad y validez [S07].

- La evidencia no respalda inferir la emoción a partir de la cara de forma fiable: su expresión varía entre culturas, situaciones y personas [S08, S09].
- En entrevistas multimodales, el contenido verbal solo rinde casi igual que la combinación y con menos sesgo [S85].
- Un LLM usado como juez coincide más del 80 % con preferencias humanas en tareas de chat, pero tiene sesgos de posición, verbosidad y autopromoción [S36].
- La calificación automática de respuestas abiertas puede igualar a jueces humanos con grandes volúmenes de datos [S89]. De otro trabajo del área no hay resumen disponible [S82].
- **Inferencia:** si alguna vez se analizan transcripciones, debe ser **solo el contenido verbal** y para **localizar evidencia**, no para calificar.

4. Perspectiva de recursos humanos

Práctica	Qué dice la evidencia	Implicación para el motor
Análisis del puesto	Base de criterios válidos; se ha ampliado a análisis del trabajo [S18]	Cada criterio de la vacante se justifica con el análisis del puesto
Modelos de competencias	20 buenas prácticas [S17]; el MBDD como marco docente peruano [O14]	Catálogo de competencias versionado (criteria_version)
Entrevista estructurada	Mayor validez [S13, S14]; 15 componentes [S15, S16]	Mismas preguntas por vacante, con calificación por pregunta
BARS	Anclas conductuales sin ambigüedad [S19]	Rúbrica versionada (rubric_version) con descriptor por nivel
Fiabilidad entre evaluadores	ICC con forma e intervalo [S20, S21]	Métrica de calidad del proceso, no de la persona
Impacto adverso	Cuatro quintos como indicio [O11]; auditorías [O12]; límites formales [S44, S45]	Revisión agregada y legalmente sustentada (ver gobernanza)
Reacciones del postulante	Rechazo a la automatización alta [S06]; diseño equilibrado [S86]	Entrevista humana; explicar el procedimiento antes de evaluar

5. Prácticas recomendadas

Las respalda la evidencia; cada una se traduce en decisión en el documento de recomendaciones.

- Criterios derivados del análisis del puesto y competencias explícitas [S17, S18, O14].
- Entrevista estructurada con preguntas situacionales y de conducta, y rúbricas BARS [S13, S14, S15, S19].
- Calificación humana independiente y medición del acuerdo entre evaluadores con ICC [S20, S21].
- Procedencia de cada nivel asignado: pregunta, respuesta, evidencia, criterio, nivel, justificación y confianza [S71, S73].
- Reglas y modelos interpretables antes que cajas negras [S51].
- Explicaciones contrastivas, verificables y para el usuario humano [S55, S56, S59].
- Diseño contra el sesgo de automatización: el evaluador califica antes de ver cualquier salida del sistema [S60, S63, S84].
- Documentación de datos y modelos: datasheets, model cards y data statements [S33, S71, S72, S79].
- Particiones sin fuga de información y pruebas de preparación [S74, S76].

- Evaluación de impacto antes de desarrollar, transparencia y registro [O13].

6. Prácticas a evitar

- **Recomendar, puntuar o preseleccionar candidatos con IA.** Ver la tensión con [S89] en la sección 1. Fuentes: [S01, S11, S58, S60, S83, S84, S87]; ADR-001.
- **Inferir emociones, personalidad o «ajuste cultural»** desde rostro, voz o vídeo [S07, S08, S09, S85, O01, O13].
- **Usar decisiones históricas de contratación como etiqueta de «idoneidad»** [S01, S42, S48].
- **Usar similitud de embeddings como puntaje** [S11].
- **Usar un LLM como juez o resumidor de candidatos** [S34, S36, S83, S87].
- **Usar una transcripción automática sin revisión humana** [S10, S81].
- **Calificar fluidez, acento o prosodia.** Inferencia desde [S10, S85]: penaliza variedades de habla sin relación con el desempeño.
- **Dar SHAP o LIME al usuario final como «explicación»** [S52, S56, S58].
- **Prometer equidad con una sola métrica o con muestras pequeñas** [S44, S45, S46].
- **Entrevistas totalmente automatizadas** [S06].
- **Revisar redes sociales del postulante:** evidencia desigual y riesgo de usar información ajena al puesto [S23].

F30 — Análisis de modelos y técnicas para el motor de reclutamiento

Fase F30, versión 1 (30/09/2026), auditada e integrada. Es un diseño conceptual: no hay código, endpoints, migraciones ni modelos. Las citas remiten a la matriz de evidencia. Lo que no lleva cita es **decisión o inferencia del equipo** y se presenta como tal.

1. Punto de partida: lo que el sistema ya hace

Pieza actual	Qué hace	Qué no hace
Criterios y ponderaciones por vacante (RF-05, RF-20; A-06)	RR. HH. define criterios, rangos y pesos; la suma se valida	No deriva criterios de un análisis del puesto documentado
Resultados de evaluación (RF-19; A-19)	El evaluador asignado registra un puntaje por criterio, una vez	No guarda la evidencia ni la justificación de cada puntaje
Ranking (RF-21, RF-22; A-23, A-24, A-26)	Suma ponderada normalizada de 0 a 100, sin desempate automático	No muestra el porqué de cada puntaje ni el acuerdo entre evaluadores
Decisión final (RF-23; ADR-002)	Humana, con justificación y auditoría de solo inserción	—
RF-29 (experimental)	Estima el riesgo de demora del proceso	No evalúa personas (ADR-001, ADR-004)

Inferencia: el hueco no es de «inteligencia» sino de **estructura y trazabilidad de la evidencia**. Hoy un puntaje es un número sin procedencia; la evidencia de RR. HH. [S13, S15, S19] indica que la calidad de la selección depende justamente de esa estructura.

2. Comparación de enfoques

Enfoque	Datos que necesita	Explicabilidad	Riesgo de sesgo	Evidencia para el caso	Encaje con los contratos del proyecto	Veredicto
Reglas y rúbricas (BARS, completitud, consistencia)	Ninguno histórico; criterios definidos por expertos	Total: cada regla es legible	Bajo, controlable en la rúbrica	FUERTE para estructura [S13, S14, S15, S19]	Total	Base del motor
MCDM (suma ponderada actual; AHP para pesos)	Juicio experto	Alta	El de los pesos	MODERADA para AHP [S39]; LIMITADA para TOPSIS [S40]	Total: ya es RF-21	Mantener la suma ponderada; AHP opcional para justificar pesos
ML interpretable (regresión logística, EBM, árboles poco profundos)	Etiquetas válidas y suficientes, que el caso no tiene	Alta [S51]	Por etiqueta y proxy [S42, S48]	Sin datos válidos para personas [S04, S22]	Prohibido sobre personas (ADR-001); permitido sobre el proceso (RF-29)	Solo sobre el proceso
NLP clásico y embeddings (NER, similitud)	Modelos preentrenados más datos de validación locales	Media: la similitud es un número opaco	Alto: sesgo por nombre y género [S11, S32]	MODERADA para recuperar [S31]; en contra para puntuar [S11]	Solo como localizador de evidencia con confirmación humana; requiere G0	Evaluar en sandbox
LLM (generación, juez, resumen)	Ninguno para usarlo; mucho para validarlo	Baja; alucina [S34]	Alto [S83, S87]; sesgos de juez [S36]	En contra para evaluar personas	Incompatible para evaluar; posible solo en tareas sin personas	Evitar en la evaluación

Conclusión (inferencia del equipo): reglas, rúbricas y la suma ponderada actual cubren lo que la evidencia respalda. El ML interpretable se limita al proceso. NLP y embeddings solo pueden **localizar** evidencia con confirmación humana. Los LLM quedan fuera de toda evaluación de personas.

3. Criterios de vacante y competencias

3.1 Proceso recomendado

La cadena sigue la evidencia de RR. HH. [S17, S18, S19, S24]:

Análisis del puesto → Competencias → Criterios evaluables → Indicadores conductuales
 → Niveles BARS (descriptor por nivel) → Preguntas estructuradas por criterio
 → Pesos justificados (directos o AHP) → Versión congelada al publicar la vacante

- **Análisis del puesto:** tareas, contexto y requisitos. Lo hacen RR. HH. y la Dirección, y queda documentado.
- **Competencias:** se toman de un catálogo versionado (criteria_version). Para docentes, se derivan del MBDD [O14] y las valida el colegio.
- **Criterio evaluable:** cada criterio dice qué método lo evalúa (CV, entrevista, clase demostrativa) y con qué evidencia.
- **Niveles BARS:** cuatro o cinco niveles con conducta observable por nivel, versionados (rubric_version) [S19].
- **Preguntas:** situacionales o de conducta pasada, iguales para todos los postulantes de la vacante [S14, S15].
- **Pesos:** la regla actual de suma 100 (A-06) se mantiene; AHP es opcional para documentar la justificación [S39].
- **Congelamiento:** como hoy (A-07), los criterios no cambian después de publicar; la versión queda ligada a cada evaluación.

3.2 Ejemplo ilustrativo: vacante docente

Ilustrativo y no adoptado. Sirve para mostrar la forma; el contenido lo define y valida el colegio en F33. Las competencias se inspiran en los dominios del Marco de Buen Desempeño Docente [O14] y no reproducen su redacción oficial. Los datos son ficticios.

Criterio (ejemplo)	Dominio MBDD de referencia	Método	Evidencia esperada	Peso (ejemplo)
Planificación de la enseñanza	Preparación para el aprendizaje	Entrevista estructurada + muestra de sesión	Describe cómo diseña una sesión a partir de un propósito de aprendizaje	25
Conducción del aprendizaje en aula	Enseñanza para el aprendizaje	Clase demostrativa observada con rúbrica	Conductas observadas durante la clase	30
Evaluación formativa	Enseñanza para el aprendizaje	Entrevista estructurada	Ejemplo concreto de retroalimentación a un estudiante	20
Trabajo con familias y comunidad	Participación en la gestión escolar	Entrevista estructurada	Situación pasada de coordinación con familias	10
Desarrollo profesional	Profesionalidad e identidad docente	CV + entrevista	Formación y reflexión sobre su práctica	15

Ejemplo de rúbrica BARS para «Evaluación formativa» (ilustrativo):

Nivel	Descriptor conductual
1 — Insuficiente	No describe ninguna práctica de retroalimentación o solo menciona calificar
2 — En inicio	Menciona la retroalimentación en general, sin ejemplo concreto
3 — Logrado	Da un ejemplo concreto: qué observó, qué retroalimentó y cómo respondió el estudiante
4 — Destacado	Da un ejemplo concreto y explica cómo ajustó su enseñanza a partir de lo observado

Quedan **fuera** de los criterios: edad, sexo, estado civil, apariencia, acento, lugar de origen, religión, discapacidad y cualquier otro atributo protegido o su proxy (ADR-001). También quedan fuera la «personalidad» y el «ajuste cultural» [S07, S08].

4. Cadena de procedencia de la evidencia

Es el núcleo del motor. Cada nivel asignado debe poder recorrerse hacia atrás hasta lo que dijo o presentó el postulante.

Pregunta → Respuesta → Evidencia → Competencia/criterio → Nivel → Justificación → Confianza
(versión) (fuente) (fragmento) (criteria_version) (BARS) (texto humano) (explícita)

Eslabón	Qué es	Quién lo produce	Regla
Pregunta	Ítem de la guía de entrevista, con id y rubric_version	RR. HH.	Igual para todos los postulantes de la vacante
Respuesta	Notas del evaluador o fragmento de transcripción revisada	Evaluador (o STT revisado por humano)	Una transcripción sin revisar no es respuesta válida [S81]
Evidencia	Fragmento concreto: cita textual, sección del CV o conducta observada	Evaluador; el sistema solo puede sugerir fragmentos	Toda evidencia apunta a su fuente (documento, minuto, línea)
Criterio	Criterio y competencia a los que se asigna la evidencia	Evaluador	Debe existir en la criteria_version congelada
Nivel	Nivel BARS elegido	Solo el evaluador humano	Sin nivel sugerido por el sistema (ADR-001) [S58, S84]
Justificación	Por qué esa evidencia corresponde a ese nivel y no al siguiente	Evaluador	Contrastiva [S55]; obligatoria
Confianza	Suficiencia de la evidencia: suficiente, parcial o insuficiente	Evaluador; el sistema señala la ausencia de evidencia	Incertidumbre epistémica explícita [S70]; no es una probabilidad

Lo que el sistema puede verificar y decir (recomendaciones sobre el proceso, no sobre la persona):

- falta evidencia para un criterio;
- hay un nivel sin justificación;
- dos evaluadores difieren en más de un nivel;
- una pregunta no se hizo a todos los postulantes;
- se cambió la rúbrica después de publicar la vacante.

Decisión de ingeniería propuesta: estas verificaciones son **reglas deterministas**, no ML.

5. Pipeline seguro de audio y vídeo

Recomendación base: no grabar. La entrevista estructurada con notas del evaluador ya captura la evidencia necesaria [S13, S15]. La grabación solo se justifica si F33 demuestra una necesidad concreta (p. ej., revisión por un segundo evaluador) y pasa la puerta G0.

Si se aprueba, el pipeline se limita a esto:

Consentimiento informado específico → Grabación de solo audio (vídeo: no) → Almacenamiento cifrado, con plazo de retención

- STT local (sin enviar audio a terceros) → Revisión humana de la transcripción contra el audio
- Segmentación por pregunta (marcas manuales del evaluador, sin huella de voz)

- [Opcional, sandbox] sugerencia de fragmentos por criterio → Confirmación humana
 → Calificación humana con BARS → Eliminación del audio al vencer el plazo

Paso	Control	Fuente
Consentimiento	Específico para grabar y transcribir; con alternativa sin grabación y sin penalización	[O09, O13]
Solo audio	Añadir vídeo apenas mejora la exactitud y aumenta el sesgo	[S85]
STT local	Whisper o una variante, con versión fijada	[S38]
Revisión humana	Contra el audio: corrige alucinaciones y errores	[S81]
Medición por variedad de habla	WER por grupo de hablantes en un piloto con voces ficticias o consentidas	[S10]
Segmentación	Por marcas manuales o canales separados; sin diarización biométrica	[S88, O09]
Retención	Plazo definido y borrado verificable	[O09]

Prohibido en cualquier versión:

- emociones, estados de ánimo, estrés o «nerviosismo» [S08, S09, O01, O13];
- personalidad o rasgos [S07];
- expresiones faciales, mirada o gestos [S08, S85];
- prosodia, tono, fluidez, acento o velocidad del habla [S10, S85];
- huellas de voz o identificación biométrica [S88, O13];
- calificación automática del contenido [S84, S89 en tensión].

6. Métricas por tarea


Tarea	Métrica	Por qué	Fuente
Acuerdo entre evaluadores	ICC (forma declarada, intervalo del 95 %)	Fiabilidad de la calificación humana	[S20, S21]
Compleitud de la evidencia	Porcentaje de criterios con evidencia y justificación	Calidad del proceso	Decisión de ingeniería
Transcripción (si se aprueba)	WER global y por grupo de hablantes ; tasa de alucinación detectada en la revisión	Errores desiguales y frases inventadas	[S10, S81]
Sugerencia de fragmentos (si se aprueba)	Precisión, exhaustividad y F1 por tramo frente a la anotación humana	Mide la localización, no al postulante	[S29, S30]
Modelo del proceso (RF-29)	PR-AUC, Brier y calibración	Clases desbalanceadas y probabilidades	[S64, S66, S68]
Ranking	Estabilidad ante cambios de pesos (análisis de sensibilidad)	Transparencia del orden	Decisión de ingeniería
NDCG	Solo si existe un juicio de relevancia válido, que hoy no existe	Evitar métricas sin verdad de terreno	[S69]
Equidad	Tasas de selección por grupo (cuatro quintos como indicio) solo con datos legales y muestra suficiente	Impacto adverso	[O11, S44, S46]

Tarea	Métrica	Por qué	Fuente
Supervisión humana	Tasa de desacuerdo con la sugerencia de fragmentos; tiempo de revisión	Detectar aceptación acrítica	[S58, S84]

Ninguna métrica de esta tabla puntúa a un postulante. Todas miden la calidad del proceso o de una herramienta.

7. Arquitectura futura (conceptual)

Extiende el patrón de RF-29 (Laravel ↔ FastAPI con fallback, ver docs/v1.1/phase-16-laravel-ml-integration.md) y los principios de MLOps y despliegue [S76, S77, S78]:



Requisito	Diseño
REST	Contrato versionado (/v2/...), validación de esquema en ambos extremos, autenticación interna como en RF-29
Asíncrono	Trabajos en cola; la interfaz nunca espera al servicio ML
Idempotencia	analysis_run_id como clave; repetir una petición no duplica resultados
Timeouts y reintentos	Límites explícitos; reintentos acotados con espera exponencial; sin reintento ante errores de validación
Circuit breaker	Tras N fallos se abre el circuito y la página sigue funcionando sin la sugerencia, como RF-29
Versionado	model_version, rubric_version, criteria_version e input_snapshot_hash en cada ejecución
Multiempresa	organization_id permanece preferentemente en Laravel, que aplica Policies y scope global. No se envía al servicio ML stateless salvo justificación explícita ; en su lugar viajan identificadores técnicos pseudónimos mínimos (p. ej., analysis_run_id o un token por ejecución). Ningún modelo se entrena ni consulta con datos de otra organización
Privacidad	El servicio ML recibe texto minimizado, sin nombre, DNI, correo ni foto, y solo identificadores pseudónimos; no persiste entradas

8. Modelo de auditoría de una ejecución

Registro por cada analysis_run. La auditoría crítica sigue en AuditLogger (solo inserción).

Campo	Persistir	Motivo o cuidado
analysis_run_id	Sí	Clave e idempotencia
organization_id, vacancy_id, application_id	Sí, solo en Laravel	Multiempresa y trazabilidad; no viajan al servicio ML salvo justificación explícita
criteria_version, rubric_version	Sí	Reproducibilidad del marco de evaluación
model_version (y hash del artefacto)	Sí	Qué modelo o regla produjo la sugerencia
input_snapshot_hash	Sí	Probar qué entrada se usó sin guardar la entrada

Campo	Persistir	Motivo o cuidado
Texto de entrada completo	No	PII; se reconstruye desde la fuente con su hash si hace falta
evidence_refs	Sí	Ids y posiciones de los fragmentos, no el texto
suggestion	Sí, si existe	Solo fragmentos sugeridos por criterio; nunca nivel ni puntaje
human_level, human_justification, evidence_sufficiency	Sí	Eslabones humanos de la cadena
reviewer_id, reviewed_at	Sí	Quién y cuándo
suggestion_seen_before_scoring	Sí	Debe ser falso: control del sesgo de anclaje [S84]
human_disagreement	Sí	Si el humano descartó la sugerencia; monitorea la aceptación acrítica [S58]
latency_ms, status, error_code	Sí	Operación
final_decision	No en este registro	La decisión vive en RF-23 y su auditoría; el análisis nunca la referencia como causa
Audio, transcripción no revisada, embeddings	No	Datos personales o biométricos sin necesidad de conservarse
Atributos sensibles (sexo, edad, discapacidad...)	No	Solo en un estudio de equidad separado, con base legal (ver gobernanza)

F30 — Explicabilidad, equidad y gobernanza

Fase F30, versión 1 (30/09/2026), auditada e integrada. Las citas remiten a la matriz de evidencia. Las referencias a normas son un análisis técnico para orientar el diseño y **no constituyen asesoría legal**: la evaluación de impacto la valida una persona con competencia jurídica.

1. Explicabilidad (XAI)

1.1 Qué dice la evidencia

Hallazgo	Fuente	Implicación
En alto impacto conviene un modelo interpretable antes que explicar una caja negra	[S51]	Reglas y suma ponderada antes que modelos opacos
LIME y SHAP dan atribuciones locales, aproximadas y a veces inestables	[S52, S53]	Útiles para depurar, no para justificar una decisión sobre una persona
En las organizaciones, la explicabilidad la usan sobre todo los ingenieros	[S56]	Hay que diseñar la explicación para el evaluador, el aprobador y el postulante
Las personas prefieren explicaciones contrastivas («por qué este nivel y no el siguiente»)	[S55]	La justificación del nivel BARS es contrastiva
Los contrafactuales explican sin revelar el modelo	[S54]	«Qué evidencia faltaría para el nivel siguiente»
Las explicaciones aumentaron la aceptación de la recomendación, correcta o no	[S58]	Una explicación no es un control: puede empeorar la dependencia
Las explicaciones reducen la sobredependencia cuando verificarlas cuesta poco	[S59]	Cada explicación cita la evidencia y se verifica con un clic

1.2 Diseño de explicaciones recomendado

Destinatario	Qué necesita	Forma
Evaluador	Por qué asigna un nivel y qué evidencia lo respalda	Su propia justificación, con enlace a la evidencia (cadena de procedencia)
Aprobador / Dirección	Por qué el ranking queda así y dónde hay dudas	Desglose por criterio de la suma ponderada (A-24), acuerdo entre evaluadores y criterios con evidencia insuficiente
Postulante	Qué se evaluó y con qué criterios	Criterios y procedimiento antes de evaluar [S86]; si lo pide, explicación comprensible de los criterios [O13 art. 25.3]
Auditor	Qué versión de criterios, rúbrica y modelo se usó	criteria_version, rubric_version, model_version e input_snapshot_hash

Los valores SHAP, la «importancia de características» y las probabilidades sin calibrar **no se muestran** a evaluadores ni postulantes [S56, S58, S65].

2. Equidad (fairness)

2.1 Métricas posibles y sus límites

Métrica	Qué mide	Límite principal	Fuente
Razón de tasas de selección (regla de los cuatro quintos)	Si un grupo es seleccionado con menos del 80 % de la tasa del más favorecido	Es un indicio, no una prueba. Con pocos postulantes por vacante la razón es inestable y no concluye nada	[O11]
Paridad demográfica	Igual tasa de resultado positivo por grupo	Ignora diferencias legítimas; choca con otras definiciones	[S41, S44]
Igualdad de oportunidades / de probabilidades	Iguals tasas de acierto entre quienes «merecen» el resultado	Requiere una etiqueta válida de idoneidad, que no existe	[S43]
Calibración por grupo	Una misma puntuación significa lo mismo en cada grupo	Incompatible con el equilibrio de errores si las tasas base difieren	[S44, S45]
Acuerdo entre evaluadores por grupo	Si el ICC es menor con ciertos postulantes	Requiere el atributo de grupo y muestras suficientes	[S20, S21]
WER por grupo de hablantes	Si la transcripción es peor para ciertos hablantes	Requiere un piloto con audio consentido o ficticio	[S10]

Límites generales:

- no pueden cumplirse todas las definiciones a la vez [S44, S45];
- los resultados varían con el preprocesamiento y la partición [S46];
- la etiqueta puede ser un proxy sesgado [S48];
- el sesgo entra en cualquier etapa del ciclo de vida [S47];
- medir equidad por grupo **exige datos sensibles**, que tienen su propio riesgo legal (sección 4.3).

2.2 Recomendación: equidad del procedimiento antes que equidad estadística

Inferencia del equipo: en el caso hay pocos postulantes por vacante y no hay base legal para recoger atributos sensibles. Por eso la equidad se controla primero en el **procedimiento**, donde la evidencia es más sólida:

- **Mismas preguntas y misma rúbrica** para todos los postulantes de una vacante [S14, S15].
- **Anclas conductuales** que reducen la ambigüedad de la calificación [S19].
- **CV minimizado para el evaluador**: sin foto, edad, estado civil ni dirección. El nombre se oculta en la etapa de revisión documental cuando sea viable. Inferencia desde [S11]: hay sesgo por nombre en sistemas, y el sesgo humano es plausible.
- **Calificación independiente** de dos evaluadores en los criterios de mayor peso, con ICC y revisión de discrepancias [S20, S21].
- **Criterios excluidos**: acento, fluidez, apariencia, «ajuste cultural» y personalidad [S07, S10, S85].
- **Revisión agregada de impacto adverso** solo cuando existan base legal, datos y muestra suficiente, a lo largo de varias convocatorias y nunca por vacante individual [O11, S46].

3. Supervisión humana y sesgo de automatización

3.1 Evidencia

- Las personas siguieron recomendaciones raciales sesgadas de una IA hasta en el 90 % de los casos, incluso cuando la juzgaban de baja calidad. Sin IA, o con IA sin sesgo, seleccionaron por igual a ambos grupos [S84].
- Las combinaciones humano + IA rindieron en promedio peor que el mejor de los dos ($g = -0,23$), con pérdidas en tareas de decisión [S60].
- Al usar evaluaciones de riesgo algorítmicas, las personas mostraron interacciones dispares por raza [S57].
- La complacencia y el sesgo de automatización producen errores de omisión y de comisión, en novatos y en expertos [S63].
- **En tensión:** en tres experimentos no se encontró sesgo de automatización general, pero sí adherencia selectiva a consejos alineados con estereotipos [S61].
- ADR-002 ya rechazó la preselección automática con confirmación posterior por el sesgo de anclaje.

3.2 Medidas de diseño

Medida	Contra qué protege	Fuente
El sistema no recomienda candidatos ni sugiere niveles	Anclaje y seguimiento de IA sesgada	[S84, S58]; ADR-001
El evaluador califica antes de ver cualquier ayuda del sistema	Anclaje	[S84, S63]
Las «recomendaciones» del sistema se refieren al proceso (falta evidencia, discrepancia, pregunta omitida)	Confundir ayuda con decisión	[S62]; ADR-001
Justificación obligatoria en cada nivel y en la decisión final	Aprobación pasiva	[S55]; RF-23
Registrar si se aceptó o descartó cada fragmento sugerido	Detectar aceptación acrítica	[S58]
Capacitación del evaluador sobre los límites del sistema	Exceso de confianza	[O13 art. 28.11]
Capacidad de detener, corregir o invalidar cualquier salida	Supervisión efectiva	[O13 art. 28.11, O01 art. 14]

Regla central: RECOMENDACIÓN DEL SISTEMA $\neq$ DECISIÓN FINAL DE CONTRATACIÓN. La decisión final es humana, con confirmación explícita y justificación (RF-23, ADR-002). Ninguna salida del motor se registra como causa de la decisión.

4. Gobernanza

4.1 Marco regulatorio aplicable al caso

Norma	Qué exige o prohíbe (relevante)	Consecuencia para F33–F40
DS 115-2025-PCM, art. 24.1 e) [O13] (corroborado)	Riesgo alto: sistemas de IA que determinan procesos de selección, evaluación, contratación y cese de trabajadores o postulantes	El motor, aunque solo asista, entra en esta zona; se trata como riesgo alto por prudencia
DS 115-2025-PCM, art. 24.1 b) [O13]	Riesgo alto: evaluar a niños, niñas y adolescentes en educación, salvo función complementaria	No aplica a docentes; prohíbe extender el motor a estudiantes sin nueva evaluación
DS 115-2025-PCM, art. 24.1, final del inciso i) [O13]	Riesgo alto: inferir emociones de una persona en entornos de trabajo y centros educativos	Excluido del diseño (además, la evidencia sobre su fiabilidad es insuficiente y mixta [S08])
DS 115-2025-PCM, art. 23 [O13]	Uso indebido (prohibido): inferir origen racial o étnico, opiniones y otros datos sensibles a partir de datos biométricos	Sin biometría ni inferencia de atributos sensibles

Norma	Qué exige o prohíbe (relevante)	Consecuencia para F33–F40
DS 115-2025-PCM, art. 25 [O13]	Transparencia algorítmica; si el sistema toma decisiones que afectan derechos, explicación comprensible a los afectados	Explicaciones por criterio y evidencia (sección 1.2)
DS 115-2025-PCM, art. 28.11 [O13]	Entidades públicas: supervisión humana capacitada y capaz de detener, corregir o invalidar	Si el colegio es privado no es obligatorio; se adopta como buena práctica
DS 115-2025-PCM, art. 30 [O13]	Evaluación de impacto previa al desarrollo o implementación de un sistema de riesgo alto	Condición de G0 (aprobada en F33), antes de F35–F40
DS 115-2025-PCM, art. 31.1 [O13]	Sector privado: registro actualizado de principios de funcionamiento y fuentes de datos	Registro de modelos y datasets (F34, F36)
Ley 29733 [O15] y DS 016-2024-JUS [O09]	Protección de datos personales: consentimiento, finalidad, proporcionalidad, seguridad; datos sensibles	Gobernanza del dataset (sección 4.3)
RGPD, art. 22 [O02] (referencia)	Derecho a no ser objeto de decisiones basadas únicamente en tratamiento automatizado	Coincide con RF-23: la decisión final es humana
Ley de IA de la UE [O01, X01] (referencia)	Prohíbe el reconocimiento de emociones en el trabajo y la educación; reclutamiento de alto riesgo; supervisión humana consciente del sesgo de automatización	Estándar comparado de diseño
Reglamento (UE) 2026/1744 [O16] (referencia)	Aplaza al 2/12/2027 los requisitos de alto riesgo para los sistemas del Anexo III; no cambia la prohibición del art. 5.1.f	Calendario oficial de la UE; sustituye a la fuente secundaria [X02]
NIST AI RMF y SP 1270 [O03, O04]; ISO/IEC 42001 y 23894 [O05, O06]	Gestión de riesgos y sesgos	Estructura de la evaluación de impacto

Vigencia del DS 115-2025-PCM: entra en vigor a los 90 días hábiles de su publicación (9/9/2025), salvo algunas disposiciones que rigen desde el día siguiente. La fecha exacta de vigencia se confirma en la evaluación de impacto.

Alcance de la lectura del DS 115-2025-PCM: el art. 24.1 e) está corroborado. Los arts. 24, 30 y 31 —y los demás citados en esta tabla— se leyeron en una copia no oficial de la publicación y **requieren contraste artículo por artículo con la publicación normativa oficial antes de producir efectos jurídicos.**

4.2 Conflicto de gobierno con el proyecto actual (hallazgo crítico)

La visión de un «motor inteligente» que **recomiende** choca con decisiones vigentes del proyecto:

Decisión vigente	Texto	Choque con la visión
Contrato 4 (CLAUDE.md)	El ML es informativo y operacional, sobre el proceso, nunca evaluando, puntuando ni clasificando personas	Cualquier puntuación o nivel sugerido por ML sobre un postulante
ADR-001	Prohíbe «puntuar, ordenar, recomendar, filtrar, preseleccionar o descartar postulantes; predecir desempeño, idoneidad...»	Recomendación de candidatos
ADR-001, alternativas rechazadas	Rechazó el «modelo de recomendación de candidatos» y la «puntuación asistida solo como sugerencia»	Sugerir niveles o puntajes

Decisión vigente	Texto	Choque con la visión
Alcance F9	OUT-04 (selección automática por IA o ML), OUT-05 (inferencia de idoneidad), OUT-11 (uso decisorio de RF-29)	Todo uso del ML en la selección

La evidencia de F30 **respalda esas decisiones** [S58, S60, S84]. Por eso F30 no las cambia: propone la puerta **G0** (ver recomendaciones), en la que el equipo decide de forma explícita y documentada qué puede hacer el motor. **Regla G0**. F33 formula y aprueba ADR-005, que constituye la puerta G0. F34 puede avanzar en paralelo **solo con datos sintéticos** y sin scoring ni recomendación de personas. F35–F40 **no comienzan sin G0 aprobado**. Lo que F30 recomienda —ayuda sobre el **proceso** y la **evidencia**, sin puntuar personas— cabe dentro de ADR-001 si un nuevo ADR lo precisa.

4.3 Gobernanza del dataset (F34)

Principio: sintético primero. Ningún dato real de postulantes entra al proyecto (contrato 7).

Tema	Regla	Fuente
Origen	Datos sintéticos generados con semilla y script versionado, como en RF-29; nunca CV ni entrevistas reales	Contrato 7
Anonimización	Si en el futuro hubiera datos reales: seudonimización en origen, eliminación de identificadores directos y verificación con texto ficticio; se mide el error de la herramienta (p. ej., Presidio o spaCy en español)	[O09, S33]
Consentimiento y finalidad	Específicos para investigación o mejora del proceso; separados de la postulación; revocables	[O09]
Minimización	Solo los campos que exige el criterio; sin foto, edad, sexo, estado civil ni dirección	[O09]; ADR-001
Linaje	Cada conjunto con id, versión, SHA-256, script generador, semilla y fecha	[S72, S79]
Dataset card	Motivación, composición, recolección, preprocesamiento, usos permitidos y prohibidos, variedad lingüística	[S33, S72]
Registro	Inventario de conjuntos y modelos con responsable y estado	[O13 art. 31.1, S71]
Fuga de información	Particiones por convocatoria y en orden temporal; ningún campo derivado del resultado (p. ej., estado final) como entrada	[S74]
Etiquetas	Prohibido usar «contratado» o «seleccionado» como verdad de idoneidad	[S42, S48]
Retención y borrado	Plazos definidos; borrado verificable	[O09]
Acceso	Por organización (organization_id) y rol; nada cruza entre organizaciones	Contrato 5

Atributos sensibles. No se proponen para recolección. Antes de considerar cualquiera, el equipo debe responder estas cinco preguntas y registrarlas en la evaluación de impacto:

Pregunta	Ejemplo para «sexo» o «discapacidad» con fines de auditoría de equidad
Necesidad	¿Hay un análisis de equidad concreto que no pueda hacerse sin el dato? Con pocos postulantes, la respuesta probable es no (sección 2.1)
Consentimiento	Voluntario, separado de la postulación, sin efecto en la evaluación y revocable

Pregunta	Ejemplo para «sexo» o «discapacidad» con fines de auditoría de equidad
Base legal	Tratamiento de datos sensibles según la Ley 29733 [O15] y su reglamento [O09]; validación jurídica
Finalidad	Solo auditoría agregada de equidad; nunca como entrada de un modelo ni visible para evaluadores
Seguridad	Almacenamiento separado, acceso restringido, agregación mínima para publicar, borrado

Decisión recomendada para F34: no recolectar atributos sensibles. Si F37 necesitara medir equidad, usará datos sintéticos con atributos simulados para probar el método, y lo declarará como tal.

4.4 Evaluación de impacto previa (contenido mínimo)

Estructurada con NIST AI RMF (gobernar, mapear, medir, gestionar) [O03] y el art. 30 del DS 115-2025-PCM [O13]:

- Finalidad, usuarios y personas afectadas (postulantes, evaluadores, Dirección).
- Clasificación de riesgo (art. 24.1 e) y justificación.
- Datos: origen, base legal, minimización, retención (sección 4.3).
- Riesgos de sesgo humano, sistémico y estadístico [O04, S47] y sus medidas.
- Supervisión humana y sesgo de automatización (sección 3).
- Transparencia y explicaciones (sección 1.2).
- Seguridad y cadena de suministro (ver herramientas).
- Monitoreo y criterios de retirada: cuándo se apaga una función.
- Responsable de la evaluación, revisión jurídica y fecha.

F30 — Análisis de herramientas, skills y servidores MCP

Datos generados por docs/academico/tools/f30/f30.py desde datos/herramientas.json (consultas a la API de GitHub, PyPI, npm y OSV con herramientas.py) y la clasificación de m_herramientas.py. **En F30 no se instaló nada:** ni paquetes, ni skills, ni servidores MCP.

1. Método

- **Datos objetivos por herramienta:** existencia y propietario del repositorio, licencia, archivado, última actividad, estrellas; versión y fecha en el registro del paquete; avisos de seguridad en OSV, tanto el total histórico como los que afectan a la última versión publicada.
- **Clasificación:** RECOMENDADO, EVALUAR EN SANDBOX, NO NECESARIO o EVITAR, según necesidad real en F33–F40, evidencia de la matriz, licencia, mantenimiento, avisos y superficie de ataque.
- **Un aviso histórico no es una vulnerabilidad actual:** indica cuánta superficie de ataque ha tenido el proyecto (p. ej., lectores de PDF frente a archivos malformados). Lo que bloquea es un aviso en la versión que se instalaría.
- **Skills y MCP locales:** inventario de solo lectura de .claude/skills/, ~/.claude/skills, plugins y conectores visibles en la sesión, revisando archivos, scripts, hooks, allowed-tools e instrucciones.

2. Resultado

Herramientas evaluadas: 49. RECOMENDADO: 6, EVALUAR EN SANDBOX: 15, NO NECESARIO: 24, EVITAR: 4.

- **RECOMENDADO:** scikit-learn, Fairlearn, nbstripout, pip-audit, OSV-Scanner, Zotero.
- **EVALUAR EN SANDBOX:** InterpretML (EBM), SHAP, AIF360, Pandera, spaCy, sentence-transformers, Microsoft Presidio, Whisper (OpenAI), faster-whisper, whisper.cpp, FFmpeg, pypdf, pdfplumber, python-docx, Ollama.
- **NO NECESARIO:** XGBoost, LightGBM, CatBoost, MLflow, DVC, Evidently, Great Expectations, Hugging Face Transformers, pgvector, FAISS, Qdrant, Vosk, Apache Tika, Docling, Unstructured, Tesseract OCR, JupyterLab, Mermaid, Better BibTeX for Zotero, MCP Reference Servers (fetch, filesystem, git), GitHub MCP Server, Hugging Face MCP Server, arXiv MCP Server, Context7 MCP.
- **EVITAR:** LIME, pyannote.audio, PyMuPDF, Zotero MCP.

3. Comparación por necesidad

Modelo base (si F36 lo justifica)

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
scikit-learn	RECOMENDADO	F36, F37, F39	Ya es la base de RF-29; trae modelos interpretables (regresión logística, árboles poco profundos), calibración y métricas [S51, S64, S67]	Fijar versión; ningún modelo puntúa personas sin la puerta G0
InterpretML (EBM)	EVALUAR EN SANDBOX	F36	Modelos aditivos interpretables (glassbox), alineados con preferir modelos interpretables a explicaciones post hoc [S51]	Solo si F36 confirma que se necesita un modelo y no bastan reglas

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
XGBoost	NO NECESARIO	—	Con datos pequeños, un modelo de boosting no compensa su menor interpretabilidad en una decisión de alto impacto [S04, S51]	Reconsiderar solo con datos y G0
LightGBM	NO NECESARIO	—	Igual que XGBoost [S04, S51]	Igual que XGBoost
CatBoost	NO NECESARIO	—	Igual que XGBoost [S04, S51]	Igual que XGBoost

Explicabilidad

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
SHAP	EVALUAR EN SANDBOX	F37	Atribuciones útiles para depurar internamente [S53]; la evidencia muestra que las explicaciones sirven sobre todo a ingenieros [S56] y pueden aumentar la aceptación acrítica [S58]	Nunca como explicación para el evaluador o el postulante
LIME	EVITAR	—	Explicaciones locales aproximadas e inestables [S52]; el repositorio no registra actividad desde julio de 2024 (ver datos)	Mantenimiento detenido
InterpretML (EBM)	EVALUAR EN SANDBOX	F36	Modelos aditivos interpretables (glassbox), alineados con preferir modelos interpretables a explicaciones post hoc [S51]	Solo si F36 confirma que se necesita un modelo y no bastan reglas

Equidad

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Fairlearn	RECOMENDADO	F37, F39	Métricas desagregadas por grupo y comparación de tasas de selección, de licencia MIT y con dependencias moderadas [S41, S46]	Las métricas exigen datos de grupo con base legal y consentimiento (F34) [O09, O13]
AIF360	EVALUAR EN SANDBOX	F37	Catálogo amplio de métricas y mitigaciones [S49]	Más pesado que Fairlearn; solo si F37 necesita una métrica que Fairlearn no tiene

Registro de modelos y experimentos

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
MLflow	NO NECESARIO	—	A la escala del caso, un registro de modelos con model_version, hash y model card versionados en Git basta [S71, S77]; MLflow añade un servidor con muchos avisos de seguridad históricos (ver datos)	Superficie de ataque de un servidor adicional

Versionado y validación de datos

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
DVC	NO NECESARIO	—	Los conjuntos sintéticos son pequeños; manifiesto SHA-256 y dataset card en Git cubren el linaje [S72, S79]	Reconsiderar si un conjunto supera lo razonable para Git

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Pandera	EVALUAR EN SANDBOX	F34	Validación de esquema de los conjuntos (tipos, rangos, columnas prohibidas como nombre o DNI) [S72, S74]	Fijar versión
Great Expectations	NO NECESARIO	—	Cubre lo mismo que Pandera con más dependencias	—

Monitoreo y deriva

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Evidently	NO NECESARIO	—	Con pocas convocatorias al año, la deriva se revisa con reportes simples por convocatoria [S75]	Reconsiderar con volumen

Texto, entidades y anonimización

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
spaCy	EVALUAR EN SANDBOX	F34, F35	Reconocimiento de entidades para anonimizar y segmentar texto en español [S33]	Medir errores de anonimización con texto ficticio antes de usarlo
Microsoft Presidio	EVALUAR EN SANDBOX	F34	Detección y anonimización de datos personales en texto [O09]	Sus reconocedores por defecto están orientados al inglés: medir en español. El repositorio ya no pertenece a la organización microsoft (GitHub lo redirige): verificar quién publica el paquete
Hugging Face Transformers	NO NECESARIO	—	Solo entraría como dependencia de otra herramienta; muchos avisos históricos y carga de pesos de modelos de terceros (ver datos)	Pesos en formatos ejecutables (pickle): solo safetensors y repositorios fijados

Similitud semántica y búsqueda vectorial

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
sentence-transformers	EVALUAR EN SANDBOX	F35	Embeddings para localizar fragmentos de evidencia relacionados con un criterio [S31]	Nunca como puntuación de candidatos: los embeddings reproducen sesgos de nombre y género [S11]
pgvector	NO NECESARIO	—	F33–F40 no necesitan búsqueda vectorial persistente; si llegara a necesitarse, pgvector usa el PostgreSQL ya existente en lugar de un servicio nuevo	Decisión diferida
FAISS	NO NECESARIO	—	Igual que pgvector; además añade una dependencia nativa	—
Qdrant	NO NECESARIO	—	Servicio adicional sin necesidad demostrada	Infraestructura nueva

Voz a texto y diarización

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Whisper (OpenAI)	EVALUAR EN SANDBOX	F35	Transcripción local robusta y multilingüe [S38]	Alucina frases en una parte pequeña de los casos [S81] y el error varía por hablante [S10]: toda transcripción se revisa contra el audio

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
faster-whisper	EVALUAR EN SANDBOX	F35	El mismo modelo Whisper con inferencia más eficiente	Mismos riesgos que Whisper [S10, S81]
whisper.cpp	EVALUAR EN SANDBOX	F35	Whisper en C/C++ sin Python, útil en equipos modestos	Mismos riesgos que Whisper [S10, S81]
Vosk	NO NECESARIO	—	La matriz no reúne evidencia de su exactitud en español; Whisper ya cubre la necesidad	Alternativa solo si Whisper no fuera viable
pyannote.audio	EVITAR	—	La diarización usa embeddings de voz [S88], que son datos biométricos; para separar entrevistador y postulante bastan canales separados o marcas manuales [O09, O13]	Dato biométrico; modelos con acceso condicionado en Hugging Face
FFmpeg	EVALUAR EN SANDBOX	F35	Conversión y normalización de audio antes de transcribir	Solo con la puerta del audio aprobada; LGPL con componentes GPL opcionales: compilar sin ellos

Documentos (PDF, DOCX, OCR)

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
pypdf	EVALUAR EN SANDBOX	F35	Extracción de texto de PDF en Python puro, licencia BSD	Muchos avisos históricos por PDF malformados: límites de tamaño y tiempo, y proceso aislado
pdfplumber	EVALUAR EN SANDBOX	F35	Extracción con posiciones (tablas, columnas), licencia MIT	Mismas precauciones que pypdf
python-docx	EVALUAR EN SANDBOX	F35	Lectura de CV en DOCX, licencia MIT	Fijar versión
PyMuPDF	EVITAR	—	Licencia AGPL-3.0: requiere revisión de compatibilidad AGPL o licencia comercial; se evita por prudencia	Riesgo de licencia
Docling	NO NECESARIO	—	Descarga modelos de disposición; los CV del caso son digitales [S37]	Peso y modelos de terceros
Unstructured	NO NECESARIO	—	Muchas dependencias para una necesidad que cubren pypdf y python-docx	—
Apache Tika	NO NECESARIO	—	Requiere JVM; para PDF y DOCX digitales bastan bibliotecas Python	Avisos históricos (ver datos)
Tesseract OCR	NO NECESARIO	—	Solo haría falta con documentos escaneados [S37]	—

Cuadernos y reproducibilidad

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
JupyterLab	NO NECESARIO	—	El proyecto usa scripts reproducibles; los cuadernos guardan salidas que pueden filtrar datos	Avisos históricos (ver datos)
nbstripout	RECOMENDADO	F34, F36	Si el equipo usa cuadernos, elimina sus salidas antes del commit	Solo tiene sentido si se adoptan cuadernos

Seguridad de dependencias

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
pip-audit	RECOMENDADO	F33–F40	Auditoría de dependencias Python (PyPA) del ml-service	—

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
OSV-Scanner	RECOMENDADO	F33–F40	Auditoría de dependencias en varios ecosistemas (Composer, npm, PyPI) con la base OSV usada en este análisis	—

LLM local

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Ollama	EVALUAR EN SANDBOX	F33	LLM local, sin enviar datos fuera; solo para tareas que no evalúan personas (p. ej., borradores de preguntas que revisa un humano)	Nunca para puntuar ni resumir candidatos: alucinación [S34] y sesgos [S83, S87]

Bibliografía y diagramas

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
Zotero	RECOMENDADO	F33–F40	Gestión bibliográfica de escritorio; la AGPL no afecta su uso local	—
Better BibTeX for Zotero	NO NECESARIO	—	Las referencias se generan desde Crossref y DataCite con un script reproducible	—
Mermaid	NO NECESARIO	—	El proyecto ya formaliza diagramas con PlantUML y PowerDesigner	—

Servidores MCP

Herramienta	Clasificación	Fase	Justificación	Condición o riesgo
MCP Reference Servers (fetch, filesystem, git)	NO NECESARIO	—	Claude Code ya tiene lectura de archivos, Git y consulta web con permisos controlados	fetch expone a contenido externo con instrucciones (inyección de prompt)
GitHub MCP Server	NO NECESARIO	—	El flujo usa Git y la API de GitHub de forma explícita	Requiere token con permisos de escritura
Hugging Face MCP Server	NO NECESARIO	—	No hay búsqueda de modelos prevista en F33–F40	Proyecto con poca adopción (ver datos)
arXiv MCP Server	NO NECESARIO	—	La búsqueda de F30 se hizo con OpenAlex, Crossref y DataCite mediante scripts reproducibles	Mantenedor individual
Zotero MCP	EVITAR	—	Da a un agente acceso a la biblioteca local y su clave de API; mantenedor individual	Acceso amplio con credenciales
Context7 MCP	NO NECESARIO	—	Envía consultas a un servicio externo; la documentación oficial de cada biblioteca basta	Envío de contexto a terceros

4. Datos verificados por herramienta

Consulta del 2026-09-30 (cada herramienta registra su fecha en datos/herramientas.json).

Herramienta	Repositorio	Licencia (GitHub)	Última actividad	Estrellas	Archivado	Versión	Avisos OSV históricos	Avisos en última versión	Clasificación
scikit-learn	scikit-learn/scikit-learn	BSD-3-Clause	2026-09-30	67435	no	1.9.1	6	0	RECOMENDADO
XGBoost	dmlc/xgboost	Apache-2.0	2026-09-30	28809	no	3.4.1	0	0	NO NECESARIO

Herramienta	Repositorio	Licencia (GitHub)	Última actividad	Estrellas	Archivado	Versión	Avisos OSV históricos	Avisos en última versión	Clasificación
LightGBM	lightgbm-org/LightGBM (transferido)	MIT	2026-09-29	18824	no	4.7.0	2	0	NO NECESARIO
CatBoost	catboost/catboost	Apache-2.0	2026-09-30	9128	no	1.2.10	0	0	NO NECESARIO
InterpretML (EBM)	interpretml/interpret	MIT	2026-09-28	6949	no	0.7.8	0	0	EVALUAR EN SANDBOX
SHAP	shap/shap	MIT	2026-09-30	25787	no	0.52.0	0	0	EVALUAR EN SANDBOX
LIME	marcotcr/lime	BSD-2-Clause	2024-07-25	12163	no	0.2.0.1	0	0	EVITAR
Fairlearn	fairlearn/fairlearn	MIT	2026-09-30	2289	no	0.14.0	0	0	RECOMENDADO
AIF360	Trusted-AI/AIF360	Apache-2.0	2026-06-15	2872	no	0.6.1	0	0	EVALUAR EN SANDBOX
MLflow	mlflow/mlflow	Apache-2.0	2026-10-01	28205	no	3.16.1	162	0	NO NECESARIO
DVC	treeverse/dvc (transferido)	Apache-2.0	2026-09-28	15892	no	3.67.1	0	0	NO NECESARIO
Evidently	evidentlyai/evidently	Apache-2.0	2026-09-29	7951	no	0.7.23	0	0	NO NECESARIO
Pandera	unionai-oss/pandera	MIT	2026-09-26	4471	no	0.33.1	0	0	EVALUAR EN SANDBOX
Great Expectations	fivetran/great_expectations (transferido)	Apache-2.0	2026-09-30	11851	no	1.23.2	0	0	NO NECESARIO
spaCy	explosion/spaCy	MIT	2026-09-30	33931	no	3.8.16	0	0	EVALUAR EN SANDBOX
sentence-transformers	huggingface/sentence-transformers (transferido)	Apache-2.0	2026-09-24	19138	no	6.1.0	1	0	EVALUAR EN SANDBOX
Hugging Face Transformers	huggingface/transformers	Apache-2.0	2026-10-01	166874	no	5.18.0	55	0	NO NECESARIO
Microsoft Presidio	data-privacy-stack/presidio (transferido)	MIT	2026-09-29	11119	no	2.2.364	0	0	EVALUAR EN SANDBOX
pgvector	pgvector/pgvector	NOASSERTION	2026-09-30	23202	no	—	—	—	NO NECESARIO
FAISS	facebookresearch/faiss	MIT	2026-09-29	41003	no	1.15.1	0	0	NO NECESARIO
Qdrant	qdrant/qdrant	Apache-2.0	2026-09-30	34892	no	1.19.1	2	0	NO NECESARIO
Whisper (OpenAI)	openai/whisper	MIT	2026-08-31	109815	no	20250625	0	0	EVALUAR EN SANDBOX
faster-whisper	SYSTRAN/faster-whisper	MIT	2026-09-30	25653	no	1.2.1	0	0	EVALUAR EN SANDBOX

Herramienta	Repositorio	Licencia (GitHub)	Última actividad	Estrellas	Archivado	Versión	Avisos OSV históricos	Avisos en última versión	Clasificación
whisper.cpp	ggml-org/whisper.cpp	MIT	2026-09-28	54050	no	—	—	—	EVALUAR EN SANDBOX
Vosk	alphacep/vosk-api	Apache-2.0	2026-08-09	15158	no	0.3.45	0	0	NO NECESARIO
pyannote.audio	pyannote/pyannote-audio	MIT	2026-09-24	10606	no	4.0.7	0	0	EVITAR
FFmpeg	FFmpeg/FFmpeg	NOASSERTION	2026-10-01	64673	no	—	—	—	EVALUAR EN SANDBOX
Apache Tika	apache/tika	Apache-2.0	2026-09-30	4082	no	—	13	—	NO NECESARIO
PyMuPDF	pymupdf/PyMuPDF	AGPL-3.0	2026-09-30	10812	no	1.28.2	2	0	EVITAR
pypdf	py-pdf/pypdf	NOASSERTION	2026-09-30	10241	no	6.19.0	85	0	EVALUAR EN SANDBOX
pdfplumber	jsvine/pdfplumber	MIT	2026-08-06	10786	no	0.11.10	0	0	EVALUAR EN SANDBOX
Docling	docling-project/docling	MIT	2026-09-30	68237	no	2.131.0	16	0	NO NECESARIO
Unstructured	Unstructured-IO/unstructured	Apache-2.0	2026-09-30	15520	no	0.27.10	6	0	NO NECESARIO
python-docx	python-openxml/python-docx	MIT	2026-08-01	5731	no	1.2.0	2	0	EVALUAR EN SANDBOX
Tesseract OCR	tesseract-ocr/tesseract	Apache-2.0	2026-09-28	76776	no	—	—	—	NO NECESARIO
JupyterLab	jupyterlab/jupyterlab	BSD-3-Clause	2026-09-30	15328	no	4.6.4	26	0	NO NECESARIO
nbstripout	kynan/nbstripout	NOASSERTION	2026-04-11	1484	no	0.9.1	0	0	RECOMENDADO
pip-audit	pypa/pip-audit	Apache-2.0	2026-09-26	1375	no	2.10.1	0	0	RECOMENDADO
OSV-Scanner	google/osv-scanner	Apache-2.0	2026-10-01	11126	no	—	—	—	RECOMENDADO
Mermaid	mermaid-js/mermaid	MIT	2026-09-30	90493	no	12.0.0	16	0	NO NECESARIO
Ollama	ollama/ollama	MIT	2026-09-30	181981	no	—	—	—	EVALUAR EN SANDBOX
Zotero	zotero/zotero	NOASSERTION	2026-09-30	15447	no	—	—	—	RECOMENDADO
Better BibTeX for Zotero	retorque/zotero-better-bibtex	MIT	2026-09-30	7178	no	—	—	—	NO NECESARIO
MCP Reference Servers (fetch, filesystem, git)	modelcont/extprotocol/servers	NOASSERTION	2026-10-01	90835	no	—	—	—	NO NECESARIO
GitHub MCP Server	github/github-mcp-server	MIT	2026-09-30	33308	no	—	—	—	NO NECESARIO
Hugging Face MCP Server	huggingface/hf-mcp-server	MIT	2026-09-29	301	no	—	—	—	NO NECESARIO
arXiv MCP Server	blazickjp/arxiv-mcp-server	Apache-2.0	2026-09-30	3183	no	0.7.3	0	0	NO NECESARIO
Zotero MCP	54yyu/zotero-mcp	MIT	2026-09-30	5205	no	0.3.1	0	0	EVITAR

Herramienta	Repositorio	Licencia (GitHub)	Última actividad	Estrellas	Archivado	Versión	Avisos OSV históricos	Avisos en última versión	Clasificación
Context7 MCP	upstash/context7	MIT	2026-09-30	62568	no	4.1.1	0	0	NO NECESARIO

«—» en avisos: la herramienta no se publica en un ecosistema que OSV indexe con ese nombre (p. ej., binarios o extensiones); no significa cero avisos. «NOASSERTION» o «Other»: GitHub no reconoce la licencia automáticamente; se revisa el archivo de licencia antes de adoptar.

5. Skills, plugins y conectores del entorno local

Inventario de solo lectura del 30/09/2026. Las skills del proyecto son Markdown sin scripts, hooks ni acceso de red; las tres externas tienen PROVENANCE.md con origen, commit fijado, licencia y auditoría. No hay hooks configurados en .claude/settings.local.json ni en la configuración de usuario.

Skill o plugin	Origen	Contenido	Clasificación	Uso o motivo
project-guardian	Proyecto (propia)	Solo Markdown	RECOMENDADO	Obligatoria antes de cualquier cambio
academic-traceability	Proyecto (propia)	Solo Markdown	RECOMENDADO	Trazabilidad de F33–F40
laravel-saas-quality	Proyecto (propia)	Solo Markdown	RECOMENDADO	F38 (integración Laravel)
ml-risk-service	Proyecto (propia)	Solo Markdown	RECOMENDADO	Marco de RF-29; F33 debe ampliarla o crear una nueva skill para el motor, sin mezclar ambos
powerdesigner-uml	Proyecto (propia)	Solo Markdown	RECOMENDADO	Diagramas TO-BE del motor
recruitment-3d-experience	Proyecto (propia)	Solo Markdown	NO NECESARIO	Sin relación con el motor
frontend-design	Externa (Anthropic), con PROVENANCE.md	Solo Markdown, Apache 2.0	RECOMENDADO	F40 (panel)
animate	Externa (comunitaria), con PROVENANCE.md	Solo Markdown, MIT	NO NECESARIO	El panel de decisión no se anima
reviewing-a11y	Externa (comunitaria), con PROVENANCE.md	Markdown; allowed-tools incluye WebFetch y herramientas de un MCP de Playwright que no está instalado	RECOMENDADO	F40; vigilar que no se instale el MCP de Playwright sin autorización
docx, pdf, pptx, xlsx (sincronizadas)	Anthropic (claude.ai)	Markdown y scripts Python locales	RECOMENDADO	Entregables académicos; scripts revisables
engineering:* (plugin oficial)	Marketplace claude-plugins-official	Markdown; conectores MCP sin autenticar	NO NECESARIO	Los conectores (Slack, Jira, Datadog...) no tienen uso en el proyecto

Conectores MCP visibles en la sesión: Claude Docs, Canva y Google Drive (claude.ai), y los del plugin engineering (Asana, Atlassian, Datadog, GitHub, Linear, Notion, PagerDuty, Slack) sin autenticar. Ninguno es necesario para F33–F40 y **ninguno debe recibir datos de postulantes**, ni siquiera ficticios que imiten datos reales. Clasificación: NO NECESARIO.

Hallazgos de la revisión de skills:

- Ninguna skill del proyecto contiene scripts, binarios, hooks ni instrucciones de leer .env, enviar datos o saltar confirmaciones.
- reviewing-a11y declara en allowed-tools WebFetch y herramientas de un MCP de Playwright que no está instalado. No es malicioso, pero instalar ese MCP ampliaría lo que la skill puede hacer sin confirmación: requiere autorización del equipo.
- Las skills sincronizadas docx, pdf, pptx y xlsx incluyen scripts Python que se ejecutan en local; su origen es Anthropic. Se revisan antes de ejecutarlos sobre documentos con datos.
- No se detectaron skills sospechosas. La sección siguiente fija los criterios para las que se propongan después.

6. Señales de alerta de cadena de suministro

Toda skill, plugin, servidor MCP o paquete que se proponga en F33–F40 se revisa con estas señales antes de instalarse. Una sola señal grave basta para EVITAR.

Señal	Cómo se comprueba
Nombre parecido a un paquete conocido (typosquatting) o repositorio redirigido	Comparar con el repositorio oficial; redirigido en los datos
Mantenedor individual, poca adopción o repositorio muy reciente	Propietario, estrellas y fecha de creación
Scripts de instalación, hooks o binarios dentro de una skill	Revisar todos los archivos, no solo SKILL.md
allowed-tools amplio (Bash, WebFetch, escritura) o instrucciones de saltar confirmaciones	Leer la cabecera de la skill
Instrucciones de ignorar reglas, enviar datos, leer .env o credenciales	Búsqueda de texto en toda la skill
Servidor MCP remoto que recibe código o datos del repositorio	Documentación del servidor; tráfico
Descarga de pesos de modelos en formatos ejecutables (pickle)	Exigir safetensors y revisión fijada
Licencia que exige revisión de compatibilidad en un SaaS (AGPL) o cambio reciente de licencia	Licencia en GitHub y en el registro
Avisos de seguridad abiertos en la versión que se instalaría	OSV para la versión exacta
Repositorio archivado o sin actividad	archivado y ultima_actividad en los datos

Riesgos concretos encontrados en esta evaluación:

- **Licencia:** PyMuPDF es AGPL-3.0: requiere revisión de compatibilidad AGPL o licencia comercial (EVITAR por prudencia). FFmpeg es LGPL con componentes GPL opcionales.
- **Superficie de ataque:** los lectores de PDF (pypdf, PyMuPDF) y las plataformas con servidor (MLflow, JupyterLab) acumulan muchos avisos históricos: si se usan, en proceso aislado con límites.
- **Pesos de modelos:** Transformers, sentence-transformers y Whisper descargan pesos de terceros; solo formatos sin ejecución (safetensors) y revisiones fijadas.
- **Datos biométricos:** la diarización con embeddings de voz (pyannote.audio) trata datos biométricos (EVITAR).
- **Mantenimiento:** LIME sin actividad desde julio de 2024 (EVITAR).
- **Cambio de propietario:** GitHub redirige 5 repositorios a otro propietario: LightGBM (microsoft/LightGBM → lightgbm-org/LightGBM), DVC (iterative/dvc → treeverse/dvc), Great Expectations (great-expectations/great_expectations → fivetran/great_expectations), sentence-transformers (UKPLab/sentence-transformers → huggingface/sentence-transformers), Microsoft Presidio (microsoft/presidio → data-privacy-stack/presidio). Puede ser un cambio legítimo (reorganización o adquisición), pero es justo la señal que explota un ataque de cadena de

suministro: antes de adoptar cualquiera de ellos se comprueba en el registro del paquete quién publica las versiones y desde qué repositorio.

- **Credenciales y envío a terceros:** Zotero MCP (clave de API y acceso a la biblioteca) y Context7 (consultas a un servicio externo).
- **Inyección de prompt:** cualquier MCP que traiga contenido externo (fetch, arXiv, Hugging Face) puede incluir instrucciones; ese contenido es dato, nunca orden.

7. Reglas de adopción para F33–F40

- Regla G0 (F30_Recomendaciones_F33_F40.md): en F35–F40 ninguna herramienta se instala sin G0 aprobado; en F33–F34, solo en sandbox, con datos sintéticos y autorización explícita.
- Toda dependencia nueva de producción requiere autorización explícita del equipo (skill project-guardian).
- Versión fijada, licencia revisada, pip-audit u OSV-Scanner sin avisos en esa versión.
- Primero en un entorno aislado con datos ficticios; sin red de producción ni credenciales reales.
- Ninguna herramienta de terceros recibe datos de postulantes reales.

F30 — Recomendaciones y decisiones para F33–F40

*Fase F30, versión 1 (30/09/2026), auditada e integrada. F30 investiga y propone; F33–F40 implementarán después, si el equipo lo autoriza. Las decisiones de este documento son **propuestas de ingeniería** respaldadas por la matriz de evidencia. Ninguna está aprobada hasta que el equipo la registre.*

1. Conclusión

La evidencia reunida respalda un motor que **estructura, documenta y verifica la evidencia** con la que los evaluadores humanos califican:

- rúbricas BARS y entrevista estructurada [S13, S14, S15, S19];
- procedencia de cada nivel asignado;
- acuerdo entre evaluadores [S20, S21];
- explicaciones verificables [S55, S59].

No respalda scoring, sugerencia de niveles ni recomendación de candidatos **para este caso, con los datos, el gobierno y las garantías actuales**:

- seguimiento acrítico de IA sesgada [S84];
- bajo rendimiento de los equipos humano-IA en decisiones [S60];
- explicaciones que aumentan la aceptación ciega [S58];
- sesgos de embeddings y LLM [S11, S83, S87];
- datos pequeños [S04] y validez predictiva baja en docentes [S22].

La evidencia a favor de la calificación automática [S89] se mantiene como **evidencia en tensión**: muestra implementaciones a escala, en organizaciones con grandes volúmenes de calificaciones humanas que el caso no tiene. No se descarta para el futuro; se descarta para este caso en las condiciones actuales.

Regla central de todo el diseño: RECOMENDACIÓN DEL SISTEMA ≠ DECISIÓN FINAL DE CONTRATACIÓN. En este motor, una «recomendación del sistema» se refiere al **proceso** y a la **evidencia**, por ejemplo «falta evidencia para el criterio X» o «los evaluadores discrepan en Y». Nunca se refiere a la persona. La decisión final es del Aprobador / Dirección, con confirmación explícita y justificación (RF-23, ADR-002).

2. Puerta G0

Regla G0. F33 formula y aprueba ADR-005, que constituye la puerta G0. F34 puede avanzar en paralelo **solo con datos sintéticos** y sin scoring ni recomendación de personas. F35–F40 **no comienzan sin G0 aprobado**.

G0 queda aprobada cuando se cumplen todas estas condiciones:

Condición G0	Evidencia de cumplimiento	Motivo
G0-1 Nuevo ADR (ADR-005) que defina qué puede hacer el motor y que ratifique o enmiende ADR-001 de forma explícita	ADR aprobado por el equipo	La visión de «recomendar» choca con ADR-001, el contrato 4 y OUT-04/05/11 (gobernanza §4.2)
G0-2 Revisión del contrato 4 de CLAUDE.md, solo si el ADR lo enmienda	Cambio registrado y autorizado	El contrato prohíbe que el ML evalúe personas
G0-3 Evaluación de impacto previa (riesgo alto)	Documento con revisión jurídica y contraste de los artículos citados con la publicación oficial	DS 115-2025-PCM, arts. 24.1 e) (corroborado) y 30 [O13]

Condición G0	Evidencia de cumplimiento	Motivo
G0-4 Análisis de datos personales	Base legal, finalidad, minimización y retención documentadas	Ley 29733 [O15] y DS 016-2024-JUS [O09]
G0-5 Requisitos nuevos como candidatos (desde RF-32), sin tocar RF-01 a RF-27	Entradas en docs/v1.1/scope-preliminary.md o su sucesor	Contrato 1; la decisión 11 no promueve por implementar
G0-6 Autorización explícita de dependencias nuevas	Lista aprobada con versión, licencia y auditoría OSV	Skill project-guardian; herramientas

3. Tabla de decisiones

ID	DECISIÓN	EVIDENCIA	ALTERNATIVAS	RIESGO	RECOMENDACIÓN	FASE
D-01	Puerta de gobierno G0 antes de implementar	[O13, O09, S84, S60]; ADR-001	Implementar y regularizar después	Incumplimiento normativo; contradicción con contratos vigentes	Adoptar la regla G0: F33 aprueba ADR-005; F34 solo con datos sintéticos; F35–F40 no comienzan sin G0 aprobado	F33
D-02	Alcance del motor: asistencia sobre proceso y evidencia, sin puntuar ni recomendar personas	[S58, S60, S84, S11, S83, S87, S22]; tensión con [S89]	Sugerir nivel por criterio; recomendar candidato	Anclaje y discriminación; incumplir ADR-001	Solo proceso y evidencia. Sugerir niveles queda fuera hasta que haya validación local con datos suficientes (hoy no existen)	F33
D-03	Criterios desde el análisis del puesto, con competencias versionadas	[S17, S18, S24, O14]	Criterios libres por vacante (hoy)	Criterios irrelevantes o sesgados	Catálogo de competencias con <code>criteria_version</code> ; para docentes, derivado del MBDD y validado por el colegio	F33
D-04	Entrevista estructurada con rúbricas BARS	[S13, S14, S15, S16, S19]	Entrevista libre; puntaje sin anclas	Baja fiabilidad y validez	Adoptar: mismas preguntas por vacante, BARS por criterio, <code>rubric_version</code>	F33
D-05	Cadena de procedencia: pregunta → respuesta → evidencia → criterio → nivel → justificación → confianza	[S55, S70, S71, S73]	Puntaje sin evidencia (hoy)	Decisiones no explicables ni auditables	Adoptar como modelo de datos del motor	F33, F38
D-06	Verificaciones del proceso con reglas deterministas	[S51, S62]	ML para detectar inconsistencias	Opacidad innecesaria	Reglas: evidencia faltante, nivel sin justificación, discrepancia entre evaluadores, pregunta omitida, rúbrica cambiada	F35
D-07	Acuerdo entre evaluadores con ICC	[S20, S21]	Un solo evaluador	Calificación no fiable	Doble calificación en los criterios de mayor peso; ICC con forma e intervalo	F35, F39
D-08	Mantener el ranking RF-21 (suma ponderada)	[S39, S40, S51]; A-24, A-26	TOPSIS u otro MCDM; ranking por ML	Opacidad; pérdida de trazabilidad	Mantener la suma ponderada; AHP opcional solo para justificar pesos; desglose por criterio en F40	F33, F40

ID	DECISIÓN	EVIDENCIA	ALTERNATIVAS	RIESGO	RECOMENDACIÓN	FASE
D-09	Dataset sintético primero, con linaje y dataset card	[S72, S74, S79, S33]	Datos reales anonimizados	PII; fuga de información	Sintético con semilla, SHA-256, card y particiones por convocatoria	F34
D-10	No recolectar atributos sensibles	[O09, S44, S46]; contrato 7	Recolectar para auditar equidad	Riesgo legal; muestras pequeñas sin poder estadístico	No recolectar ; simular atributos en datos sintéticos si F37 prueba métodos	F34, F37
D-11	Etiquetas: nunca usar «contratado» como idoneidad	[S42, S48, S01]	Aprender de decisiones históricas	Sesgo por etiqueta proxy	Prohibido en la dataset card y en las pruebas	F34, F36
D-12	Pipeline de evidencia: CV digital con extracción de texto; sin OCR por defecto	[S37]	Docling, Tika u OCR	Complejidad y dependencias	pypdf/pdfplumber/python-docx en sandbox ; OCR solo si aparecen escaneados	F35
D-13	Localizar fragmentos de evidencia con similitud semántica	[S31, S11]	No usar NLP; puntuar por similitud	Sesgo por nombre y género si se usa como puntaje	Evaluar en sandbox solo como localizador, mostrado después de la calificación humana, sin nombre en la entrada	F35
D-14	Audio: por defecto, no grabar	[S13, S15, S06]	Grabar y transcribir siempre	Datos personales; errores de STT	No grabar ; solo si F33 demuestra necesidad y pasa G0	F33
D-15	Si se graba: solo audio, STT local, revisión humana, sin biometría	[S38, S81, S10, S88, S85, O13]	Vídeo; STT en la nube; diarización por voz	Alucinaciones, sesgo por variedad de habla, biometría	Whisper local en sandbox , revisión contra el audio, WER por grupo, segmentación manual	F35
D-16	Prohibir la inferencia de emociones, personalidad, prosodia y rasgos faciales	[S07, S08, S09, S85, O01, O13]	Análisis multimodal	Evidencia insuficiente, mixta y no generalizable para este uso; riesgo alto o prohibición	Prohibido en ADR-005 y en pruebas de regresión	F33
D-17	LLM fuera de toda evaluación de personas	[S34, S36, S83, S87]	LLM como juez o resumidor	Alucinación y sesgo	Prohibido para evaluar; Ollama en sandbox solo para tareas sin personas	F33
D-18	ML solo sobre el proceso (como RF-29)	[S51, S04]; ADR-001, ADR-004	Modelo de idoneidad	Contradice contratos y evidencia	Si F36 necesita un modelo, interpretable (regresión logística o EBM) y sobre el proceso	F36
D-19	Calibración y métricas apropiadas si hay probabilidades	[S64, S66, S67, S68]	Exactitud y ROC	Confianza engañosa	PR-AUC, Brier y curva de calibración; sin «confianza» sin calibrar	F36, F39
D-20	Explicaciones contrastivas y verificables para humanos; SHAP solo interno	[S51, S52, S55, S56, S58, S59]	SHAP o LIME para usuarios	Aceptación acrítica	Justificación BARS contrastiva con enlace a la evidencia	F37, F40
D-21	Equidad del procedimiento primero; revisión estadística agregada con base legal	[S44, S45, S46, O11, S14, S19]	Una métrica de equidad por vacante	Conclusiones espurias con n pequeño	Controles de procedimiento + revisión agregada cuando sea legal y estadísticamente posible	F37, F39

ID	DECISIÓN	EVIDENCIA	ALTERNATIVAS	RIESGO	RECOMENDACION	FASE
D-22	Diseño contra el sesgo de automatización	[S84, S60, S63, S57, S61]	Mostrar la sugerencia junto a la calificación	Anclaje	El evaluador califica antes de ver ayudas; se registra <code>suggestion_seen_before_scoring</code> y el desacuerdo	F38, F40
D-23	Integración Laravel ↔ ML asíncrona, idempotente y con fallback	[S76, S77, S78]; patrón de RF-29	Llamada síncrona en la página	Caídas; duplicados	Cola Redis, Idempotency-Key, timeouts, reintentos, circuit breaker	F38
D-24	Versionado de cada ejecución	[S71, S72, S79]	Solo la versión del modelo	Resultados no reproducibles	<code>model_version</code> , <code>rubric_version</code> , <code>criteria_version</code> , <code>input_snapshot_hash</code>	F38
D-25	Auditoría sin PII ni entradas completas	[O09, S73]; contrato 6	Guardar la entrada completa	Exposición de datos	Registro de <code>analysis_run</code> sin texto de entrada, con hash; AuditLogger de solo inserción	F38
D-26	Multiempresa en todo el motor	Contrato 5	Modelos compartidos entre organizaciones	Filtración entre organizaciones	<code>organization_id</code> permanece en Laravel (datos, Policies, auditoría); no se envía al servicio ML stateless salvo justificación explícita: viajan identificadores técnicos pseudónimos mínimos; ningún modelo mezcla organizaciones; pruebas cross-tenant	F38
D-27	Evaluación con métricas por tarea, no por persona	[S20, S10, S29, S68, S69]	Una exactitud global	Métricas sin verdad de terreno	Tabla de métricas de modelos §6; NDCG solo con relevancia válida	F39
D-28	Auditoría interna antes de cualquier piloto	[S73, S76]	Piloto directo	Daños no detectados	Auditoría interna con model card, dataset card y las 28 pruebas como lista	F39
D-29	Panel: desglose del ranking, evidencia y alertas de proceso; sin «recomendado»	[S62, S55]; RF-22, RF-23	Insignia de «mejor candidato»	Anclaje	El panel muestra criterios, evidencia, acuerdo y faltantes ; la decisión sigue en RF-23	F40
D-30	Herramientas: adopción controlada	Herramientas	Instalar a demanda	Cadena de suministro y licencias	Solo RECOMENDADO o EVALUAR EN SANDBOX tras G0-6; EVITAR PyMuPDF, LIME, pyannote.audio y Zotero MCP	F33–F40

4. Plan por fase

Fase	Objetivo	Entrada	Salida mínima	Decisiones
F33 Diseño funcional	Definir qué hace y qué no hace el motor; formular y aprobar G0	F30 auditada	ADR-005 aprobado (G0); requisitos candidatos (RF-32+); modelo de competencias, rúbricas y cadena de procedencia; casos de uso TO-BE; evaluación de impacto iniciada	D-01–D-05, D-08, D-14, D-16, D-17
F34 Dataset y gobernanza	Datos sintéticos gobernados	F30 auditada; en paralelo a F33, solo con datos sintéticos y sin scoring ni recomendación de personas	Generador con semilla; dataset card; linaje SHA-256; particiones; registro; regla «sin atributos sensibles»	D-09–D-11
F35 Pipeline de evidencia	Capturar y verificar la evidencia	G0 aprobado	Reglas de proceso; doble calificación con ICC; extracción de texto de CV en sandbox; localizador de fragmentos y STT solo si G0 los aprueba	D-06, D-07, D-12, D-13, D-15
F36 ML baseline	Solo si se justifica, un modelo interpretable sobre el proceso	F34 y G0 aprobado	Model card; métricas calibradas; comparación con reglas; decisión de usarlo o no	D-18, D-19
F37 XAI y equidad	Explicaciones y controles de equidad	G0 aprobado; F35 (y F36 si existe)	Explicaciones BARS contrastivas; controles de procedimiento; método de revisión agregada probado con datos sintéticos	D-20, D-21
F38 Integración Laravel ↔ ML	Integrar sin romper contratos	G0 aprobado; F35–F37	Cola, idempotencia, fallback, versionado, auditoría, multiempresa, pruebas cross-tenant, regresión completa	D-22–D-26
F39 Evaluación	Medir con honestidad	G0 aprobado; F38	Métricas por tarea; auditoría interna; informe de límites	D-27, D-28
F40 Panel	Mostrar evidencia, no veredictos	F38–F39	Desglose del ranking, evidencia, acuerdo y faltantes; accesibilidad; sin insignias de candidato	D-29

5. Decisiones pendientes del equipo

- ¿Se ratifica ADR-001 tal como está (recomendación de F30) o se enmienda? Si se enmienda, ¿con qué límites exactos?
- ¿El motor incluirá grabación de audio o solo notas del evaluador?
- ¿Qué vacantes cubre: solo docentes o también personal administrativo?
- ¿Quién valida el catálogo de competencias en el colegio y con qué periodicidad?
- ¿El Colegio Andino es una institución pública o privada? Cambia las obligaciones del DS 115-2025-PCM (arts. 28 y 31).
- ¿Quién firma la evaluación de impacto y quién hace la revisión jurídica?

6. Qué no se debe hacer en F33–F40 (resumen)

- Puntuar, sugerir niveles, ordenar por ML o recomendar candidatos.
- Inferir emociones, personalidad, «ajuste cultural», rasgos faciales, prosodia o acento.
- Usar LLM para evaluar, resumir o comparar candidatos.
- Entrenar con decisiones de contratación pasadas como etiqueta.

- Recolectar atributos sensibles sin el análisis de necesidad, consentimiento, base legal, finalidad y seguridad.
- Usar datos reales o PII.
- Instalar herramientas sin autorización.
- Modificar RF-01 a RF-27, la decisión humana de RF-23, la multiempresa o la auditoría de solo inserción.

F30 — Matriz de evidencia científica

Documento generado por `docs/academico/tools/f30/f30.py` desde `fuentes.py`, `m_matriz.py` y los datos verificados de `datos/`. No se edita a mano.

Cómo leer la matriz. Cada ficha separa cuatro tipos de afirmación:

- **Evidencia científica:** «Resultados relevantes», tomado del resumen publicado del trabajo. Si el trabajo no tiene resumen disponible, se indica y no se dan cifras.
- **Recomendación de los autores:** cuando el resultado es una propuesta o guía, se escribe como tal.
- **Inferencia del equipo:** «Aplicabilidad al caso».
- **Decisión de ingeniería:** «Decisión que respalda». Las decisiones finales están en `F30_Recomendaciones_F33_F40.md`.

Niveles de evidencia (sobre el aporte de la fuente a la decisión, no sobre su prestigio):

Nivel	Significado
FUERTE	Metaanálisis, revisión amplia o resultado formal o experimental robusto y replicado
MODERADA	Estudio empírico sólido, revisión sistemática o guía ampliamente adoptada, con límites de contexto
LIMITADA	Estudio único, caso de aplicación o contexto muy distinto del caso
CONFLICTIVA	Resultados que otras fuentes de la matriz contradicen o matizan
INSUFICIENTE	No hay datos suficientes para extraer resultados (p. ej., sin resumen disponible)

1. Estrategia de búsqueda

- **Base de búsqueda:** OpenAlex (API pública, 2026-09-30), elegida por indexar Crossref, PubMed, arXiv y repositorios, y por devolver resúmenes; Crossref respondió con límite de tasa (HTTP 429) en búsquedas masivas, por eso se usó solo para verificar.
- **Verificación:** Crossref para cada DOI (metadatos y avisos de retractación, corrección o retirada), DataCite para DOI de arXiv y SSRN, y respuesta HTTP con palabra clave esperada en el título para normas y páginas oficiales (`verificar.py`).
- **Criterio de cribado:** orden por relevancia; 25 primeros resultados de cada consulta como conjunto cribado.
- **Inclusión:** trabajo revisado por pares, metaanálisis, revisión sistemática, norma oficial o trabajo fundacional muy citado; relación directa con un tema A–T; resumen o texto que permita extraer los campos.
- **Exclusión:** sin DOI ni URL verificable, retractado, duplicado, opinión sin método, o tema solo tangencial (p. ej., IA en reclutamiento de pacientes clínicos, que aparece mucho al buscar «recruitment»).
- **Bola de nieve:** trabajos citados por los seleccionados y trabajos fundacionales que la búsqueda por relevancia no devuelve en los 25 primeros (p. ej., metaanálisis de validez de la entrevista).
- **Búsqueda complementaria:** consultas dirigidas a 2021–2025 para cubrir huecos (alucinación de Whisper, sesgo de LLM en contratación, calificación automática de respuestas abiertas, entrevistas multimodales).

Consultas

Tema	Nombre	Consulta	Resultados	Cribados	Trabajos seleccionados
A	AI in recruitment / algorithmic hiring	algorithmic hiring artificial intelligence recruitment	20 662	25	4
B	Candidate-job fit	person-job fit candidate job matching	40 796	25	1
C	Competency-based assessment	competency modeling personnel selection	218 279	25	1
D	Structured interviews	structured employment interview validity	403 463	25	2
E	CV / resume NLP	resume parsing natural language processing	11 251	25	2
F	Semantic matching	semantic matching job postings resumes embeddings	717	25	1
G	Information extraction	skill extraction job postings information extraction	8 129	25	2
H	Ranking / recommendation	job recommender system e-recruitment survey	261 296	25	2
I	Multicriteria decision support	multi-criteria decision making personnel selection	193 791	25	1
J	Explainable AI	explainable artificial intelligence interpretability survey	390 115	25	1
K	Fairness / algorithmic bias	algorithmic fairness bias machine learning survey	161 027	25	2
L	Responsible AI	responsible artificial intelligence governance accountability	96 767	25	1
M	Human-in-the-loop	human-AI decision making automation bias reliance	48 672	25	3
N	Uncertainty / calibration	probability calibration classifiers uncertainty	75 737	25	3
O	Model monitoring / drift	concept drift dataset shift monitoring machine learning	32 607	25	3
P	Auditability	algorithmic auditing accountability machine learning	64 390	25	2
Q	Recruitment analytics	human resource analytics people analytics	947 321	25	1
R	Document understanding	document understanding layout analysis PDF parsing	7 801	25	1
S	Speech-to-text for interviews	automatic speech recognition robust weak supervision	46 793	25	1

Tema	Nombre	Consulta	Resultados	Cribados	Trabajos seleccionados
T	Interview transcript evaluation	automated interview assessment transcripts language	28 515	25	1

Además, O03 (L) y O04 (A) son documentos oficiales que aparecieron en el cribado; se cuentan entre las normas y no entre los trabajos.

Flujo de selección

Resultados devueltos por las 20 consultas 3 058 129
 Cribados (25 primeros por consulta) 500 registros, 450 DOI únicos
 seleccionados desde el cribado 35
 excluidos del cribado resto (fuera de tema, sin método, duplicados, 1 retractado)
 Búsqueda complementaria 2021-2025 9
 Bola de nieve y trabajos fundacionales 45
 Trabajos científicos en la matriz (S01-S89) 89
 Normas y documentos oficiales (O01-O16) 16
 Fuentes secundarias de contraste (X01-X02) 2
 Total verificado 107 de 107

El cribado fue por título, tipo y revista; la extracción de campos se hizo sobre el resumen publicado (OpenAlex). Los conteos «Resultados» son los que devuelve OpenAlex para la consulta y no equivalen a trabajos pertinentes: solo indican el tamaño del área.

2. Resumen de la matriz

Distribución por nivel: FUERTE 19, MODERADA 62, LIMITADA 4, CONFLICTIVA 3, INSUFICIENTE 1.

ID	Referencia	Tema	Tipo	Revisión por pares	Nivel
S01	Raghavan et al. (2020)	A	Artículo de conferencia	Sí	MODERADA
S02	Köchling y Wehner (2020)	A	Artículo de revista	Sí	MODERADA
S03	Hunkenschroer y Luetge (2022)	A	Artículo de revista	Sí	MODERADA
S04	Tambe et al. (2019)	A	Artículo de revista	Sí	MODERADA
S05	Chen (2023)	A	Artículo de revista	Sí	LIMITADA
S06	Langer et al. (2019)	A	Artículo de revista	Sí	MODERADA
S07	Hickman et al. (2022)	T	Artículo de revista	Sí	MODERADA
S08	Barrett et al. (2019)	T	Artículo de revista	Sí	FUERTE
S09	Stark y Hoey (2021)	T	Artículo de conferencia	Sí	MODERADA
S10	Koenecke et al. (2020)	S	Artículo de revista	Sí	MODERADA
S11	Wilson y Caliskan (2024)	E	Artículo de revista	Sí	MODERADA
S12	Schmidt y Hunter (1998)	D	Artículo de revista	Sí	CONFLICTIVA
S13	Sackett et al. (2022)	D	Artículo de revista	Sí	FUERTE
S14	McDaniel et al. (1994)	D	Artículo de revista	Sí	FUERTE
S15	Campion et al. (1997)	D	Artículo de revista	Sí	MODERADA
S16	Levashina et al. (2013)	D	Artículo de revista	Sí	FUERTE
S17	Campion et al. (2011)	C	Artículo de revista	Sí	MODERADA
S18	Sanchez y Levine (2012)	C	Artículo de revista	Sí	MODERADA
S19	Smith y Kendall (1963)	C	Artículo de revista	Sí	MODERADA
S20	Shrout y Fleiss (1979)	C	Artículo de revista	Sí	FUERTE

ID	Referencia	Tema	Tipo	Revisión por pares	Nivel
S21	Koo y Li (2016)	C	Artículo de revista	Sí	FUERTE
S22	Klassen y Kim (2019)	C	Artículo de revista	Sí	FUERTE
S23	Woods et al. (2019)	C	Artículo de revista	Sí	MODERADA
S24	Huffcutt et al. (2001)	D	Artículo de revista	Sí	MODERADA
S25	Zhu et al. (2018)	B	Artículo de revista	Sí	LIMITADA
S26	Qin et al. (2018)	B	Artículo de conferencia	Sí	LIMITADA
S27	Freire y de Castro (2020)	H	Artículo de revista	Sí	MODERADA
S28	Mashayekhi et al. (2024)	H	Artículo de revista	Sí	MODERADA
S29	Zhang et al. (2022)	G	Artículo de conferencia	Sí	MODERADA
S30	Khaouja et al. (2021)	G	Artículo de revista	Sí	MODERADA
S31	Reimers y Gurevych (2019)	F	Artículo de conferencia	Sí	FUERTE
S32	Blodgett et al. (2020)	E	Artículo de conferencia	Sí	MODERADA
S33	Bender y Friedman (2018)	E	Artículo de revista	Sí	MODERADA
S34	Ji et al. (2023)	E	Artículo de revista	Sí	FUERTE
S35	Bender et al. (2021)	E	Artículo de conferencia	Sí	MODERADA
S36	Zheng et al. (2023)	T	Preprint (arXiv)	No (preprint); publicado en NeurIPS 2023	MODERADA
S37	Xu et al. (2021)	R	Artículo de conferencia	Sí	MODERADA
S38	Radford et al. (2022)	S	Preprint (arXiv)	No (preprint); publicado en ICML 2023	MODERADA
S39	Saaty (1990)	I	Artículo de revista	Sí	MODERADA
S40	Kelemenis y Askounis (2010)	I	Artículo de revista	Sí	LIMITADA
S41	Mehrabi et al. (2021)	K	Artículo de revista	Sí	MODERADA
S42	Barocas y Selbst (2016)	K	Artículo de revista	Revisión editorial (revista jurídica)	MODERADA
S43	Hardt et al. (2016)	K	Preprint (arXiv)	No (preprint); publicado en NeurIPS 2016	FUERTE
S44	Kleinberg et al. (2017)	K	Artículo de conferencia	Sí	FUERTE
S45	Chouldechova (2017)	K	Artículo de revista	Sí	FUERTE
S46	Friedler et al. (2019)	K	Artículo de conferencia	Sí	MODERADA
S47	Suresh y Guttat (2021)	K	Artículo de conferencia	Sí	MODERADA
S48	Obermeyer et al. (2019)	K	Artículo de revista	Sí	FUERTE
S49	Bellamy et al. (2019)	K	Artículo de revista	Sí	MODERADA
S50	Holstein et al. (2019)	K	Artículo de conferencia	Sí	MODERADA
S51	Rudin (2019)	J	Artículo de revista	Sí	MODERADA
S52	Ribeiro et al. (2016)	J	Artículo de conferencia	Sí	MODERADA
S53	Lundberg y Lee (2017)	J	Preprint (arXiv)	No (preprint); publicado en NeurIPS 2017	MODERADA
S54	Wachter et al. (2017)	J	Documento de trabajo (SSRN)	No (documento de trabajo en SSRN); publicado luego en Harvard Journal of Law & Technology	MODERADA
S55	Miller (2019)	J	Artículo de revista	Sí	MODERADA
S56	Bhatt et al. (2020)	J	Artículo de conferencia	Sí	MODERADA
S57	Green y Chen (2019)	M	Artículo de conferencia	Sí	MODERADA
S58	Bansal et al. (2021)	M	Artículo de conferencia	Sí	MODERADA
S59	Vasconcelos et al. (2023)	M	Artículo de revista	Sí	MODERADA
S60	Vaccaro et al. (2024)	M	Artículo de revista	Sí	FUERTE

ID	Referencia	Tema	Tipo	Revisión por pares	Nivel
S61	Alon-Barkat y Busuioc (2022)	M	Artículo de revista	Sí	CONFLICTIVA
S62	Amershi et al. (2019)	M	Artículo de conferencia	Sí	MODERADA
S63	Parasuraman y Manzey (2010)	M	Artículo de revista	Sí	MODERADA
S64	Niculescu-Mizil y Caruana (2005)	N	Artículo de conferencia	Sí	FUERTE
S65	Guo et al. (2017)	N	Preprint (arXiv)	No (preprint); publicado en ICML 2017	MODERADA
S66	Brier (1950)	N	Artículo de revista	Sí	FUERTE
S67	Silva Filho et al. (2023)	N	Artículo de revista	Sí	MODERADA
S68	Saito y Rehmsmeier (2015)	N	Artículo de revista	Sí	MODERADA
S69	Järvelin y Kekäläinen (2002)	N	Artículo de revista	Sí	FUERTE
S70	Hüllermeier y Waegeman (2021)	N	Artículo de revista	Sí	MODERADA
S71	Mitchell et al. (2019)	P	Artículo de conferencia	Sí	MODERADA
S72	Gebri et al. (2021)	P	Artículo de revista	Sí	MODERADA
S73	Raji et al. (2020)	P	Artículo de conferencia	Sí	MODERADA
S74	Kaufman et al. (2012)	O	Artículo de revista	Sí	FUERTE
S75	Gama et al. (2014)	O	Artículo de revista	Sí	MODERADA
S76	Breck et al. (2017)	O	Artículo de conferencia	Sí	MODERADA
S77	Kreuzberger et al. (2023)	O	Artículo de revista	Sí	MODERADA
S78	Paleyes et al. (2022)	O	Artículo de revista	Sí	MODERADA
S79	Hutchinson et al. (2021)	P	Artículo de conferencia	Sí	MODERADA
S80	Giermindi et al. (2021)	Q	Artículo de revista	Sí	MODERADA
S81	Koenecke et al. (2024)	S	Artículo de conferencia	Sí	MODERADA
S82	Thompson et al. (2023)	T	Artículo de revista	Sí	INSUFICIENTE
S83	Armstrong et al. (2024)	E	Artículo de conferencia	Sí	MODERADA
S84	Wilson et al. (2025)	M	Artículo de revista	Sí	FUERTE
S85	Booth et al. (2021)	T	Artículo de conferencia	Sí	MODERADA
S86	Van Iddekinge et al. (2023)	D	Artículo de revista	Sí	MODERADA
S87	Glazko et al. (2024)	E	Artículo de conferencia	Sí	MODERADA
S88	Bredin (2023)	S	Artículo de conferencia	Sí	MODERADA
S89	Koenig et al. (2023)	C	Artículo de revista	Sí	CONFLICTIVA

3. Fichas de evidencia

S01 — Raghavan et al. (2020)

Campo	Contenido
Referencia	Raghavan, M., Barocas, S., Kleinberg, J. y Levy, K. (2020). Mitigating bias in algorithmic hiring. Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3351095.3372828
Año	2020
Autores	Raghavan, M., Barocas, S., Kleinberg, J. y Levy, K.
Revista o conferencia	Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3351095.3372828
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	A · búsqueda A

Campo	Contenido
Avisos de Crossref	ninguno
Objetivo	Analizar afirmaciones y prácticas de proveedores de evaluaciones algorítmicas de preempleo
Datos o población	Información pública de proveedores comerciales
Técnica	Análisis documental técnico y jurídico
Variables o características	Datos usados, objetivo de predicción, validación, des-sesgo declarado
Métricas	Cualitativo
Resultados relevantes (evidencia)	Las decisiones sobre datos y objetivo de predicción crean riesgos; el des-sesgo técnico interactúa de forma compleja con la ley antidiscriminación
Limitaciones	Solo lo que los proveedores publican; contexto EE. UU.
Riesgos de sesgo	Objetivos de predicción basados en decisiones históricas heredan sesgo
Aplicabilidad al caso (inferencia del equipo)	Directa: advierte sobre elegir «etiquetas» de contratación pasada
Decisión que respalda (decisión de ingeniería)	No entrenar con decisiones históricas como etiqueta; documentar validación y sesgo
Nivel de confianza	MODERADA

S02 — Köchling y Wehner (2020)

Campo	Contenido
Referencia	Köchling, A. y Wehner, M. C. (2020). Discriminated by an algorithm: a systematic review of discrimination and fairness by algorithmic decision-making in the context of HR recruitment and HR development. Business Research. https://doi.org/10.1007/s40685-020-00134-w
Año	2020
Autores	Köchling, A. y Wehner, M. C.
Revista o conferencia	Business Research
DOI / URL	https://doi.org/10.1007/s40685-020-00134-w
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	A · búsqueda A
Avisos de Crossref	ninguno
Objetivo	Revisar la literatura sobre discriminación y equidad en decisiones algorítmicas de RR. HH.
Datos o población	36 artículos (2014–2020)
Técnica	Revisión sistemática
Variables o características	Aplicaciones en reclutamiento y desarrollo
Métricas	Cualitativo
Resultados relevantes (evidencia)	El conocimiento sobre discriminación implícita en RR. HH. es aún escaso; identifica riesgos y vacíos
Limitaciones	Corpus pequeño y temprano
Riesgos de sesgo	Riesgo de discriminación implícita y percepción de injusticia
Aplicabilidad al caso (inferencia del equipo)	Alta para el marco de riesgos
Decisión que respalda (decisión de ingeniería)	Tratar la equidad como requisito de diseño, no como añadido
Nivel de confianza	MODERADA

S03 — Hunkenschroer y Luetge (2022)

Campo	Contenido
Referencia	Hunkenschroer, A. L. y Luetge, C. (2022). Ethics of AI-Enabled Recruiting and Selection: A Review and Research Agenda. Journal of Business Ethics. https://doi.org/10.1007/s10551-022-05049-6
Año	2022
Autores	Hunkenschroer, A. L. y Luetge, C.
Revista o conferencia	Journal of Business Ethics
DOI / URL	https://doi.org/10.1007/s10551-022-05049-6

Campo	Contenido
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	A · búsqueda F
Avisos de Crossref	ninguno
Objetivo	Mapear oportunidades, riesgos y ambigüedades éticas de la IA en reclutamiento
Datos o población	51 artículos
Técnica	Revisión sistemática
Variables o características	Etapas: anuncios, cribado de CV, entrevistas en vídeo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Identifica riesgos éticos (incluido el análisis facial en vídeo) y medidas de mitigación
Limitaciones	Literatura emergente; pocos estudios empíricos
Riesgos de sesgo	Opacidad, discriminación, privacidad
Aplicabilidad al caso (inferencia del equipo)	Alta: cubre las mismas etapas que la visión F33–F40
Decisión que respalda (decisión de ingeniería)	Excluir análisis facial; priorizar transparencia
Nivel de confianza	MODERADA

S04 — Tambe et al. (2019)

Campo	Contenido
Referencia	Tambe, P., Cappelli, P. y Yakubovich, V. (2019). Artificial Intelligence in Human Resources Management: Challenges and a Path Forward. California Management Review. https://doi.org/10.1177/0008125619867910
Año	2019
Autores	Tambe, P., Cappelli, P. y Yakubovich, V.
Revista o conferencia	California Management Review
DOI / URL	https://doi.org/10.1177/0008125619867910
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	A · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Identificar retos del uso de ciencia de datos en RR. HH.
Datos o población	Ensayo conceptual con casos
Técnica	Análisis conceptual
Variables o características	Complejidad de fenómenos de RR. HH., datos pequeños, rendición de cuentas
Métricas	Cualitativo
Resultados relevantes (evidencia)	Propone razonamiento causal, aleatorización y participación de los empleados
Limitaciones	Sin datos empíricos propios
Riesgos de sesgo	Conjuntos pequeños y etiquetas débiles
Aplicabilidad al caso (inferencia del equipo)	Muy alta: un colegio genera pocos procesos por año
Decisión que respalda (decisión de ingeniería)	Asumir datos pequeños: reglas y rúbricas antes que ML
Nivel de confianza	MODERADA

S05 — Chen (2023)

Campo	Contenido
Referencia	Chen, Z. (2023). Ethics and discrimination in artificial intelligence-enabled recruitment practices. Humanities and Social Sciences Communications. https://doi.org/10.1057/s41599-023-02079-x
Año	2023
Autores	Chen, Z.
Revista o conferencia	Humanities and Social Sciences Communications

Campo	Contenido
DOI / URL	https://doi.org/10.1057/s41599-023-02079-x
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	A · búsqueda A
Avisos de Crossref	ninguno
Objetivo	Estudiar la discriminación algorítmica en reclutamiento y sus soluciones
Datos o población	Revisión de literatura y encuesta
Técnica	Revisión + teoría fundamentada
Variables o características	Género, raza, rasgos de personalidad
Métricas	Cualitativo
Resultados relevantes (evidencia)	El sesgo proviene de datos limitados y del diseño; recomienda medidas técnicas y de gobernanza
Limitaciones	Método mixto con muestra no detallada en el resumen
Riesgos de sesgo	Datos históricos sesgados
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Combinar controles técnicos con gobernanza interna y supervisión externa
Nivel de confianza	LIMITADA

S06 — Langer et al. (2019)

Campo	Contenido
Referencia	Langer, M., König, C. J. y Papathanasiou, M. (2019). Highly automated job interviews: Acceptance under the influence of stakes. <i>International Journal of Selection and Assessment</i> . https://doi.org/10.1111/ijsa.12246
Año	2019
Autores	Langer, M., König, C. J. y Papathanasiou, M.
Revista o conferencia	<i>International Journal of Selection and Assessment</i>
DOI / URL	https://doi.org/10.1111/ijsa.12246
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	A · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Medir la reacción de las personas a entrevistas altamente automatizadas
Datos o población	N = 123; experimento 2 × 2 preregistrado
Técnica	Experimento con viñetas en vídeo
Variables o características	Automatización (alta / videoconferencia) × consecuencias (selección / formación)
Métricas	Aceptación, presencia social, equidad percibida, controlabilidad
Resultados relevantes (evidencia)	La entrevista automatizada redujo la aceptación por menor presencia social y equidad percibida; en alto riesgo generó ambigüedad
Limitaciones	Observadores, no postulantes reales
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta: la entrevista del colegio debe seguir siendo humana
Decisión que respalda (decisión de ingeniería)	No automatizar la conducción de la entrevista
Nivel de confianza	MODERADA

S07 — Hickman et al. (2022)

Campo	Contenido
Referencia	Hickman, L., Bosch, N., Ng, V., Saef, R., Tay, L. y Woo, S. E. (2022). Automated video interview personality assessments: Reliability, validity, and generalizability investigations. <i>Journal of Applied Psychology</i> . https://doi.org/10.1037/apl0000695
Año	2022
Autores	Hickman, L., Bosch, N., Ng, V., Saef, R., Tay, L. y Woo, S. E.

Campo	Contenido
Revista o conferencia	Journal of Applied Psychology
DOI / URL	https://doi.org/10.1037/apl0000695
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	T · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Evaluar fiabilidad y validez de evaluaciones de personalidad por entrevista en vídeo automatizada
Datos o población	Varias muestras (resumen parcial en OpenAlex)
Técnica	Modelos de ML sobre entrevistas en vídeo
Variables o características	Rasgos de personalidad (autoinforme vs. informe del entrevistador)
Métricas	Fiabilidad, validez convergente y discriminante, generalización
Resultados relevantes (evidencia)	Evidencia escasa de validez cuando se entrenan con autoinformes; mixta con informes del entrevistador
Limitaciones	Contextos de laboratorio y académicos
Riesgos de sesgo	Constructo psicológico inferido
Aplicabilidad al caso (inferencia del equipo)	Directa: sustenta no inferir personalidad
Decisión que respalda (decisión de ingeniería)	Prohibir puntuaciones de personalidad desde vídeo
Nivel de confianza	MODERADA

S08 — Barrett et al. (2019)

Campo	Contenido
Referencia	Barrett, L. F., Adolphs, R., Marsella, S., Martinez, A. M. y Pollak, S. D. (2019). Emotional Expressions Reconsidered: Challenges to Inferring Emotion From Human Facial Movements. Psychological Science in the Public Interest. https://doi.org/10.1177/1529100619832930
Año	2019
Autores	Barrett, L. F., Adolphs, R., Marsella, S., Martinez, A. M. y Pollak, S. D.
Revista o conferencia	Psychological Science in the Public Interest
DOI / URL	https://doi.org/10.1177/1529100619832930
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	T · bola de nieve
Avisos de Crossref	correction
Objetivo	Examinar si la emoción puede inferirse de los movimientos faciales
Datos o población	Revisión de la evidencia científica sobre 6 categorías emocionales
Técnica	Revisión crítica amplia
Variables o características	Configuraciones faciales y emoción
Métricas	Cualitativo
Resultados relevantes (evidencia)	La expresión de emociones varía mucho entre culturas, situaciones y personas; una misma configuración facial expresa varias emociones o algo distinto de una emoción
Limitaciones	Se centra en 6 emociones básicas
Riesgos de sesgo	Inferencias poco generalizables entre culturas
Aplicabilidad al caso (inferencia del equipo)	Directa: la evidencia no respalda que el reconocimiento de emociones en entrevistas sea fiable ni generalizable para un uso de alto impacto
Decisión que respalda (decisión de ingeniería)	Prohibir inferir emociones o estados desde rostro o voz
Nivel de confianza	FUERTE

S09 — Stark y Hoey (2021)

Campo	Contenido
Referencia	Stark, L. y Hoey, J. (2021). The Ethics of Emotion in Artificial Intelligence Systems. Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3442188.3445939

Campo	Contenido
Año	2021
Autores	Stark, L. y Hoey, J.
Revista o conferencia	Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3442188.3445939
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	T · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Analizar los modelos conceptuales y datos proxy del reconocimiento automático de emociones
Datos o población	Análisis conceptual
Técnica	Taxonomía crítica
Variables o características	Modelos de emoción, datos proxy
Métricas	Cualitativo
Resultados relevantes (evidencia)	No debe asumirse que estos sistemas producen una «verdad de terreno» sobre emociones
Limitaciones	Conceptual
Riesgos de sesgo	Proxies culturalmente sesgados
Aplicabilidad al caso (inferencia del equipo)	Directa
Decisión que respalda (decisión de ingeniería)	Misma decisión que S08
Nivel de confianza	MODERADA

S10 — Koenecke et al. (2020)

Campo	Contenido
Referencia	Koenecke, A., Nam, A., Lake, E., Nudell, J., Quartey, M., Mengesha, Z. et al. (2020). Racial disparities in automated speech recognition. Proceedings of the National Academy of Sciences. https://doi.org/10.1073/pnas.1915768117
Año	2020
Autores	Koenecke, A., Nam, A., Lake, E., Nudell, J., Quartey, M., Mengesha, Z. et al.
Revista o conferencia	Proceedings of the National Academy of Sciences
DOI / URL	https://doi.org/10.1073/pnas.1915768117
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	S · búsqueda T
Avisos de Crossref	ninguno
Objetivo	Medir disparidades raciales en reconocimiento automático del habla
Datos o población	5 sistemas comerciales; entrevistas estructuradas con 42 hablantes blancos y 73 negros; 19,8 h
Técnica	Auditoría comparativa
Variables o características	Raza del hablante; frases idénticas
Métricas	WER
Resultados relevantes (evidencia)	WER promedio 0,35 en hablantes negros frente a 0,19 en blancos; la brecha se atribuye a los modelos acústicos
Limitaciones	Inglés de EE. UU.; sistemas de 2019
Riesgos de sesgo	Disparidad por variedad dialectal
Aplicabilidad al caso (inferencia del equipo)	Alta: el STT puede degradar la evidencia de ciertos hablantes (p. ej., variedades del español andino)
Decisión que respalda (decisión de ingeniería)	Medir WER por variedad de habla antes de usar STT; revisión humana de transcripciones
Nivel de confianza	MODERADA

S11 — Wilson y Caliskan (2024)

Campo	Contenido
Referencia	Wilson, K. y Caliskan, A. (2024). Gender, Race, and Intersectional Bias in Resume Screening via Language Model Retrieval. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society. https://doi.org/10.1609/aies.v7i1.31748
Año	2024
Autores	Wilson, K. y Caliskan, A.
Revista o conferencia	Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society
DOI / URL	https://doi.org/10.1609/aies.v7i1.31748
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	E · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Auditar sesgos de modelos de embeddings en cribado de CV
Datos o población	>500 CV públicos, 500 descripciones de puesto, 9 ocupaciones
Técnica	Auditoría por recuperación (Massive Text Embeddings)
Variables o características	Nombres asociados a raza y género
Métricas	Tasa de preferencia por grupo
Resultados relevantes (evidencia)	Preferencia por nombres asociados a personas blancas en 85,1 % de los casos; hombres negros desfavorecidos hasta en el 100 % de los casos
Limitaciones	Nombres como proxy; EE. UU.
Riesgos de sesgo	Embeddings reproducen sesgos sociales
Aplicabilidad al caso (inferencia del equipo)	Directa para matching semántico
Decisión que respalda (decisión de ingeniería)	No usar similitud de embeddings como puntuación de candidatos sin auditoría; ocultar nombres
Nivel de confianza	MODERADA

S12 — Schmidt y Hunter (1998)

Campo	Contenido
Referencia	Schmidt, F. L. y Hunter, J. E. (1998). The validity and utility of selection methods in personnel psychology: Practical and theoretical implications of 85 years of research findings. Psychological Bulletin. https://doi.org/10.1037/0033-2909.124.2.262
Año	1998
Autores	Schmidt, F. L. y Hunter, J. E.
Revista o conferencia	Psychological Bulletin
DOI / URL	https://doi.org/10.1037/0033-2909.124.2.262
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Resumir 85 años de investigación sobre validez de métodos de selección
Datos o población	Metaanálisis de 19 métodos
Técnica	Síntesis metaanalítica
Variables o características	Métodos de selección y desempeño
Métricas	Validez de criterio
Resultados relevantes (evidencia)	Las combinaciones de capacidad cognitiva con muestra de trabajo, prueba de integridad o entrevista estructurada tuvieron las mayores validez ($\approx 0,63-0,65$)
Limitaciones	Correcciones de rango revisadas después por S13
Riesgos de sesgo	Sobreestimación por correcciones
Aplicabilidad al caso (inferencia del equipo)	Media: contexto histórico
Decisión que respalda (decisión de ingeniería)	Usar con la revisión de S13
Nivel de confianza	CONFLICTIVA

S13 — Sackett et al. (2022)

Campo	Contenido
Referencia	Sackett, P. R., Zhang, C., Berry, C. M. y Lievens, F. (2022). Revisiting meta-analytic estimates of validity in personnel selection: Addressing systematic overcorrection for restriction of range. <i>Journal of Applied Psychology</i> . https://doi.org/10.1037/apl0000994
Año	2022
Autores	Sackett, P. R., Zhang, C., Berry, C. M. y Lievens, F.
Revista o conferencia	<i>Journal of Applied Psychology</i>
DOI / URL	https://doi.org/10.1037/apl0000994
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Revisar estimaciones metaanalíticas de validez en selección
Datos o población	Reanálisis de metaanálisis previos
Técnica	Revisión de correcciones por restricción de rango
Variables o características	Métodos de selección
Métricas	Validez de criterio
Resultados relevantes (evidencia)	Validez sobreestimada antes en 0,10–0,20; la entrevista estructurada queda en el primer lugar
Limitaciones	Sigue dependiendo de estudios primarios
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta: sustenta la entrevista estructurada como método central
Decisión que respalda (decisión de ingeniería)	Basar la evaluación en entrevista estructurada con rúbrica
Nivel de confianza	FUERTE

S14 — McDaniel et al. (1994)

Campo	Contenido
Referencia	McDaniel, M. A., Whetzel, D. L., Schmidt, F. L. y Maurer, S. D. (1994). The validity of employment interviews: A comprehensive review and meta-analysis. <i>Journal of Applied Psychology</i> . https://doi.org/10.1037/0021-9010.79.4.599
Año	1994
Autores	McDaniel, M. A., Whetzel, D. L., Schmidt, F. L. y Maurer, S. D.
Revista o conferencia	<i>Journal of Applied Psychology</i>
DOI / URL	https://doi.org/10.1037/0021-9010.79.4.599
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · búsqueda D
Avisos de Crossref	ninguno
Objetivo	Metaanalizar la validez de la entrevista de empleo
Datos o población	245 coeficientes; 86 311 personas
Técnica	Metaanálisis
Variables o características	Contenido, estructura, formato, criterio
Métricas	Validez
Resultados relevantes (evidencia)	La entrevista estructurada supera a la no estructurada; las situacionales superan a las psicológicas
Limitaciones	Datos antiguos
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Preguntas situacionales y de conducta pasada, no psicológicas
Nivel de confianza	FUERTE

S15 — Campion et al. (1997)

Campo	Contenido
Referencia	Campion, M. A., Palmer, D. K. y Campion, J. E. (1997). A REVIEW OF STRUCTURE IN THE SELECTION INTERVIEW. Personnel Psychology. https://doi.org/10.1111/j.1744-6570.1997.tb00709.x
Año	1997
Autores	Campion, M. A., Palmer, D. K. y Campion, J. E.
Revista o conferencia	Personnel Psychology
DOI / URL	https://doi.org/10.1111/j.1744-6570.1997.tb00709.x
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Describir y evaluar los componentes de la estructura de una entrevista
Datos o población	Revisión de literatura
Técnica	Revisión narrativa
Variables o características	15 componentes de estructura
Métricas	Fiabilidad, validez, reacciones
Resultados relevantes (evidencia)	La estructura mejora las propiedades psicométricas; identifica 15 componentes
Limitaciones	Narrativa
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta: guía para la rúbrica de entrevista
Decisión que respalda (decisión de ingeniería)	Mismas preguntas, escalas ancladas y calificación por pregunta
Nivel de confianza	MODERADA

S16 — Levashina et al. (2013)

Campo	Contenido
Referencia	Levashina, J., Hartwell, C. J., Morgeson, F. P. y Campion, M. A. (2013). The Structured Employment Interview: Narrative and Quantitative Review of the Research Literature. Personnel Psychology. https://doi.org/10.1111/peps.12052
Año	2013
Autores	Levashina, J., Hartwell, C. J., Morgeson, F. P. y Campion, M. A.
Revista o conferencia	Personnel Psychology
DOI / URL	https://doi.org/10.1111/peps.12052
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Revisar 20 años de investigación sobre entrevista estructurada
Datos o población	Revisión narrativa y metaanalítica
Técnica	Revisión mixta
Variables o características	Sesgo, gestión de impresiones, escalas, preguntas
Métricas	Varias
Resultados relevantes (evidencia)	Mucho se sabe; 12 proposiciones y 19 preguntas abiertas
Limitaciones	Preguntas no resueltas
Riesgos de sesgo	Gestión de impresiones
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Escalas de calificación ancladas y sondeo controlado
Nivel de confianza	FUERTE

S17 — Campion et al. (2011)

Campo	Contenido
Referencia	Campion, M. A., Fink, A. A., Ruggeberg, B. J., Carr, L., Phillips, G. M. y Odman, R. B. (2011). DOING COMPETENCIES WELL: BEST PRACTICES IN COMPETENCY MODELING. Personnel Psychology. https://doi.org/10.1111/j.1744-6570.2010.01207.x
Año	2011
Autores	Campion, M. A., Fink, A. A., Ruggeberg, B. J., Carr, L., Phillips, G. M. y Odman, R. B.
Revista o conferencia	Personnel Psychology
DOI / URL	https://doi.org/10.1111/j.1744-6570.2010.01207.x
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer buenas prácticas de modelado por competencias
Datos o población	Experiencia aplicada y académica
Técnica	Revisión de prácticas
Variables o características	Análisis, organización y uso de competencias
Métricas	Cualitativo
Resultados relevantes (evidencia)	20 buenas prácticas; diferencia y complementariedad con el análisis de puestos
Limitaciones	Recomendaciones de expertos
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta: base de criterios por vacante
Decisión que respalda (decisión de ingeniería)	Competencias derivadas de análisis del puesto
Nivel de confianza	MODERADA

S18 — Sanchez y Levine (2012)

Campo	Contenido
Referencia	Sanchez, J. I. y Levine, E. L. (2012). The Rise and Fall of Job Analysis and the Future of Work Analysis. Annual Review of Psychology. https://doi.org/10.1146/annurev-psych-120710-100401
Año	2012
Autores	Sanchez, J. I. y Levine, E. L.
Revista o conferencia	Annual Review of Psychology
DOI / URL	https://doi.org/10.1146/annurev-psych-120710-100401
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Revisar la evolución del análisis de puestos y el modelado de competencias
Datos o población	Revisión
Técnica	Revisión narrativa
Variables o características	Actividades, atributos, contexto de trabajo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Propone nuevas formas de análisis del trabajo y una agenda para competencias
Limitaciones	Narrativa
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Hacer análisis del puesto antes de definir criterios
Nivel de confianza	MODERADA

S19 — Smith y Kendall (1963)

Campo	Contenido
Referencia	Smith, P. C. y Kendall, L. M. (1963). Retranslation of expectations: An approach to the construction of unambiguous anchors for rating scales. Journal of Applied Psychology. https://doi.org/10.1037/h0047060
Año	1963
Autores	Smith, P. C. y Kendall, L. M.
Revista o conferencia	Journal of Applied Psychology
DOI / URL	https://doi.org/10.1037/h0047060
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer escalas de calificación ancladas en conducta (BARS) (sin resumen disponible; descripción general)
Datos o población	Desarrollo de escalas
Técnica	Retraducción de expectativas
Variables o características	Anclas conductuales
Métricas	Cualitativo
Resultados relevantes (evidencia)	Método para escalas con anclas conductuales no ambiguas
Limitaciones	Antiguo
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Usar anclas conductuales por nivel en cada criterio
Nivel de confianza	MODERADA

S20 — Shrout y Fleiss (1979)

Campo	Contenido
Referencia	Shrout, P. E. y Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. Psychological Bulletin. https://doi.org/10.1037/0033-2909.86.2.420
Año	1979
Autores	Shrout, P. E. y Fleiss, J. L.
Revista o conferencia	Psychological Bulletin
DOI / URL	https://doi.org/10.1037/0033-2909.86.2.420
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Guiar la elección del coeficiente de correlación intraclass
Datos o población	Metodológico
Técnica	Estadística
Variables o características	n objetos calificados por k jueces
Métricas	ICC
Resultados relevantes (evidencia)	Seis formas de ICC según el modelo y el uso
Limitaciones	Metodológico
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta: fiabilidad entre evaluadores
Decisión que respalda (decisión de ingeniería)	Medir acuerdo entre evaluadores con ICC
Nivel de confianza	FUERTE

S21 — Koo y Li (2016)

Campo	Contenido
Referencia	Koo, T. K. y Li, M. Y. (2016). A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research. Journal of Chiropractic Medicine. https://doi.org/10.1016/j.jcm.2016.02.012
Año	2016
Autores	Koo, T. K. y Li, M. Y.
Revista o conferencia	Journal of Chiropractic Medicine
DOI / URL	https://doi.org/10.1016/j.jcm.2016.02.012
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	erratum
Objetivo	Guía de selección y reporte del ICC
Datos o población	Metodológico
Técnica	Estadística
Variables o características	Formas de ICC
Métricas	ICC e IC 95 %
Resultados relevantes (evidencia)	Hay 10 formas de ICC; debe reportarse modelo, tipo y definición
Limitaciones	Tiene una errata registrada en Crossref
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Reportar el ICC con su forma e intervalo
Nivel de confianza	FUERTE

S22 — Klassen y Kim (2019)

Campo	Contenido
Referencia	Klassen, R. M. y Kim, L. E. (2019). Selecting teachers and prospective teachers: A meta-analysis. Educational Research Review. https://doi.org/10.1016/j.edurev.2018.12.003
Año	2019
Autores	Klassen, R. M. y Kim, L. E.
Revista o conferencia	Educational Research Review
DOI / URL	https://doi.org/10.1016/j.edurev.2018.12.003
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Metaanalizar la validez predictiva de la selección de docentes
Datos o población	32 estudios en condiciones reales
Técnica	Metaanálisis
Variables o características	Predictores académicos y no académicos
Métricas	Correlación con eficacia docente
Resultados relevantes (evidencia)	Efecto global pequeño pero significativo ($r = 0,12$)
Limitaciones	Medidas de eficacia heterogéneas
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta: caso docente
Decisión que respalda (decisión de ingeniería)	Ser prudente con la capacidad predictiva en docentes; apoyo, no predicción
Nivel de confianza	FUERTE

S23 — Woods et al. (2019)

Campo	Contenido
Referencia	Woods, S. A., Ahmed, S., Nikolaou, I., Costa, A. C. y Anderson, N. R. (2019). Personnel selection in the digital age: a review of validity and applicant reactions, and future research challenges. <i>European Journal of Work and Organizational Psychology</i> . https://doi.org/10.1080/1359432x.2019.1681401
Año	2019
Autores	Woods, S. A., Ahmed, S., Nikolaou, I., Costa, A. C. y Anderson, N. R.
Revista o conferencia	European Journal of Work and Organizational Psychology
DOI / URL	https://doi.org/10.1080/1359432x.2019.1681401
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · búsqueda C
Avisos de Crossref	ninguno
Objetivo	Revisar procedimientos de selección digitales
Datos o población	Revisión focalizada
Técnica	Revisión
Variables o características	Aplicaciones en línea, pruebas, entrevistas digitales, gamificación, redes sociales
Métricas	Validez y reacciones
Resultados relevantes (evidencia)	Base de evidencia desigual; agenda de investigación
Limitaciones	Evidencia limitada
Riesgos de sesgo	Uso de redes sociales
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	No usar redes sociales del postulante
Nivel de confianza	MODERADA

S24 — Huffcutt et al. (2001)

Campo	Contenido
Referencia	Huffcutt, A. I., Conway, J. M., Roth, P. L. y Stone, N. J. (2001). Identification and meta-analytic assessment of psychological constructs measured in employment interviews. <i>Journal of Applied Psychology</i> . https://doi.org/10.1037/0021-9010.86.5.897
Año	2001
Autores	Huffcutt, A. I., Conway, J. M., Roth, P. L. y Stone, N. J.
Revista o conferencia	Journal of Applied Psychology
DOI / URL	https://doi.org/10.1037/0021-9010.86.5.897
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · búsqueda D
Avisos de Crossref	ninguno
Objetivo	Identificar qué constructos mide la entrevista
Datos o población	338 calificaciones de 47 estudios
Técnica	Metaanálisis
Variables o características	Taxonomía de 7 constructos
Métricas	Frecuencia y validez
Resultados relevantes (evidencia)	La mayor validez de la entrevista estructurada se explica en parte por medir constructos más ligados al desempeño
Limitaciones	Datos de estudios publicados
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Definir qué competencia mide cada pregunta
Nivel de confianza	MODERADA

S25 — Zhu et al. (2018)

Campo	Contenido
Referencia	Zhu, C., Zhu, H., Xiong, H., Ma, C., Xie, F., Ding, P. et al. (2018). Person-Job Fit. ACM Transactions on Management Information Systems. https://doi.org/10.1145/3234465
Año	2018
Autores	Zhu, C., Zhu, H., Xiong, H., Ma, C., Xie, F., Ding, P. et al.
Revista o conferencia	ACM Transactions on Management Information Systems
DOI / URL	https://doi.org/10.1145/3234465
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	B · búsqueda B
Avisos de Crossref	ninguno
Objetivo	Modelar el ajuste persona-puesto con redes neuronales
Datos o población	Postulaciones históricas
Técnica	CNN bipartita (PJFNN)
Variables o características	Texto de requisitos y de experiencia
Métricas	Precisión de ajuste
Resultados relevantes (evidencia)	Estima el ajuste e identifica qué requisitos cumple el candidato
Limitaciones	Requiere grandes datos históricos
Riesgos de sesgo	Aprende de decisiones pasadas
Aplicabilidad al caso (inferencia del equipo)	Baja: no hay volumen de datos en el caso
Decisión que respalda (decisión de ingeniería)	Descartar deep learning de matching para el caso
Nivel de confianza	LIMITADA

S26 — Qin et al. (2018)

Campo	Contenido
Referencia	Qin, C., Zhu, H., Xu, T., Zhu, C., Jiang, L., Chen, E. et al. (2018). Enhancing Person-Job Fit for Talent Recruitment. The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. https://doi.org/10.1145/3209978.3210025
Año	2018
Autores	Qin, C., Zhu, H., Xu, T., Zhu, C., Jiang, L., Chen, E. et al.
Revista o conferencia	The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval
DOI / URL	https://doi.org/10.1145/3209978.3210025
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	B · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Ajuste persona-puesto consciente de habilidades con mejor interpretación
Datos o población	Postulaciones históricas
Técnica	Red neuronal con atención (APJFNN)
Variables o características	Representaciones de requisitos y experiencia
Métricas	Precisión
Resultados relevantes (evidencia)	Mejora la interpretación del ajuste frente a modelos previos
Limitaciones	Datos de una plataforma
Riesgos de sesgo	Etiquetas de decisiones pasadas
Aplicabilidad al caso (inferencia del equipo)	Baja por datos
Decisión que respalda (decisión de ingeniería)	Igual que S25
Nivel de confianza	LIMITADA

S27 — Freire y de Castro (2020)

Campo	Contenido
Referencia	Freire, M. N. y de Castro, L. N. (2020). e-Recruitment recommender systems: a systematic review. Knowledge and Information Systems. https://doi.org/10.1007/s10115-020-01522-8
Año	2020
Autores	Freire, M. N. y de Castro, L. N.
Revista o conferencia	Knowledge and Information Systems
DOI / URL	https://doi.org/10.1007/s10115-020-01522-8
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	H · búsqueda H
Avisos de Crossref	ninguno
Objetivo	Revisión sistemática de recomendadores de e-recruitment (sin resumen disponible; descripción general)
Datos o población	Literatura
Técnica	Revisión sistemática
Variables o características	Enfoques de recomendación
Métricas	Varias
Resultados relevantes (evidencia)	Panorama de técnicas y retos
Limitaciones	Ver la publicación
Riesgos de sesgo	Varios
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Contexto para F40
Nivel de confianza	MODERADA

S28 — Mashayekhi et al. (2024)

Campo	Contenido
Referencia	Mashayekhi, Y., Li, N., Kang, B., Lijffijt, J. y De Bie, T. (2024). A Challenge-based Survey of E-recruitment Recommendation Systems. ACM Computing Surveys. https://doi.org/10.1145/3659942
Año	2024
Autores	Mashayekhi, Y., Li, N., Kang, B., Lijffijt, J. y De Bie, T.
Revista o conferencia	ACM Computing Surveys
DOI / URL	https://doi.org/10.1145/3659942
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	H · búsqueda H
Avisos de Crossref	ninguno
Objetivo	Identificar retos de los recomendadores de e-recruitment
Datos o población	Literatura
Técnica	Revisión por retos
Variables o características	Retos: datos, bidireccionalidad, equidad, explicabilidad
Métricas	Varias
Resultados relevantes (evidencia)	Organiza la literatura por retos prácticos
Limitaciones	Revisión
Riesgos de sesgo	Equidad e impacto en carreras
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Tratar equidad y explicación como requisitos del ranking
Nivel de confianza	MODERADA

S29 — Zhang et al. (2022)

Campo	Contenido
Referencia	Zhang, M., Jensen, K., Sonniks, S. y Plank, B. (2022). SkillSpan: Hard and Soft Skill Extraction from English Job Postings. Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. https://doi.org/10.18653/v1/2022.naacl-main.366
Año	2022
Autores	Zhang, M., Jensen, K., Sonniks, S. y Plank, B.
Revista o conferencia	Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies
DOI / URL	https://doi.org/10.18653/v1/2022.naacl-main.366
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	G · búsqueda G
Avisos de Crossref	ninguno
Objetivo	Extraer habilidades duras y blandas de avisos de empleo (sin resumen disponible; descripción general)
Datos o población	Corpus anotado de avisos en inglés
Técnica	Etiquetado de secuencias con modelos tipo BERT
Variables o características	Tramos de habilidad
Métricas	F1 por tramo
Resultados relevantes (evidencia)	Conjunto de datos y referencias para extracción de habilidades
Limitaciones	Inglés; avisos, no CV
Riesgos de sesgo	Anotación subjetiva de habilidades blandas
Aplicabilidad al caso (inferencia del equipo)	Media: la extracción en español requiere datos propios
Decisión que respalda (decisión de ingeniería)	Extracción de habilidades como sugerencia revisada por humanos
Nivel de confianza	MODERADA

S30 — Khaouja et al. (2021)

Campo	Contenido
Referencia	Khaouja, I., Kassou, I. y Ghogho, M. (2021). A Survey on Skill Identification From Online Job Ads. IEEE Access. https://doi.org/10.1109/access.2021.3106120
Año	2021
Autores	Khaouja, I., Kassou, I. y Ghogho, M.
Revista o conferencia	IEEE Access
DOI / URL	https://doi.org/10.1109/access.2021.3106120
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	G · búsqueda G
Avisos de Crossref	ninguno
Objetivo	Revisar la identificación de habilidades en avisos de empleo
Datos o población	108 artículos
Técnica	Revisión sistemática
Variables o características	Bases de habilidades, métodos, granularidad
Métricas	Varias
Resultados relevantes (evidencia)	Clasifica métodos y aplicaciones; retos abiertos
Limitaciones	Avisos, no CV
Riesgos de sesgo	Taxonomías no neutrales
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Usar una taxonomía explícita (p. ej., ESCO) si se extraen habilidades
Nivel de confianza	MODERADA

S31 — Reimers y Gurevych (2019)

Campo	Contenido
Referencia	Reimers, N. y Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). https://doi.org/10.18653/v1/D19-1410
Año	2019
Autores	Reimers, N. y Gurevych, I.
Revista o conferencia	Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)
DOI / URL	https://doi.org/10.18653/v1/D19-1410
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	F · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Obtener embeddings de oraciones eficientes (sin resumen disponible; descripción general)
Datos o población	Corpus de similitud y NLI
Técnica	Redes siamesas sobre BERT (SBERT)
Variables o características	Pares de oraciones
Métricas	Correlación con similitud humana
Resultados relevantes (evidencia)	Embeddings comparables por coseno con mucho menor costo que comparar con BERT completo
Limitaciones	Similitud general, no ajuste laboral
Riesgos de sesgo	Hereda sesgos del preentrenamiento (ver S11)
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Similitud semántica solo para encontrar evidencia, no para puntuar
Nivel de confianza	FUERTE

S32 — Blodgett et al. (2020)

Campo	Contenido
Referencia	Blodgett, S. L., Barocas, S., Daumé III, H. y Wallach, H. (2020). Language (Technology) is Power: A Critical Survey of “Bias” in NLP. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.485
Año	2020
Autores	Blodgett, S. L., Barocas, S., Daumé III, H. y Wallach, H.
Revista o conferencia	Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics
DOI / URL	https://doi.org/10.18653/v1/2020.acl-main.485
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	E · búsqueda E
Avisos de Crossref	ninguno
Objetivo	Revisar críticamente cómo se estudia el «sesgo» en NLP
Datos o población	146 artículos
Técnica	Revisión crítica
Variables o características	Motivaciones y técnicas de medición del sesgo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Motivaciones vagas y técnicas poco alineadas con ellas; propone tres recomendaciones
Limitaciones	Revisión
Riesgos de sesgo	Sesgo social en lenguaje
Aplicabilidad al caso (inferencia del equipo)	Alta

Campo	Contenido
Decisión que respalda (decisión de ingeniería)	Definir qué daño se mide y a quién afecta antes de medir sesgo
Nivel de confianza	MODERADA

S33 — Bender y Friedman (2018)

Campo	Contenido
Referencia	Bender, E. M. y Friedman, B. (2018). Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science. Transactions of the Association for Computational Linguistics. https://doi.org/10.1162/tac1_a_00041
Año	2018
Autores	Bender, E. M. y Friedman, B.
Revista o conferencia	Transactions of the Association for Computational Linguistics
DOI / URL	https://doi.org/10.1162/tac1_a_00041
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	E · búsqueda E
Avisos de Crossref	ninguno
Objetivo	Proponer «data statements» para NLP
Datos o población	Propuesta
Técnica	Práctica de documentación
Variables o características	Población, variedad lingüística, anotadores
Métricas	Cualitativo
Resultados relevantes (evidencia)	Documentar datos mejora generalización y reduce exclusión
Limitaciones	Propuesta normativa
Riesgos de sesgo	Variedades lingüísticas
Aplicabilidad al caso (inferencia del equipo)	Alta (español andino)
Decisión que respalda (decisión de ingeniería)	Documentar variedad de habla y texto en el dataset card
Nivel de confianza	MODERADA

S34 — Ji et al. (2023)

Campo	Contenido
Referencia	Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y. et al. (2023). Survey of Hallucination in Natural Language Generation. ACM Computing Surveys. https://doi.org/10.1145/3571730
Año	2023
Autores	Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y. et al.
Revista o conferencia	ACM Computing Surveys
DOI / URL	https://doi.org/10.1145/3571730
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	E · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Revisar la alucinación en generación de lenguaje
Datos o población	Literatura
Técnica	Revisión
Variables o características	Tareas de generación
Métricas	Métricas de alucinación
Resultados relevantes (evidencia)	La generación neuronal es propensa a alucinar; métodos de medición y mitigación
Limitaciones	Previa a los LLM más recientes
Riesgos de sesgo	Información falsa

Campo	Contenido
Aplicabilidad al caso (inferencia del equipo)	Muy alta para resúmenes y explicaciones con LLM
Decisión que respalda (decisión de ingeniería)	Toda salida de LLM debe citar la evidencia de origen y validarse
Nivel de confianza	FUERTE

S35 — Bender et al. (2021)

Campo	Contenido
Referencia	Bender, E. M., Gebru, T., McMillan-Major, A. y Shmitchell, S. (2021). On the Dangers of Stochastic Parrots. Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3442188.3445922
Año	2021
Autores	Bender, E. M., Gebru, T., McMillan-Major, A. y Shmitchell, S.
Revista o conferencia	Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3442188.3445922
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	E · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Analizar riesgos de modelos de lenguaje muy grandes
Datos o población	Ensayo crítico
Técnica	Análisis
Variables o características	Datos, costo, sesgo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Recomienda documentar datos y evaluar riesgos antes de desarrollar
Limitaciones	Posicionamiento
Riesgos de sesgo	Sesgos del corpus web
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Evaluar riesgos antes de adoptar LLM
Nivel de confianza	MODERADA

S36 — Zheng et al. (2023)

Campo	Contenido
Referencia	Zheng, L., Chiang, W. L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv. https://doi.org/10.48550/arXiv.2306.05685
Año	2023
Autores	Zheng, L., Chiang, W. L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y. et al.
Revista o conferencia	arXiv
DOI / URL	https://doi.org/10.48550/arXiv.2306.05685
Tipo de publicación	Preprint (arXiv)
Revisión por pares	No (preprint); publicado en NeurIPS 2023
Tema y origen	T · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Evaluar el uso de LLM como jueces
Datos o población	MT-Bench y Chatbot Arena
Técnica	LLM como evaluador
Variables o características	Preguntas abiertas
Métricas	Acuerdo con preferencias humanas
Resultados relevantes (evidencia)	Acuerdo superior al 80 % con preferencias humanas; sesgos de posición, verbosidad y autopromoción
Limitaciones	Tareas de chat, no evaluación de personas

Campo	Contenido
Riesgos de sesgo	Sesgos del juez
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	No usar LLM como juez de candidatos; como mucho, ayuda para revisar consistencia de rúbricas
Nivel de confianza	MODERADA

S37 — Xu et al. (2021)

Campo	Contenido
Referencia	Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G. et al. (2021). LayoutLMv2: Multi-modal Pre-training for Visually-rich Document Understanding. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). https://doi.org/10.18653/v1/2021.acl-long.201
Año	2021
Autores	Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G. et al.
Revista o conferencia	Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)
DOI / URL	https://doi.org/10.18653/v1/2021.acl-long.201
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	R · búsqueda R
Avisos de Crossref	ninguno
Objetivo	Preentrenamiento multimodal para comprender documentos (sin resumen disponible; descripción general)
Datos o población	Documentos escaneados y digitales
Técnica	Transformer de texto, disposición e imagen (LayoutLMv2)
Variables o características	Texto, posición, imagen
Métricas	Exactitud en tareas
Resultados relevantes (evidencia)	Mejora tareas de comprensión de documentos visualmente ricos
Limitaciones	Costo computacional
Riesgos de sesgo	No relevante
Aplicabilidad al caso (inferencia del equipo)	Baja: los CV del caso son digitales
Decisión que respalda (decisión de ingeniería)	OCR/disposición solo si hay escaneados
Nivel de confianza	MODERADA

S38 — Radford et al. (2022)

Campo	Contenido
Referencia	Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C. y Sutskever, I. (2022). Robust Speech Recognition via Large-Scale Weak Supervision. arXiv. https://doi.org/10.48550/arXiv.2212.04356
Año	2022
Autores	Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C. y Sutskever, I.
Revista o conferencia	arXiv
DOI / URL	https://doi.org/10.48550/arXiv.2212.04356
Tipo de publicación	Preprint (arXiv)
Revisión por pares	No (preprint); publicado en ICML 2023
Tema y origen	S · búsqueda S
Avisos de Crossref	ninguno
Objetivo	Reconocimiento de voz robusto con supervisión débil
Datos o población	680 000 h de audio multilingüe
Técnica	Transformer codificador-decodificador (Whisper)

Campo	Contenido
Variables o características	Audio
Métricas	WER
Resultados relevantes (evidencia)	Generaliza bien en cero disparos y se acerca a la robustez humana
Limitaciones	Evaluación en benchmarks
Riesgos de sesgo	Rendimiento desigual por idioma y variedad
Aplicabilidad al caso (inferencia del equipo)	Alta: candidato STT local
Decisión que respalda (decisión de ingeniería)	Evaluar Whisper con audio propio y revisión humana
Nivel de confianza	MODERADA

S39 — Saaty (1990)

Campo	Contenido
Referencia	Saaty, T. L. (1990). How to make a decision: The analytic hierarchy process. European Journal of Operational Research. https://doi.org/10.1016/0377-2217(90)90057-I
Año	1990
Autores	Saaty, T. L.
Revista o conferencia	European Journal of Operational Research
DOI / URL	https://doi.org/10.1016/0377-2217(90)90057-I
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	I · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Presentar el proceso analítico jerárquico (AHP) (sin resumen disponible; descripción general)
Datos o población	Método
Técnica	AHP
Variables o características	Comparaciones por pares de criterios
Métricas	Razón de consistencia
Resultados relevantes (evidencia)	Método para derivar pesos de criterios
Limitaciones	Sensible a la elicitación
Riesgos de sesgo	Pesos subjetivos
Aplicabilidad al caso (inferencia del equipo)	Alta: pesos por vacante
Decisión que respalda (decisión de ingeniería)	Derivar pesos con método explícito y registrado
Nivel de confianza	MODERADA

S40 — Kelemenis y Askounis (2010)

Campo	Contenido
Referencia	Kelemenis, A. y Askounis, D. (2010). A new TOPSIS-based multi-criteria approach to personnel selection. Expert Systems with Applications. https://doi.org/10.1016/j.eswa.2009.12.013
Año	2010
Autores	Kelemenis, A. y Askounis, D.
Revista o conferencia	Expert Systems with Applications
DOI / URL	https://doi.org/10.1016/j.eswa.2009.12.013
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	I · búsqueda I
Avisos de Crossref	ninguno
Objetivo	Aplicar TOPSIS a la selección de personal (sin resumen disponible; descripción general)

Campo	Contenido
Datos o población	Caso de aplicación
Técnica	TOPSIS
Variables o características	Criterios ponderados
Métricas	Ordenamiento
Resultados relevantes (evidencia)	Enfoque multicriterio para ordenar candidatos
Limitaciones	Caso único
Riesgos de sesgo	Pesos subjetivos
Aplicabilidad al caso (inferencia del equipo)	Media: el ranking actual ya es una suma ponderada (RF-21)
Decisión que respalda (decisión de ingeniería)	Mantener la suma ponderada transparente; MCDM complejo no aporta evidencia adicional
Nivel de confianza	LIMITADA

S41 — Mehrabi et al. (2021)

Campo	Contenido
Referencia	Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K. y Galstyan, A. (2021). A Survey on Bias and Fairness in Machine Learning. ACM Computing Surveys. https://doi.org/10.1145/3457607
Año	2021
Autores	Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K. y Galstyan, A.
Revista o conferencia	ACM Computing Surveys
DOI / URL	https://doi.org/10.1145/3457607
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	K · búsqueda K
Avisos de Crossref	ninguno
Objetivo	Revisar sesgo y equidad en ML
Datos o población	Literatura
Técnica	Revisión
Variables o características	Fuentes de sesgo, definiciones
Métricas	Varias
Resultados relevantes (evidencia)	Taxonomía de sesgos y definiciones de equidad
Limitaciones	Revisión
Riesgos de sesgo	Varios
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Catálogo de sesgos para el análisis de riesgos
Nivel de confianza	MODERADA

S42 — Barocas y Selbst (2016)

Campo	Contenido
Referencia	Barocas, S. y Selbst, A. D. (2016). Big Data's Disparate Impact. California Law Review. https://doi.org/10.15779/Z38BG31
Año	2016
Autores	Barocas, S. y Selbst, A. D.
Revista o conferencia	California Law Review
DOI / URL	https://doi.org/10.15779/Z38BG31
Tipo de publicación	Artículo de revista
Revisión por pares	Revisión editorial (revista jurídica)
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Analizar el impacto dispar de la minería de datos

Campo	Contenido
Datos o población	Análisis jurídico
Técnica	Análisis
Variables o características	Datos históricos
Métricas	Cualitativo
Resultados relevantes (evidencia)	Los algoritmos heredan prejuicios de decisiones previas y patrones de exclusión
Limitaciones	Derecho de EE. UU.
Riesgos de sesgo	Sesgo histórico
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	No usar decisiones históricas de contratación como verdad
Nivel de confianza	MODERADA

S43 — Hardt et al. (2016)

Campo	Contenido
Referencia	Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. arXiv. https://doi.org/10.48550/arXiv.1610.02413
Año	2016
Autores	Hardt, M., Price, E. y Srebro, N.
Revista o conferencia	arXiv
DOI / URL	https://doi.org/10.48550/arXiv.1610.02413
Tipo de publicación	Preprint (arXiv)
Revisión por pares	No (preprint); publicado en NeurIPS 2016
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Definir igualdad de oportunidades en aprendizaje supervisado
Datos o población	Teórico con caso
Técnica	Post-procesamiento
Variables o características	Predictor, objetivo, atributo protegido
Métricas	Tasas de error por grupo
Resultados relevantes (evidencia)	Define igualdad de oportunidades/probabilidades y cómo ajustarlas; límites de las medidas «oblivious»
Limitaciones	Requiere el atributo protegido y una etiqueta confiable
Riesgos de sesgo	Etiqueta sesgada
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Las métricas de equidad requieren etiquetas válidas que el caso no tiene
Nivel de confianza	FUERTE

S44 — Kleinberg et al. (2017)

Campo	Contenido
Referencia	Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. Schloss Dagstuhl – Leibniz-Zentrum für Informatik. https://doi.org/10.4230/LIPIcs.ITCS.2017.43
Año	2017
Autores	Kleinberg, J., Mullainathan, S. y Raghavan, M.
Revista o conferencia	Schloss Dagstuhl – Leibniz-Zentrum für Informatik
DOI / URL	https://doi.org/10.4230/LIPIcs.ITCS.2017.43
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Formalizar compromisos entre condiciones de equidad

Campo	Contenido
Datos o población	Teórico
Técnica	Demostración
Variables o características	Calibración y equilibrio de errores
Métricas	Formal
Resultados relevantes (evidencia)	Salvo casos especiales, no pueden cumplirse a la vez
Limitaciones	Teórico
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Elegir y justificar una métrica de equidad; no prometer todas
Nivel de confianza	FUERTE

S45 — Chouldechova (2017)

Campo	Contenido
Referencia	Chouldechova, A. (2017). Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments. Big Data. https://doi.org/10.1089/big.2016.0047
Año	2017
Autores	Chouldechova, A.
Revista o conferencia	Big Data
DOI / URL	https://doi.org/10.1089/big.2016.0047
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Estudiar criterios de equidad en instrumentos de riesgo
Datos o población	Teórico con datos de reincidencia
Técnica	Análisis formal y empírico
Variables o características	Tasas base por grupo
Métricas	Error por grupo
Resultados relevantes (evidencia)	Los criterios no pueden satisfacerse a la vez si las tasas base difieren
Limitaciones	Dominio penal
Riesgos de sesgo	Tasas base
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Igual que S44
Nivel de confianza	FUERTE

S46 — Friedler et al. (2019)

Campo	Contenido
Referencia	Friedler, S. A., Scheidegger, C., Venkatasubramanian, S., Choudhary, S., Hamilton, E. P. y Roth, D. (2019). A comparative study of fairness-enhancing interventions in machine learning. Proceedings of the Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3287560.3287589
Año	2019
Autores	Friedler, S. A., Scheidegger, C., Venkatasubramanian, S., Choudhary, S., Hamilton, E. P. y Roth, D.
Revista o conferencia	Proceedings of the Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3287560.3287589
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	K · búsqueda K
Avisos de Crossref	ninguno

Campo	Contenido
Objetivo	Comparar intervenciones para mejorar la equidad
Datos o población	Varios conjuntos de datos
Técnica	Benchmark
Variables o características	Algoritmos de equidad
Métricas	Equidad y exactitud
Resultados relevantes (evidencia)	Resultados sensibles al preprocesamiento y a la partición
Limitaciones	Datasets de referencia
Riesgos de sesgo	Inestabilidad de métricas
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Reportar variabilidad, no un solo número
Nivel de confianza	MODERADA

S47 — Suresh y Guttag (2021)

Campo	Contenido
Referencia	Suresh, H. y Guttag, J. (2021). A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle. Equity and Access in Algorithms, Mechanisms, and Optimization. https://doi.org/10.1145/3465416.3483305
Año	2021
Autores	Suresh, H. y Guttag, J.
Revista o conferencia	Equity and Access in Algorithms, Mechanisms, and Optimization
DOI / URL	https://doi.org/10.1145/3465416.3483305
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Identificar fuentes de daño en el ciclo de vida del ML
Datos o población	Marco conceptual
Técnica	Taxonomía
Variables o características	7 fuentes de daño
Métricas	Cualitativo
Resultados relevantes (evidencia)	Sesgos histórico, de representación, de medición, etc.
Limitaciones	Conceptual
Riesgos de sesgo	Todos
Aplicabilidad al caso (inferencia del equipo)	Muy alta
Decisión que respalda (decisión de ingeniería)	Usar las 7 fuentes como lista de riesgos de F34
Nivel de confianza	MODERADA

S48 — Obermeyer et al. (2019)

Campo	Contenido
Referencia	Obermeyer, Z., Powers, B., Vogeli, C. y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. Science. https://doi.org/10.1126/science.aax2342
Año	2019
Autores	Obermeyer, Z., Powers, B., Vogeli, C. y Mullainathan, S.
Revista o conferencia	Science
DOI / URL	https://doi.org/10.1126/science.aax2342
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	K · búsqueda A

Campo	Contenido
Avisos de Crossref	ninguno
Objetivo	Medir sesgo racial en un algoritmo de salud
Datos o población	Algoritmo comercial; millones de pacientes
Técnica	Auditoría
Variables o características	Costo de salud como proxy
Métricas	Tasa de derivación
Resultados relevantes (evidencia)	Usar el costo como proxy de la necesidad creó sesgo racial; corregirlo eleva la ayuda a pacientes negros de 17,7 % a 46,5 %
Limitaciones	Dominio de salud
Riesgos de sesgo	Sesgo de proxy de la etiqueta
Aplicabilidad al caso (inferencia del equipo)	Alta por analogía
Decisión que respalda (decisión de ingeniería)	Revisar qué representa la etiqueta (p. ej., «contratado» ≠ «idóneo»)
Nivel de confianza	FUERTE

S49 — Bellamy et al. (2019)

Campo	Contenido
Referencia	Bellamy, R. K. E., Dey, K., Hind, M., Hoffman, S. C., Houde, S., Kannan, K. et al. (2019). AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias. IBM Journal of Research and Development. https://doi.org/10.1147/JRD.2019.2942287
Año	2019
Autores	Bellamy, R. K. E., Dey, K., Hind, M., Hoffman, S. C., Houde, S., Kannan, K. et al.
Revista o conferencia	IBM Journal of Research and Development
DOI / URL	https://doi.org/10.1147/JRD.2019.2942287
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Presentar el toolkit AI Fairness 360
Datos o población	Software
Técnica	Biblioteca
Variables o características	Métricas y mitigaciones
Métricas	Métricas de equidad
Resultados relevantes (evidencia)	Toolkit Apache 2.0 con métricas, explicaciones y mitigaciones
Limitaciones	Herramienta
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Candidato de herramienta (ver análisis de herramientas)
Nivel de confianza	MODERADA

S50 — Holstein et al. (2019)

Campo	Contenido
Referencia	Holstein, K., Wortman Vaughan, J., Daumé, H., Dudik, M. y Wallach, H. (2019). Improving Fairness in Machine Learning Systems. Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3290605.3300830
Año	2019
Autores	Holstein, K., Wortman Vaughan, J., Daumé, H., Dudik, M. y Wallach, H.
Revista o conferencia	Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems
DOI / URL	https://doi.org/10.1145/3290605.3300830
Tipo de publicación	Artículo de conferencia

Campo	Contenido
Revisión por pares	Sí
Tema y origen	K · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Identificar necesidades de practicantes para ML más justo
Datos o población	35 entrevistas y 267 encuestados
Técnica	Entrevistas y encuesta
Variables o características	Retos de equipos de producto
Métricas	Cualitativo
Resultados relevantes (evidencia)	Desajuste entre retos reales y soluciones de investigación
Limitaciones	Empresas de tecnología
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Planificar recolección de datos de auditoría desde el diseño
Nivel de confianza	MODERADA

S51 — Rudin (2019)

Campo	Contenido
Referencia	Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence. https://doi.org/10.1038/s42256-019-0048-x
Año	2019
Autores	Rudin, C.
Revista o conferencia	Nature Machine Intelligence
DOI / URL	https://doi.org/10.1038/s42256-019-0048-x
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	J · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Argumentar contra explicar cajas negras en decisiones de alto impacto (sin resumen disponible; descripción general)
Datos o población	Ensayo
Técnica	Análisis
Variables o características	Modelos interpretables
Métricas	Cualitativo
Resultados relevantes (evidencia)	Recomienda modelos interpretables en lugar de explicaciones post hoc en alto impacto
Limitaciones	Posición
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta: selección es alto impacto
Decisión que respalda (decisión de ingeniería)	Preferir modelos/reglas interpretables
Nivel de confianza	MODERADA

S52 — Ribeiro et al. (2016)

Campo	Contenido
Referencia	Ribeiro, M. T., Singh, S. y Guestrin, C. (2016). "Why Should I Trust You?". Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. https://doi.org/10.1145/2939672.2939778
Año	2016
Autores	Ribeiro, M. T., Singh, S. y Guestrin, C.
Revista o conferencia	Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining

Campo	Contenido
DOI / URL	https://doi.org/10.1145/2939672.2939778
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	J · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Explicar predicciones de cualquier clasificador (LIME)
Datos o población	Experimentos con usuarios
Técnica	LIME
Variables o características	Explicaciones locales
Métricas	Confianza del usuario
Resultados relevantes (evidencia)	Explicaciones locales ayudan a evaluar la confianza
Limitaciones	Explicaciones aproximadas e inestables
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Baja
Decisión que respalda (decisión de ingeniería)	No usar LIME como explicación al usuario final
Nivel de confianza	MODERADA

S53 — Lundberg y Lee (2017)

Campo	Contenido
Referencia	Lundberg, S. y Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. arXiv. https://doi.org/10.48550/arXiv.1705.07874
Año	2017
Autores	Lundberg, S. y Lee, S. I.
Revista o conferencia	arXiv
DOI / URL	https://doi.org/10.48550/arXiv.1705.07874
Tipo de publicación	Preprint (arXiv)
Revisión por pares	No (preprint); publicado en NeurIPS 2017
Tema y origen	J · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Unificar métodos de atribución (SHAP)
Datos o población	Teórico y experimentos
Técnica	Valores de Shapley
Variables o características	Importancia por característica
Métricas	Consistencia
Resultados relevantes (evidencia)	Marco unificado de importancia aditiva
Limitaciones	Asume independencia en algunas variantes; costo
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	SHAP solo para depuración interna si hubiera modelo
Nivel de confianza	MODERADA

S54 — Wachter et al. (2017)

Campo	Contenido
Referencia	Wachter, S., Mittelstadt, B. y Russell, C. (2017). Counterfactual Explanations Without Opening the Black Box: Automated Decisions and the GDPR. SSRN Electronic Journal. https://doi.org/10.2139/ssrn.3063289
Año	2017
Autores	Wachter, S., Mittelstadt, B. y Russell, C.
Revista o conferencia	SSRN Electronic Journal

Campo	Contenido
DOI / URL	https://doi.org/10.2139/ssrn.3063289
Tipo de publicación	Documento de trabajo (SSRN)
Revisión por pares	No (documento de trabajo en SSRN); publicado luego en Harvard Journal of Law & Technology
Tema y origen	J · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer explicaciones contrafactuales (sin resumen disponible; descripción general)
Datos o población	Análisis jurídico-técnico
Técnica	Contrafactuales
Variables o características	Cambios mínimos
Métricas	Cualitativo
Resultados relevantes (evidencia)	Explicar qué cambio mínimo alteraría el resultado sin abrir la caja negra
Limitaciones	Puede sugerir cambios no accionables
Riesgos de sesgo	Atributos protegidos
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Explicar por criterios y evidencia faltante
Nivel de confianza	MODERADA

S55 — Miller (2019)

Campo	Contenido
Referencia	Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. Artificial Intelligence. https://doi.org/10.1016/j.artint.2018.07.007
Año	2019
Autores	Miller, T.
Revista o conferencia	Artificial Intelligence
DOI / URL	https://doi.org/10.1016/j.artint.2018.07.007
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	J · búsqueda J
Avisos de Crossref	ninguno
Objetivo	Aportar la perspectiva de ciencias sociales sobre explicaciones (sin resumen disponible; descripción general)
Datos o población	Revisión
Técnica	Revisión
Variables o características	Explicaciones contrastivas y sociales
Métricas	Cualitativo
Resultados relevantes (evidencia)	Las personas prefieren explicaciones contrastivas, selectivas y sociales
Limitaciones	Revisión
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Explicar «por qué este nivel y no otro» con evidencia
Nivel de confianza	MODERADA

S56 — Bhatt et al. (2020)

Campo	Contenido
Referencia	Bhatt, U., Xiang, A., Sharma, S., Weller, A., Taly, A., Jia, Y. et al. (2020). Explainable machine learning in deployment. Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3351095.3375624
Año	2020
Autores	Bhatt, U., Xiang, A., Sharma, S., Weller, A., Taly, A., Jia, Y. et al.

Campo	Contenido
Revista o conferencia	Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3351095.3375624
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	J · búsqueda P
Avisos de Crossref	ninguno
Objetivo	Estudiar cómo se usa la explicabilidad en organizaciones
Datos o población	Entrevistas en organizaciones
Técnica	Estudio cualitativo
Variables o características	Usos de explicaciones
Métricas	Cualitativo
Resultados relevantes (evidencia)	La mayoría de despliegues sirven a ingenieros para depurar, no a los afectados
Limitaciones	Muestra limitada
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Diseñar explicaciones para el evaluador humano y el postulante
Nivel de confianza	MODERADA

S57 — Green y Chen (2019)

Campo	Contenido
Referencia	Green, B. y Chen, Y. (2019). Disparate Interactions. Proceedings of the Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3287560.3287563
Año	2019
Autores	Green, B. y Chen, Y.
Revista o conferencia	Proceedings of the Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3287560.3287563
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	M · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Estudiar cómo las personas usan evaluaciones de riesgo
Datos o población	Experimento en línea
Técnica	Experimento controlado
Variables o características	Predicciones de riesgo
Métricas	Exactitud y disparidad
Resultados relevantes (evidencia)	Las personas rindieron menos que el algoritmo, no evaluaron bien su exactitud y mostraron «interacciones dispares» por raza
Limitaciones	Participantes en línea
Riesgos de sesgo	Disparidad en la interacción
Aplicabilidad al caso (inferencia del equipo)	Muy alta
Decisión que respalda (decisión de ingeniería)	Evaluar el sistema socio-técnico completo, no solo el modelo
Nivel de confianza	MODERADA

S58 — Bansal et al. (2021)

Campo	Contenido
Referencia	Bansal, G., Wu, T., Zhou, J., Fok, R., Nushi, B., Kamar, E. et al. (2021). Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance. Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3411764.3445717
Año	2021

Campo	Contenido
Autores	Bansal, G., Wu, T., Zhou, J., Fok, R., Nushi, B., Kamar, E. et al.
Revista o conferencia	Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems
DOI / URL	https://doi.org/10.1145/3411764.3445717
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	M · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Medir si las explicaciones producen desempeño complementario
Datos o población	Estudios con usuarios en 3 datasets
Técnica	Experimentos mixtos
Variables o características	Explicaciones de IA
Métricas	Exactitud del equipo
Resultados relevantes (evidencia)	Las explicaciones no aumentaron el desempeño complementario; aumentaron la aceptación de la recomendación sea correcta o no
Limitaciones	Tareas de laboratorio
Riesgos de sesgo	Sobredependencia
Aplicabilidad al caso (inferencia del equipo)	Muy alta
Decisión que respalda (decisión de ingeniería)	Una explicación no garantiza control humano; evitar recomendar un candidato
Nivel de confianza	MODERADA

S59 — Vasconcelos et al. (2023)

Campo	Contenido
Referencia	Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S. y Krishna, R. (2023). Explanations Can Reduce Overreliance on AI Systems During Decision-Making. Proceedings of the ACM on Human-Computer Interaction. https://doi.org/10.1145/3579605
Año	2023
Autores	Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S. y Krishna, R.
Revista o conferencia	Proceedings of the ACM on Human-Computer Interaction
DOI / URL	https://doi.org/10.1145/3579605
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	M · búsqueda M
Avisos de Crossref	ninguno
Objetivo	Explicar cuándo las explicaciones reducen la sobredependencia
Datos o población	Experimentos
Técnica	Marco costo-beneficio
Variables o características	Costo de verificar la explicación
Métricas	Sobredependencia
Resultados relevantes (evidencia)	Hay escenarios en que las explicaciones sí reducen la sobredependencia, si verificarlas cuesta poco
Limitaciones	Tareas controladas
Riesgos de sesgo	Sobredependencia
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Explicaciones fáciles de verificar contra evidencia citada
Nivel de confianza	MODERADA

S60 — Vaccaro et al. (2024)

Campo	Contenido
Referencia	Vaccaro, M., Almaatouq, A. y Malone, T. (2024). When combinations of humans and AI are useful: A systematic review and meta-analysis. Nature Human Behaviour. https://doi.org/10.1038/s41562-024-02024-1
Año	2024
Autores	Vaccaro, M., Almaatouq, A. y Malone, T.
Revista o conferencia	Nature Human Behaviour
DOI / URL	https://doi.org/10.1038/s41562-024-02024-1
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	M · búsqueda M
Avisos de Crossref	ninguno
Objetivo	Metaanalizar cuándo humano + IA supera a cada uno
Datos o población	106 experimentos; 370 tamaños de efecto
Técnica	Metaanálisis preregistrado
Variables o características	Tipo de tarea y desempeño relativo
Métricas	g de Hedges
Resultados relevantes (evidencia)	En promedio la combinación rindió peor que el mejor de los dos ($g = -0,23$); pérdidas en tareas de decisión
Limitaciones	Posible sesgo de publicación
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Muy alta
Decisión que respalda (decisión de ingeniería)	No asumir que la recomendación de IA mejora la decisión de selección
Nivel de confianza	FUERTE

S61 — Alon-Barkat y Busuioc (2022)

Campo	Contenido
Referencia	Alon-Barkat, S. y Busuioc, M. (2022). Human–AI Interactions in Public Sector Decision Making: “Automation Bias” and “Selective Adherence” to Algorithmic Advice. Journal of Public Administration Research and Theory. https://doi.org/10.1093/jopart/muac007
Año	2022
Autores	Alon-Barkat, S. y Busuioc, M.
Revista o conferencia	Journal of Public Administration Research and Theory
DOI / URL	https://doi.org/10.1093/jopart/muac007
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	M · búsqueda M
Avisos de Crossref	ninguno
Objetivo	Medir sesgo de automatización y adherencia selectiva en el sector público
Datos o población	3 experimentos (N = 605, 904, 1345)
Técnica	Experimentos
Variables o características	Fuente del consejo y estereotipos
Métricas	Adherencia
Resultados relevantes (evidencia)	No se encontró sesgo de automatización; sí adherencia selectiva a consejos alineados con estereotipos en el estudio 2
Limitaciones	Países Bajos
Riesgos de sesgo	Estereotipos
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Vigilar adherencia selectiva, no solo sobredependencia
Nivel de confianza	CONFLICTIVA

S62 — Amershi et al. (2019)

Campo	Contenido
Referencia	Amershi, S., Weld, D., Vorvoreanu, M., Fournay, A., Nushi, B., Collisson, P. et al. (2019). Guidelines for Human-AI Interaction. Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3290605.3300233
Año	2019
Autores	Amershi, S., Weld, D., Vorvoreanu, M., Fournay, A., Nushi, B., Collisson, P. et al.
Revista o conferencia	Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems
DOI / URL	https://doi.org/10.1145/3290605.3300233
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	M · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer guías de interacción humano-IA
Datos o población	Evaluación con 49 profesionales y 20 productos
Técnica	Diseño validado
Variables o características	18 guías
Métricas	Cumplimiento
Resultados relevantes (evidencia)	18 guías validadas para interacción con IA
Limitaciones	Productos de consumo
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta para F40
Decisión que respalda (decisión de ingeniería)	Mostrar qué hace y qué no hace el sistema; permitir corregirlo
Nivel de confianza	MODERADA

S63 — Parasuraman y Manzey (2010)

Campo	Contenido
Referencia	Parasuraman, R. y Manzey, D. H. (2010). Complacency and Bias in Human Use of Automation: An Attentional Integration. Human Factors: The Journal of the Human Factors and Ergonomics Society. https://doi.org/10.1177/0018720810376055
Año	2010
Autores	Parasuraman, R. y Manzey, D. H.
Revista o conferencia	Human Factors: The Journal of the Human Factors and Ergonomics Society
DOI / URL	https://doi.org/10.1177/0018720810376055
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	M · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Integrar la evidencia sobre complacencia y sesgo de automatización
Datos o población	Revisión de estudios
Técnica	Revisión y modelo teórico
Variables o características	Carga de tareas, atención
Métricas	Cualitativo
Resultados relevantes (evidencia)	El sesgo de automatización produce errores de omisión y comisión; afecta a novatos y expertos
Limitaciones	Automatización en general
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Diseñar para revisión activa, no aprobación pasiva
Nivel de confianza	MODERADA

S64 — Niculescu-Mizil y Caruana (2005)

Campo	Contenido
Referencia	Niculescu-Mizil, A. y Caruana, R. (2005). Predicting good probabilities with supervised learning. Proceedings of the 22nd international conference on Machine learning - ICML '05. https://doi.org/10.1145/1102351.1102430
Año	2005
Autores	Niculescu-Mizil, A. y Caruana, R.
Revista o conferencia	Proceedings of the 22nd international conference on Machine learning - ICML '05
DOI / URL	https://doi.org/10.1145/1102351.1102430
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	N · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Comparar la calidad probabilística de distintos algoritmos
Datos o población	Varios datasets
Técnica	Experimentos
Variables o características	Probabilidades predichas
Métricas	Calibración
Resultados relevantes (evidencia)	Algunos modelos distorsionan probabilidades; Platt e isotónica las corrigen
Limitaciones	Datasets clásicos
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Calibrar y verificar probabilidades si se reportan
Nivel de confianza	FUERTE

S65 — Guo et al. (2017)

Campo	Contenido
Referencia	Guo, C., Pleiss, G., Sun, Y. y Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. arXiv. https://doi.org/10.48550/arXiv.1706.04599
Año	2017
Autores	Guo, C., Pleiss, G., Sun, Y. y Weinberger, K. Q.
Revista o conferencia	arXiv
DOI / URL	https://doi.org/10.48550/arXiv.1706.04599
Tipo de publicación	Preprint (arXiv)
Revisión por pares	No (preprint); publicado en ICML 2017
Tema y origen	N · búsqueda N
Avisos de Crossref	ninguno
Objetivo	Estudiar la calibración de redes modernas
Datos o población	Imagen y texto
Técnica	Experimentos
Variables o características	Profundidad, regularización
Métricas	ECE
Resultados relevantes (evidencia)	Las redes modernas están mal calibradas; el escalado de temperatura ayuda
Limitaciones	Redes profundas
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Baja
Decisión que respalda (decisión de ingeniería)	No reportar «confianza» sin calibrarla
Nivel de confianza	MODERADA

S66 — Brier (1950)

Campo	Contenido
Referencia	Brier, G. W. (1950). VERIFICATION OF FORECASTS EXPRESSED IN TERMS OF PROBABILITY. Monthly Weather Review. <a href="https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2">https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
Año	1950
Autores	Brier, G. W.
Revista o conferencia	Monthly Weather Review
DOI / URL	<a href="https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2">https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	N · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer la verificación de pronósticos probabilísticos (puntaje de Brier) (sin resumen disponible; descripción general)
Datos o población	Método
Técnica	Estadística
Variables o características	Pronósticos probabilísticos
Métricas	Puntaje de Brier
Resultados relevantes (evidencia)	Medida de exactitud probabilística
Limitaciones	Antiguo
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Usar Brier si se reportan probabilidades
Nivel de confianza	FUERTE

S67 — Silva Filho et al. (2023)

Campo	Contenido
Referencia	Silva Filho, T., Song, H., Perello-Nieto, M., Santos-Rodriguez, R., Kull, M. y Flach, P. (2023). Classifier calibration: a survey on how to assess and improve predicted class probabilities. Machine Learning. https://doi.org/10.1007/s10994-023-06336-7
Año	2023
Autores	Silva Filho, T., Song, H., Perello-Nieto, M., Santos-Rodriguez, R., Kull, M. y Flach, P.
Revista o conferencia	Machine Learning
DOI / URL	https://doi.org/10.1007/s10994-023-06336-7
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	N · búsqueda N
Avisos de Crossref	ninguno
Objetivo	Revisar la calibración de clasificadores
Datos o población	Revisión
Técnica	Tutorial y revisión
Variables o características	Métodos de calibración
Métricas	Varias
Resultados relevantes (evidencia)	Introducción y panorama de principios y práctica
Limitaciones	Revisión
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Guía para F39
Nivel de confianza	MODERADA

S68 — Saito y Rehmsmeier (2015)

Campo	Contenido
Referencia	Saito, T. y Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE. https://doi.org/10.1371/journal.pone.0118432
Año	2015
Autores	Saito, T. y Rehmsmeier, M.
Revista o conferencia	PLOS ONE
DOI / URL	https://doi.org/10.1371/journal.pone.0118432
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	N · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Comparar curvas ROC y PR en datos desbalanceados
Datos o población	Simulación y estudios
Técnica	Análisis
Variables o características	Desbalance de clases
Métricas	ROC, PR
Resultados relevantes (evidencia)	Las curvas PR son más informativas que ROC con desbalance
Limitaciones	Bioinformática
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Preferir PR-AUC con clases desbalanceadas
Nivel de confianza	MODERADA

S69 — Järvelin y Kekäläinen (2002)

Campo	Contenido
Referencia	Järvelin, K. y Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems. https://doi.org/10.1145/582415.582418
Año	2002
Autores	Järvelin, K. y Kekäläinen, J.
Revista o conferencia	ACM Transactions on Information Systems
DOI / URL	https://doi.org/10.1145/582415.582418
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	N · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer medidas de ganancia acumulada (DCG/NDCG)
Datos o población	Experimentos de recuperación
Técnica	Métricas
Variables o características	Relevancia graduada
Métricas	DCG, NDCG
Resultados relevantes (evidencia)	Medidas para evaluar rankings con relevancia graduada
Limitaciones	Recuperación de información
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	NDCG solo si existe un juicio de relevancia válido
Nivel de confianza	FUERTE

S70 — Hüllermeier y Waegeman (2021)

Campo	Contenido
Referencia	Hüllermeier, E. y Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods. Machine Learning. https://doi.org/10.1007/s10994-021-05946-3
Año	2021
Autores	Hüllermeier, E. y Waegeman, W.
Revista o conferencia	Machine Learning
DOI / URL	https://doi.org/10.1007/s10994-021-05946-3
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	N · búsqueda N
Avisos de Crossref	ninguno
Objetivo	Introducir incertidumbre aleatoria y epistémica
Datos o población	Revisión
Técnica	Tutorial
Variables o características	Tipos de incertidumbre
Métricas	Varias
Resultados relevantes (evidencia)	Distingue incertidumbre aleatoria y epistémica y sus métodos
Limitaciones	Revisión
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Representar «evidencia insuficiente» como incertidumbre epistémica explícita
Nivel de confianza	MODERADA

S71 — Mitchell et al. (2019)

Campo	Contenido
Referencia	Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B. et al. (2019). Model Cards for Model Reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3287560.3287596
Año	2019
Autores	Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B. et al.
Revista o conferencia	Proceedings of the Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3287560.3287596
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	P · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer model cards
Datos o población	Propuesta con ejemplos
Técnica	Documentación
Variables o características	Uso previsto, métricas por grupo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Documentación estándar de modelos con evaluación por subgrupo
Limitaciones	Propuesta
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta (ya usada en RF-29)
Decisión que respalda (decisión de ingeniería)	Exigir model card en F36
Nivel de confianza	MODERADA

S72 — Gebru et al. (2021)

Campo	Contenido
Referencia	Gebu, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Iii, H. D. et al. (2021). Datasheets for datasets. Communications of the ACM. https://doi.org/10.1145/3458723
Año	2021
Autores	Gebu, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Iii, H. D. et al.
Revista o conferencia	Communications of the ACM
DOI / URL	https://doi.org/10.1145/3458723
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	P · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer datasheets for datasets
Datos o población	Propuesta
Técnica	Documentación
Variables o características	Motivación, composición, recolección
Métricas	Cualitativo
Resultados relevantes (evidencia)	Documentación estándar de conjuntos de datos
Limitaciones	Propuesta
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Exigir dataset card en F34
Nivel de confianza	MODERADA

S73 — Raji et al. (2020)

Campo	Contenido
Referencia	Raji, I. D., Smart, A., White, R. N., Mitchell, M., Gebu, T., Hutchinson, B. et al. (2020). Closing the AI accountability gap. Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3351095.3372873
Año	2020
Autores	Raji, I. D., Smart, A., White, R. N., Mitchell, M., Gebu, T., Hutchinson, B. et al.
Revista o conferencia	Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3351095.3372873
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	P · búsqueda L
Avisos de Crossref	ninguno
Objetivo	Proponer un marco de auditoría algorítmica interna
Datos o población	Marco
Técnica	Proceso de auditoría
Variables o características	Artefactos de auditoría
Métricas	Cualitativo
Resultados relevantes (evidencia)	Auditoría interna de extremo a extremo antes del despliegue
Limitaciones	Marco
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Auditoría interna documentada antes de F39
Nivel de confianza	MODERADA

S74 — Kaufman et al. (2012)

Campo	Contenido
Referencia	Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining. ACM Transactions on Knowledge Discovery from Data. https://doi.org/10.1145/2382577.2382579
Año	2012
Autores	Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O.
Revista o conferencia	ACM Transactions on Knowledge Discovery from Data
DOI / URL	https://doi.org/10.1145/2382577.2382579
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	O · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Formalizar la fuga de datos (leakage)
Datos o población	Casos y competencias
Técnica	Análisis
Variables o características	Información del objetivo
Métricas	Cualitativo
Resultados relevantes (evidencia)	Taxonomía de fugas y cómo evitarlas
Limitaciones	Casos
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Particiones temporales y por proceso (ya aplicado en RF-29)
Nivel de confianza	FUERTE

S75 — Gama et al. (2014)

Campo	Contenido
Referencia	Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. y Bouchachia, A. (2014). A survey on concept drift adaptation. ACM Computing Surveys. https://doi.org/10.1145/2523813
Año	2014
Autores	Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. y Bouchachia, A.
Revista o conferencia	ACM Computing Surveys
DOI / URL	https://doi.org/10.1145/2523813
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	O · búsqueda O
Avisos de Crossref	ninguno
Objetivo	Revisar la adaptación a la deriva de concepto
Datos o población	Revisión
Técnica	Revisión
Variables o características	Deriva
Métricas	Varias
Resultados relevantes (evidencia)	Categoriza estrategias y evaluación
Limitaciones	Aprendizaje en línea
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Monitorear deriva entre convocatorias
Nivel de confianza	MODERADA

S76 — Breck et al. (2017)

Campo	Contenido
Referencia	Breck, E., Cai, S., Nielsen, E., Salib, M. y Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. 2017 IEEE International Conference on Big Data (Big Data). https://doi.org/10.1109/BigData.2017.8258038
Año	2017
Autores	Breck, E., Cai, S., Nielsen, E., Salib, M. y Sculley, D.
Revista o conferencia	2017 IEEE International Conference on Big Data (Big Data)
DOI / URL	https://doi.org/10.1109/BigData.2017.8258038
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	O · bola de nieve
Avisos de Crossref	ninguno
Objetivo	Proponer pruebas de preparación para producción de ML
Datos o población	Experiencia industrial
Técnica	Rúbrica
Variables o características	28 pruebas y monitoreo
Métricas	Puntaje
Resultados relevantes (evidencia)	28 pruebas concretas para reducir deuda técnica
Limitaciones	Experiencia de una empresa
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Usar la rúbrica como lista de F38–F39
Nivel de confianza	MODERADA

S77 — Kreuzberger et al. (2023)

Campo	Contenido
Referencia	Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. IEEE Access. https://doi.org/10.1109/access.2023.3262138
Año	2023
Autores	Kreuzberger, D., Kühl, N. y Hirschl, S.
Revista o conferencia	IEEE Access
DOI / URL	https://doi.org/10.1109/access.2023.3262138
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	O · búsqueda O
Avisos de Crossref	ninguno
Objetivo	Definir MLOps
Datos o población	Revisión, herramientas y entrevistas
Técnica	Métodos mixtos
Variables o características	Prácticas y roles
Métricas	Cualitativo
Resultados relevantes (evidencia)	Definición y arquitectura de MLOps
Limitaciones	Revisión
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Versionado y registro mínimos, no una plataforma completa
Nivel de confianza	MODERADA

S78 — Paleyes et al. (2022)

Campo	Contenido
Referencia	Paley, A., Urma, R. G. y Lawrence, N. D. (2022). Challenges in Deploying Machine Learning: A Survey of Case Studies. ACM Computing Surveys. https://doi.org/10.1145/3533378
Año	2022
Autores	Paley, A., Urma, R. G. y Lawrence, N. D.
Revista o conferencia	ACM Computing Surveys
DOI / URL	https://doi.org/10.1145/3533378
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	O · búsqueda O
Avisos de Crossref	ninguno
Objetivo	Revisar retos de desplegar ML
Datos o población	Casos publicados
Técnica	Revisión
Variables o características	Etapas de despliegue
Métricas	Cualitativo
Resultados relevantes (evidencia)	Hay problemas en cada etapa del despliegue
Limitaciones	Reportes publicados
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Planificar despliegue y monitoreo desde F33
Nivel de confianza	MODERADA

S79 — Hutchinson et al. (2021)

Campo	Contenido
Referencia	Hutchinson, B., Smart, A., Hanna, A., Denton, R., Greer, C., Kjartansson, O. et al. (2021). Towards Accountability for Machine Learning Datasets: Practices from Software Engineering and Infrastructure. Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3442188.3445918
Año	2021
Autores	Hutchinson, B., Smart, A., Hanna, A., Denton, R., Greer, C., Kjartansson, O. et al.
Revista o conferencia	Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3442188.3445918
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	P · búsqueda P
Avisos de Crossref	ninguno
Objetivo	Proponer rendición de cuentas para datasets
Datos o población	Marco
Técnica	Ingeniería de software
Variables o características	Ciclo de vida del dataset
Métricas	Cualitativo
Resultados relevantes (evidencia)	Marco de transparencia para el desarrollo de datasets
Limitaciones	Marco
Riesgos de sesgo	No aplica
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Requisitos y revisiones del dataset como artefactos versionados
Nivel de confianza	MODERADA

S80 — Giermindl et al. (2021)

Campo	Contenido
Referencia	Giermindl, L. M., Strich, F., Christ, O., Leicht-Deobald, U. y Redzepi, A. (2021). The dark sides of people analytics: reviewing the perils for organisations and employees. European Journal of Information Systems. https://doi.org/10.1080/0960085x.2021.1927213
Año	2021
Autores	Giermindl, L. M., Strich, F., Christ, O., Leicht-Deobald, U. y Redzepi, A.
Revista o conferencia	European Journal of Information Systems
DOI / URL	https://doi.org/10.1080/0960085x.2021.1927213
Tipo de publicación	Artículo de revista
Revisión por pares	Si
Tema y origen	Q · búsqueda Q
Avisos de Crossref	ninguno
Objetivo	Revisar los riesgos de la analítica de personas
Datos o población	Revisión teórica
Técnica	Revisión
Variables o características	Riesgos
Métricas	Cualitativo
Resultados relevantes (evidencia)	Identifica peligros para organizaciones y empleados
Limitaciones	Teórico
Riesgos de sesgo	Vigilancia, discriminación
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Minimizar datos y propósito limitado
Nivel de confianza	MODERADA

S81 — Koenecke et al. (2024)

Campo	Contenido
Referencia	Koenecke, A., Choi, A. S. G., Mei, K. X., Schellmann, H. y Sloane, M. (2024). Careless Whisper: Speech-to-Text Hallucination Harms. The 2024 ACM Conference on Fairness, Accountability, and Transparency. https://doi.org/10.1145/3630106.3658996
Año	2024
Autores	Koenecke, A., Choi, A. S. G., Mei, K. X., Schellmann, H. y Sloane, M.
Revista o conferencia	The 2024 ACM Conference on Fairness, Accountability, and Transparency
DOI / URL	https://doi.org/10.1145/3630106.3658996
Tipo de publicación	Artículo de conferencia
Revisión por pares	Si
Tema y origen	S · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Medir alucinaciones de Whisper
Datos o población	Audio de hablantes con afasia y control
Técnica	Auditoría
Variables o características	Duración no vocal
Métricas	Tasa de alucinación
Resultados relevantes (evidencia)	Cerca del 1 % de transcripciones contenía frases inventadas; el 38 % de ellas con daños explícitos; más frecuentes con pausas largas
Limitaciones	Versión 2023
Riesgos de sesgo	Afecta más a ciertos hablantes
Aplicabilidad al caso (inferencia del equipo)	Muy alta: una transcripción puede inventar «evidencia»
Decisión que respalda (decisión de ingeniería)	Toda transcripción se revisa contra el audio antes de usarse como evidencia
Nivel de confianza	MODERADA

S82 — Thompson et al. (2023)

Campo	Contenido
Referencia	Thompson, I., Koenig, N., Mracek, D. L. y Tonidandel, S. (2023). Deep Learning in Employee Selection: Evaluation of Algorithms to Automate the Scoring of Open-Ended Assessments. Journal of Business and Psychology. https://doi.org/10.1007/s10869-023-09874-y
Año	2023
Autores	Thompson, I., Koenig, N., Mracek, D. L. y Tonidandel, S.
Revista o conferencia	Journal of Business and Psychology
DOI / URL	https://doi.org/10.1007/s10869-023-09874-y
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	T · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Evaluar algoritmos para calificar respuestas abiertas en selección (sin resumen disponible; descripción general)
Datos o población	Respuestas de evaluaciones de selección
Técnica	Deep learning
Variables o características	Texto de respuestas
Métricas	Acuerdo con calificadores humanos
Resultados relevantes (evidencia)	Ver la publicación (resumen no disponible)
Limitaciones	Ver la publicación
Riesgos de sesgo	Sesgo de los calificadores de entrenamiento
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Solo como antecedente; no adoptar calificación automática
Nivel de confianza	INSUFICIENTE

S83 — Armstrong et al. (2024)

Campo	Contenido
Referencia	Armstrong, L., Liu, A., MacNeil, S. y Metaxa, D. (2024). The Silicon Ceiling: Auditing GPT's Race and Gender Biases in Hiring. Proceedings of the 4th ACM Conference on Equity and Access in Algorithms, Mechanisms, and Optimization. https://doi.org/10.1145/3689904.3694699
Año	2024
Autores	Armstrong, L., Liu, A., MacNeil, S. y Metaxa, D.
Revista o conferencia	Proceedings of the 4th ACM Conference on Equity and Access in Algorithms, Mechanisms, and Optimization
DOI / URL	https://doi.org/10.1145/3689904.3694699
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	E · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Auditar sesgos de GPT-3.5 en contratación
Datos o población	32 nombres, 10 ocupaciones, 3 tareas
Técnica	Auditoría por nombres
Variables o características	Raza y género
Métricas	Puntuaciones
Resultados relevantes (evidencia)	El modelo refleja sesgos estereotípicos al evaluar y al generar CV
Limitaciones	Un modelo y versión
Riesgos de sesgo	Estereotipos
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	No pedir a un LLM que puntúe candidatos

Campo	Contenido
Nivel de confianza	MODERADA

S84 — Wilson et al. (2025)

Campo	Contenido
Referencia	Wilson, K., Sim, M., Gueorgieva, A. M. y Caliskan, A. (2025). No Thoughts Just AI: Biased LLM Hiring Recommendations Alter Human Decision Making and Limit Human Autonomy. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society. https://doi.org/10.1609/aies.v8i3.36749
Año	2025
Autores	Wilson, K., Sim, M., Gueorgieva, A. M. y Caliskan, A.
Revista o conferencia	Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society
DOI / URL	https://doi.org/10.1609/aies.v8i3.36749
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	M · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Medir el efecto de recomendaciones sesgadas de IA en decisiones humanas de contratación
Datos o población	N = 528; 1526 escenarios; 16 ocupaciones
Técnica	Experimento de cribado con IA simulada
Variables o características	Preferencias raciales de la IA, IAT, alfabetización en IA
Métricas	Tasa de selección por grupo
Resultados relevantes (evidencia)	Sin IA o con IA sin sesgo, las personas seleccionaron por igual; con IA sesgada la siguieron hasta en el 90 % de los casos, incluso juzgándola de baja calidad
Limitaciones	IA simulada; EE. UU.
Riesgos de sesgo	Sesgo transmitido a la persona
Aplicabilidad al caso (inferencia del equipo)	Muy alta: cuestiona el «humano en el circuito» como salvaguarda
Decisión que respalda (decisión de ingeniería)	No mostrar recomendación de candidato junto a la decisión (refuerza ADR-001)
Nivel de confianza	FUERTE

S85 — Booth et al. (2021)

Campo	Contenido
Referencia	Booth, B. M., Hickman, L., Subburaj, S. K., Tay, L., Woo, S. E. y D'Mello, S. K. (2021). Bias and Fairness in Multimodal Machine Learning: A Case Study of Automated Video Interviews. Proceedings of the 2021 International Conference on Multimodal Interaction. https://doi.org/10.1145/3462244.3479897
Año	2021
Autores	Booth, B. M., Hickman, L., Subburaj, S. K., Tay, L., Woo, S. E. y D'Mello, S. K.
Revista o conferencia	Proceedings of the 2021 International Conference on Multimodal Interaction
DOI / URL	https://doi.org/10.1145/3462244.3479897
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	T · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Analizar sesgo y equidad en entrevistas en vídeo multimodales
Datos o población	733 participantes; anotadores entrenados
Técnica	Modelos interpretables multimodales
Variables o características	Rasgos verbales, paraverbales, visuales
Métricas	Exactitud, sesgo, equidad
Resultados relevantes (evidencia)	Combinar modalidades apenas mejora la exactitud y aumenta el sesgo; lo verbal solo rinde casi igual
Limitaciones	Contratación simulada
Riesgos de sesgo	Rasgos visuales y paraverbales

Campo	Contenido
Aplicabilidad al caso (inferencia del equipo)	Muy alta
Decisión que respalda (decisión de ingeniería)	Usar solo el contenido verbal; excluir rasgos visuales y paraverbales
Nivel de confianza	MODERADA

S86 — Van Iddekinge et al. (2023)

Campo	Contenido
Referencia	Van Iddekinge, C. H., Lievens, F. y Sackett, P. R. (2023). Personnel selection: A review of ways to maximize validity, diversity, and the applicant experience. <i>Personnel Psychology</i> . https://doi.org/10.1111/peps.12578
Año	2023
Autores	Van Iddekinge, C. H., Lievens, F. y Sackett, P. R.
Revista o conferencia	<i>Personnel Psychology</i>
DOI / URL	https://doi.org/10.1111/peps.12578
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	D · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Revisar decisiones de diseño de selección (validez, diversidad, experiencia)
Datos o población	Revisión
Técnica	Revisión
Variables o características	Desarrollo, administración y puntuación (incluida IA)
Métricas	Cualitativo
Resultados relevantes (evidencia)	Sintetiza efectos de decisiones de diseño sobre validez, diversidad y experiencia del postulante
Limitaciones	Revisión
Riesgos de sesgo	Impacto adverso
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	Explicar el procedimiento al postulante antes de evaluar
Nivel de confianza	MODERADA

S87 — Glazko et al. (2024)

Campo	Contenido
Referencia	Glazko, K., Mohammed, Y., Kosa, B., Potluri, V. y Mankoff, J. (2024). Identifying and Improving Disability Bias in GPT-Based Resume Screening. <i>The 2024 ACM Conference on Fairness Accountability and Transparency</i> . https://doi.org/10.1145/3630106.3658933
Año	2024
Autores	Glazko, K., Mohammed, Y., Kosa, B., Potluri, V. y Mankoff, J.
Revista o conferencia	<i>The 2024 ACM Conference on Fairness Accountability and Transparency</i>
DOI / URL	https://doi.org/10.1145/3630106.3658933
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	E · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Auditar sesgo por discapacidad en cribado de CV con GPT-4
Datos o población	Pares de CV con y sin méritos relacionados con discapacidad
Técnica	Auditoría
Variables o características	Méritos asociados a discapacidad
Métricas	Ranking
Resultados relevantes (evidencia)	GPT-4 mostró prejuicio contra CV con méritos relacionados con discapacidad
Limitaciones	Un modelo

Campo	Contenido
Riesgos de sesgo	Capacitismo
Aplicabilidad al caso (inferencia del equipo)	Alta
Decisión que respalda (decisión de ingeniería)	No usar LLM para ordenar CV
Nivel de confianza	MODERADA

S88 — Bredin (2023)

Campo	Contenido
Referencia	Bredin, H. (2023). pyannote.audio 2.1 speaker diarization pipeline: principle, benchmark, and recipe. INTERSPEECH 2023. https://doi.org/10.21437/interspeech.2023-105
Año	2023
Autores	Bredin, H.
Revista o conferencia	INTERSPEECH 2023
DOI / URL	https://doi.org/10.21437/interspeech.2023-105
Tipo de publicación	Artículo de conferencia
Revisión por pares	Sí
Tema y origen	S · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Describir el pipeline de diarización de pyannote.audio 2.1 (sin resumen disponible; descripción general)
Datos o población	Benchmarks de diarización
Técnica	Segmentación y embeddings de hablante
Variables o características	Audio
Métricas	DER
Resultados relevantes (evidencia)	Pipeline y receta de diarización
Limitaciones	Benchmarks
Riesgos de sesgo	Usa embeddings de voz (dato biométrico)
Aplicabilidad al caso (inferencia del equipo)	Media
Decisión que respalda (decisión de ingeniería)	Preferir canales separados o segmentación manual antes que huellas de voz
Nivel de confianza	MODERADA

S89 — Koenig et al. (2023)

Campo	Contenido
Referencia	Koenig, N., Tonidandel, S., Thompson, I., Albritton, B., Koohifar, F., Yankov, G. et al. (2023). Improving measurement and prediction in personnel selection through the application of machine learning. Personnel Psychology. https://doi.org/10.1111/peps.12608
Año	2023
Autores	Koenig, N., Tonidandel, S., Thompson, I., Albritton, B., Koohifar, F., Yankov, G. et al.
Revista o conferencia	Personnel Psychology
DOI / URL	https://doi.org/10.1111/peps.12608
Tipo de publicación	Artículo de revista
Revisión por pares	Sí
Tema y origen	C · búsqueda complementaria
Avisos de Crossref	ninguno
Objetivo	Presentar seis casos de ML para puntuar respuestas en selección operativa
Datos o población	Seis sistemas operativos en organizaciones
Técnica	ML sobre respuestas escritas y orales
Variables o características	Texto de respuestas
Métricas	Exactitud, fiabilidad, impacto adverso

Campo	Contenido
Resultados relevantes (evidencia)	El ML calificó respuestas tan exacta y fiablemente como jueces humanos, con poco o ningún impacto adverso
Limitaciones	Grandes volúmenes de datos de organizaciones grandes
Riesgos de sesgo	Depende de los calificadores humanos de referencia
Aplicabilidad al caso (inferencia del equipo)	Media: el caso no tiene ese volumen de datos
Decisión que respalda (decisión de ingeniería)	Posible a futuro solo con validación local; en tensión con S84
Nivel de confianza	CONFLICTIVA

4. Normas, documentos oficiales y fuentes secundarias

Para las normas no aplican campos como métricas o población: se registra qué establecen, si aplican al caso y qué decisión motivan. Esto no es asesoría legal: la evaluación de impacto la valida una persona con competencia jurídica.

- **Normas de la UE (O01, O02, O16):** EUR-Lex responde 202 a clientes automáticos; su texto se verificó en la versión oficial del Diario Oficial que sirve la Oficina de Publicaciones de la UE.
- **DS 115-2025-PCM (O13):** la ficha oficial en gob.pe está verificada y el **art. 24.1 e) está corroborado**. El texto de los demás artículos citados (24, incluidos sus incisos b) e i); 23, 25, 28.11, 30 y 31) se leyó en la copia en PDF de la publicación en El Peruano que difunde el portal jurídico LP Derecho. **Requieren contraste artículo por artículo con la publicación normativa oficial antes de producir efectos jurídicos.**

ID	Documento	Qué establece (relevante)	Aplicabilidad	Decisión que motiva	Verificado
O01	Reglamento (UE) 2024/1689 (Ley de IA)	Prohíbe inferir emociones en el trabajo y la educación (art. 5.1.f); clasifica como alto riesgo el reclutamiento y la evaluación de candidatos (Anexo III, 4.a); exige supervisión humana capaz de ignorar o revertir el resultado y consciente del sesgo de automatización (art. 14). Texto contrastado en el Diario Oficial (Oficina de Publicaciones de la UE)	Referencia comparada (no aplica directamente en Perú)	Diseñar como sistema de alto riesgo aunque no se esté obligado	Sí
O02	Reglamento (UE) 2016/679 (RGPD)	Derecho a no ser objeto de decisiones exclusivamente automatizadas (art. 22)	Referencia comparada	Decisión final siempre humana (ya en RF-23)	Sí
O03	NIST AI RMF 1.0	Funciones gobernar, mapear, medir y gestionar riesgos de IA	Marco voluntario	Estructurar el análisis de riesgos de F34–F39	Sí
O04	NIST SP 1270	Identificación y gestión de sesgos en IA (sesgos sistémicos, estadísticos y humanos)	Marco voluntario	Catálogo de sesgos humanos y sistémicos	Sí
O05	ISO/IEC 42001:2023	Sistema de gestión de IA	Norma de pago; referencia	Referencia de gobernanza; sin certificación	Sí

ID	Documento	Qué establece (relevante)	Aplicabilidad	Decisión que motiva	Verificado
O06	ISO/IEC 23894:2023	Gestión de riesgos de IA	Norma de pago; referencia	Referencia de gestión de riesgos	Sí
O07	Principios de IA de la OCDE	Principios de IA confiable	Referencia; el DS 115-2025-PCM los cita	Alineación de principios	Sí
O08	Recomendación de la UNESCO sobre ética de la IA	Principios éticos y supervisión humana	Referencia	Alineación de principios	Sí
O09	DS 016-2024-JUS (reglamento de la Ley 29733)	Protección de datos personales en Perú	Aplica al caso	Base legal, consentimiento, minimización y seguridad de datos de postulantes	Sí
O10	Ley N.º 31814	Promueve el uso de IA en Perú	Aplica	Marco nacional	Sí
O11	29 CFR 1607 (Uniform Guidelines)	Regla de los cuatro quintos como indicio de impacto adverso	Referencia de EE. UU.	Indicador de impacto adverso solo con datos válidos y suficientes	Sí
O12	NYC Local Law 144 (AEDT)	Auditorías de sesgo para herramientas automatizadas de empleo	Referencia de EE. UU.	Antecedente de auditoría independiente	Sí
O13	DS 115-2025-PCM (reglamento de la Ley 31814)	Riesgo alto: determinar selección, evaluación, contratación y cese de postulantes (art. 24.1 e, corroborado). Además, según la lectura de F30 pendiente de contraste con la publicación oficial: evaluación de NNA en educación (24.1 b); inferir emociones en el trabajo o centros educativos (24.1, final del inciso i); transparencia y explicación (art. 25); evaluación de impacto previa (art. 30); registro (art. 31)	Aplica al caso (vigente)	Tratar la visión F33–F40 como riesgo alto. Los arts. 24, 30 y 31 se contrastan artículo por artículo con la publicación normativa oficial antes de producir efectos jurídicos	Sí
O14	Marco de Buen Desempeño Docente (MINEDU, RM 0547-2012-ED)	Dominios, competencias y desempeños del buen docente en Perú	Aplica al caso docente	Fuente candidata de competencias para vacantes docentes, a validar con el colegio	Sí
O15	Ley N.º 29733, Ley de Protección de Datos Personales (2011)	Derecho fundamental a la protección de datos personales: principios de consentimiento, finalidad, proporcionalidad y seguridad; datos sensibles	Aplica al caso (norma primaria; O09 es su reglamento)	Base legal, consentimiento, minimización y seguridad de los datos de postulantes	Sí
O16	Reglamento (UE) 2026/1744 (Digital Omnibus on AI)	Modifica el Reglamento (UE) 2024/1689: los requisitos de alto riesgo (cap. III, secciones 1 a 3) se aplican desde el 2/12/2027 a los sistemas del Anexo III y desde el 2/8/2028 a los del Anexo I; entra en vigor al tercer día de su publicación (DO de 24/7/2026); no modifica la prohibición del art. 5.1.f	Referencia comparada (fuente oficial del calendario)	El calendario de la UE se cita desde esta fuente oficial y no desde X02	Sí

Fuentes secundarias (solo para contrastar, nunca como única base de una afirmación):

ID	Página	Uso
X01	Annex III: High-Risk AI Systems Referred to in Article 6(2) EU Artificial Intelligence Act	Lectura del Anexo III y del art. 5 de la Ley de IA cuando EUR-Lex no entrega el texto a clientes automáticos
X02	EU AI Act Omnibus Agreement — Postponed High-Risk Deadlines and Other Key Changes - Gibson Dunn	Contexto del acuerdo político del Digital Omnibus. Sustituida para fechas por la fuente oficial O16 (Reglamento (UE) 2026/1744), con la que coincide en el aplazamiento al 2/12/2027 de las obligaciones del Anexo III

5. Avisos editoriales y exclusiones

Fuentes incluidas con avisos (corrección o errata; ninguna retractada):

ID	Referencia	Aviso
S08	Barrett et al. (2019)	correction
S21	Koo y Li (2016)	erratum

Fuentes excluidas tras la verificación:

DOI	Tema	Motivo
https://doi.org/10.1057/s41599-023-01787-8	Q	Artículo retractado: Crossref registra una retractación del editor (10.1057/s41599-026-06602-8, 03/02/2026) y el título empieza por «RETRACTED ARTICLE»

F30 — Referencias

Generado por `docs/academico/tools/f30/f30.py` desde `datos/verificacion_fuentes.json` (verificación del 2026-09-30). Autores, año, título y revista salen de Crossref o DataCite, no de memoria. Formato basado en APA 7 (más de seis autores: los seis primeros y «et al.»).

Trabajos científicos

- **[S01]** Raghavan, M., Barocas, S., Kleinberg, J. y Levy, K. (2020). Mitigating bias in algorithmic hiring. Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3351095.3372828>
- **[S02]** Köchling, A. y Wehner, M. C. (2020). Discriminated by an algorithm: a systematic review of discrimination and fairness by algorithmic decision-making in the context of HR recruitment and HR development. Business Research. <https://doi.org/10.1007/s40685-020-00134-w>
- **[S03]** Hunkenschroer, A. L. y Luetge, C. (2022). Ethics of AI-Enabled Recruiting and Selection: A Review and Research Agenda. Journal of Business Ethics. <https://doi.org/10.1007/s10551-022-05049-6>
- **[S04]** Tambe, P., Cappelli, P. y Yakubovich, V. (2019). Artificial Intelligence in Human Resources Management: Challenges and a Path Forward. California Management Review. <https://doi.org/10.1177/0008125619867910>
- **[S05]** Chen, Z. (2023). Ethics and discrimination in artificial intelligence-enabled recruitment practices. Humanities and Social Sciences Communications. <https://doi.org/10.1057/s41599-023-02079-x>
- **[S06]** Langer, M., König, C. J. y Papathanasiou, M. (2019). Highly automated job interviews: Acceptance under the influence of stakes. International Journal of Selection and Assessment. <https://doi.org/10.1111/ijsa.12246>
- **[S07]** Hickman, L., Bosch, N., Ng, V., Saef, R., Tay, L. y Woo, S. E. (2022). Automated video interview personality assessments: Reliability, validity, and generalizability investigations. Journal of Applied Psychology. <https://doi.org/10.1037/apl0000695>
- **[S08]** Barrett, L. F., Adolphs, R., Marsella, S., Martinez, A. M. y Pollak, S. D. (2019). Emotional Expressions Reconsidered: Challenges to Inferring Emotion From Human Facial Movements. Psychological Science in the Public Interest. <https://doi.org/10.1177/1529100619832930>
- **[S09]** Stark, L. y Hoey, J. (2021). The Ethics of Emotion in Artificial Intelligence Systems. Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3442188.3445939>
- **[S10]** Koenecke, A., Nam, A., Lake, E., Nudell, J., Quartey, M., Mengesha, Z. et al. (2020). Racial disparities in automated speech recognition. Proceedings of the National Academy of Sciences. <https://doi.org/10.1073/pnas.1915768117>
- **[S11]** Wilson, K. y Caliskan, A. (2024). Gender, Race, and Intersectional Bias in Resume Screening via Language Model Retrieval. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society. <https://doi.org/10.1609/aies.v7i1.31748>
- **[S12]** Schmidt, F. L. y Hunter, J. E. (1998). The validity and utility of selection methods in personnel psychology: Practical and theoretical implications of 85 years of research findings. Psychological Bulletin. <https://doi.org/10.1037/0033-2909.124.2.262>

- **[S13]** Sackett, P. R., Zhang, C., Berry, C. M. y Lievens, F. (2022). Revisiting meta-analytic estimates of validity in personnel selection: Addressing systematic overcorrection for restriction of range. *Journal of Applied Psychology*. <https://doi.org/10.1037/apl0000994>
- **[S14]** McDaniel, M. A., Whetzel, D. L., Schmidt, F. L. y Maurer, S. D. (1994). The validity of employment interviews: A comprehensive review and meta-analysis. *Journal of Applied Psychology*. <https://doi.org/10.1037/0021-9010.79.4.599>
- **[S15]** Campion, M. A., Palmer, D. K. y Campion, J. E. (1997). A REVIEW OF STRUCTURE IN THE SELECTION INTERVIEW. *Personnel Psychology*. <https://doi.org/10.1111/j.1744-6570.1997.tb00709.x>
- **[S16]** Levashina, J., Hartwell, C. J., Morgeson, F. P. y Campion, M. A. (2013). The Structured Employment Interview: Narrative and Quantitative Review of the Research Literature. *Personnel Psychology*. <https://doi.org/10.1111/peps.12052>
- **[S17]** Campion, M. A., Fink, A. A., Ruggeberg, B. J., Carr, L., Phillips, G. M. y Odman, R. B. (2011). DOING COMPETENCIES WELL: BEST PRACTICES IN COMPETENCY MODELING. *Personnel Psychology*. <https://doi.org/10.1111/j.1744-6570.2010.01207.x>
- **[S18]** Sanchez, J. I. y Levine, E. L. (2012). The Rise and Fall of Job Analysis and the Future of Work Analysis. *Annual Review of Psychology*. <https://doi.org/10.1146/annurev-psych-120710-100401>
- **[S19]** Smith, P. C. y Kendall, L. M. (1963). Retranslation of expectations: An approach to the construction of unambiguous anchors for rating scales. *Journal of Applied Psychology*. <https://doi.org/10.1037/h0047060>
- **[S20]** Shrout, P. E. y Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. *Psychological Bulletin*. <https://doi.org/10.1037/0033-2909.86.2.420>
- **[S21]** Koo, T. K. y Li, M. Y. (2016). A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research. *Journal of Chiropractic Medicine*. <https://doi.org/10.1016/j.jcm.2016.02.012>
- **[S22]** Klassen, R. M. y Kim, L. E. (2019). Selecting teachers and prospective teachers: A meta-analysis. *Educational Research Review*. <https://doi.org/10.1016/j.edurev.2018.12.003>
- **[S23]** Woods, S. A., Ahmed, S., Nikolaou, I., Costa, A. C. y Anderson, N. R. (2019). Personnel selection in the digital age: a review of validity and applicant reactions, and future research challenges. *European Journal of Work and Organizational Psychology*. <https://doi.org/10.1080/1359432x.2019.1681401>
- **[S24]** Huffcutt, A. I., Conway, J. M., Roth, P. L. y Stone, N. J. (2001). Identification and meta-analytic assessment of psychological constructs measured in employment interviews. *Journal of Applied Psychology*. <https://doi.org/10.1037/0021-9010.86.5.897>
- **[S25]** Zhu, C., Zhu, H., Xiong, H., Ma, C., Xie, F., Ding, P. et al. (2018). Person-Job Fit. *ACM Transactions on Management Information Systems*. <https://doi.org/10.1145/3234465>
- **[S26]** Qin, C., Zhu, H., Xu, T., Zhu, C., Jiang, L., Chen, E. et al. (2018). Enhancing Person-Job Fit for Talent Recruitment. *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*. <https://doi.org/10.1145/3209978.3210025>
- **[S27]** Freire, M. N. y de Castro, L. N. (2020). e-Recruitment recommender systems: a systematic review. *Knowledge and Information Systems*. <https://doi.org/10.1007/s10115-020-01522-8>

- **[S28]** Mashayekhi, Y., Li, N., Kang, B., Lijffijt, J. y De Bie, T. (2024). A Challenge-based Survey of E-recruitment Recommendation Systems. *ACM Computing Surveys*. <https://doi.org/10.1145/3659942>
- **[S29]** Zhang, M., Jensen, K., Sonniks, S. y Plank, B. (2022). SkillSpan: Hard and Soft Skill Extraction from English Job Postings. *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. <https://doi.org/10.18653/v1/2022.naacl-main.366>
- **[S30]** Khaouja, I., Kassou, I. y Ghogho, M. (2021). A Survey on Skill Identification From Online Job Ads. *IEEE Access*. <https://doi.org/10.1109/access.2021.3106120>
- **[S31]** Reimers, N. y Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. <https://doi.org/10.18653/v1/D19-1410>
- **[S32]** Blodgett, S. L., Barocas, S., Daumé III, H. y Wallach, H. (2020). Language (Technology) is Power: A Critical Survey of “Bias” in NLP. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. <https://doi.org/10.18653/v1/2020.acl-main.485>
- **[S33]** Bender, E. M. y Friedman, B. (2018). Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science. *Transactions of the Association for Computational Linguistics*. https://doi.org/10.1162/tacl_a_00041
- **[S34]** Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y. et al. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*. <https://doi.org/10.1145/3571730>
- **[S35]** Bender, E. M., Gebru, T., McMillan-Major, A. y Shmitchell, S. (2021). On the Dangers of Stochastic Parrots. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. <https://doi.org/10.1145/3442188.3445922>
- **[S36]** Zheng, L., Chiang, W. L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y. et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *arXiv*. <https://doi.org/10.48550/arXiv.2306.05685>
- **[S37]** Xu, Y., Xu, Y., Lv, T., Cui, L., Wei, F., Wang, G. et al. (2021). LayoutLMv2: Multi-modal Pre-training for Visually-rich Document Understanding. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. <https://doi.org/10.18653/v1/2021.acl-long.201>
- **[S38]** Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C. y Sutskever, I. (2022). Robust Speech Recognition via Large-Scale Weak Supervision. *arXiv*. <https://doi.org/10.48550/arXiv.2212.04356>
- **[S39]** Saaty, T. L. (1990). How to make a decision: The analytic hierarchy process. *European Journal of Operational Research*. [https://doi.org/10.1016/0377-2217\(90\)90057-I](https://doi.org/10.1016/0377-2217(90)90057-I)
- **[S40]** Kelemenis, A. y Askounis, D. (2010). A new TOPSIS-based multi-criteria approach to personnel selection. *Expert Systems with Applications*. <https://doi.org/10.1016/j.eswa.2009.12.013>
- **[S41]** Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K. y Galstyan, A. (2021). A Survey on Bias and Fairness in Machine Learning. *ACM Computing Surveys*. <https://doi.org/10.1145/3457607>

- **[S42]** Barocas, S. y Selbst, A. D. (2016). Big Data's Disparate Impact. *California Law Review*. <https://doi.org/10.15779/Z38BG31>
- **[S43]** Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. *arXiv*. <https://doi.org/10.48550/arXiv.1610.02413>
- **[S44]** Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. *Schloss Dagstuhl – Leibniz-Zentrum für Informatik*. <https://doi.org/10.4230/LIPIcs.ITCS.2017.43>
- **[S45]** Chouldechova, A. (2017). Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments. *Big Data*. <https://doi.org/10.1089/big.2016.0047>
- **[S46]** Friedler, S. A., Scheidegger, C., Venkatasubramanian, S., Choudhary, S., Hamilton, E. P. y Roth, D. (2019). A comparative study of fairness-enhancing interventions in machine learning. *Proceedings of the Conference on Fairness, Accountability, and Transparency*. <https://doi.org/10.1145/3287560.3287589>
- **[S47]** Suresh, H. y Gutttag, J. (2021). A Framework for Understanding Sources of Harm throughout the Machine Learning Life Cycle. *Equity and Access in Algorithms, Mechanisms, and Optimization*. <https://doi.org/10.1145/3465416.3483305>
- **[S48]** Obermeyer, Z., Powers, B., Vogeli, C. y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*. <https://doi.org/10.1126/science.aax2342>
- **[S49]** Bellamy, R. K. E., Dey, K., Hind, M., Hoffman, S. C., Houde, S., Kannan, K. et al. (2019). AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias. *IBM Journal of Research and Development*. <https://doi.org/10.1147/JRD.2019.2942287>
- **[S50]** Holstein, K., Wortman Vaughan, J., Daumé, H., Dudik, M. y Wallach, H. (2019). Improving Fairness in Machine Learning Systems. *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. <https://doi.org/10.1145/3290605.3300830>
- **[S51]** Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*. <https://doi.org/10.1038/s42256-019-0048-x>
- **[S52]** Ribeiro, M. T., Singh, S. y Guestrin, C. (2016). "Why Should I Trust You?". *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. <https://doi.org/10.1145/2939672.2939778>
- **[S53]** Lundberg, S. y Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *arXiv*. <https://doi.org/10.48550/arXiv.1705.07874>
- **[S54]** Wachter, S., Mittelstadt, B. y Russell, C. (2017). Counterfactual Explanations Without Opening the Black Box: Automated Decisions and the GDPR. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.3063289>
- **[S55]** Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. *Artificial Intelligence*. <https://doi.org/10.1016/j.artint.2018.07.007>
- **[S56]** Bhatt, U., Xiang, A., Sharma, S., Weller, A., Taly, A., Jia, Y. et al. (2020). Explainable machine learning in deployment. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. <https://doi.org/10.1145/3351095.3375624>
- **[S57]** Green, B. y Chen, Y. (2019). Disparate Interactions. *Proceedings of the Conference on Fairness, Accountability, and Transparency*. <https://doi.org/10.1145/3287560.3287563>
- **[S58]** Bansal, G., Wu, T., Zhou, J., Fok, R., Nushi, B., Kamar, E. et al. (2021). Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team

- Performance. Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. <https://doi.org/10.1145/3411764.3445717>
- **[S59]** Vasconcelos, H., Jörke, M., Grunde-McLaughlin, M., Gerstenberg, T., Bernstein, M. S. y Krishna, R. (2023). Explanations Can Reduce Overreliance on AI Systems During Decision-Making. Proceedings of the ACM on Human-Computer Interaction. <https://doi.org/10.1145/3579605>
 - **[S60]** Vaccaro, M., Almaatouq, A. y Malone, T. (2024). When combinations of humans and AI are useful: A systematic review and meta-analysis. Nature Human Behaviour. <https://doi.org/10.1038/s41562-024-02024-1>
 - **[S61]** Alon-Barkat, S. y Busuioc, M. (2022). Human–AI Interactions in Public Sector Decision Making: “Automation Bias” and “Selective Adherence” to Algorithmic Advice. Journal of Public Administration Research and Theory. <https://doi.org/10.1093/jopart/muac007>
 - **[S62]** Amershi, S., Weld, D., Vorvoreanu, M., Fourney, A., Nushi, B., Collisson, P. et al. (2019). Guidelines for Human-AI Interaction. Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems. <https://doi.org/10.1145/3290605.3300233>
 - **[S63]** Parasuraman, R. y Manzey, D. H. (2010). Complacency and Bias in Human Use of Automation: An Attentional Integration. Human Factors: The Journal of the Human Factors and Ergonomics Society. <https://doi.org/10.1177/0018720810376055>
 - **[S64]** Niculescu-Mizil, A. y Caruana, R. (2005). Predicting good probabilities with supervised learning. Proceedings of the 22nd international conference on Machine learning - ICML '05. <https://doi.org/10.1145/1102351.1102430>
 - **[S65]** Guo, C., Pleiss, G., Sun, Y. y Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. arXiv. <https://doi.org/10.48550/arXiv.1706.04599>
 - **[S66]** Brier, G. W. (1950). VERIFICATION OF FORECASTS EXPRESSED IN TERMS OF PROBABILITY. Monthly Weather Review. [https://doi.org/10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2)
 - **[S67]** Silva Filho, T., Song, H., Perello-Nieto, M., Santos-Rodriguez, R., Kull, M. y Flach, P. (2023). Classifier calibration: a survey on how to assess and improve predicted class probabilities. Machine Learning. <https://doi.org/10.1007/s10994-023-06336-7>
 - **[S68]** Saito, T. y Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE. <https://doi.org/10.1371/journal.pone.0118432>
 - **[S69]** Järvelin, K. y Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems. <https://doi.org/10.1145/582415.582418>
 - **[S70]** Hüllermeier, E. y Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods. Machine Learning. <https://doi.org/10.1007/s10994-021-05946-3>
 - **[S71]** Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B. et al. (2019). Model Cards for Model Reporting. Proceedings of the Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3287560.3287596>
 - **[S72]** Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Iii, H. D. et al. (2021). Datasheets for datasets. Communications of the ACM. <https://doi.org/10.1145/3458723>

- **[S73]** Raji, I. D., Smart, A., White, R. N., Mitchell, M., Gebru, T., Hutchinson, B. et al. (2020). Closing the AI accountability gap. Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3351095.3372873>
- **[S74]** Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining. ACM Transactions on Knowledge Discovery from Data. <https://doi.org/10.1145/2382577.2382579>
- **[S75]** Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. y Bouchachia, A. (2014). A survey on concept drift adaptation. ACM Computing Surveys. <https://doi.org/10.1145/2523813>
- **[S76]** Breck, E., Cai, S., Nielsen, E., Salib, M. y Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. 2017 IEEE International Conference on Big Data (Big Data). <https://doi.org/10.1109/BigData.2017.8258038>
- **[S77]** Kreuzberger, D., Kühl, N. y Hirschl, S. (2023). Machine Learning Operations (MLOps): Overview, Definition, and Architecture. IEEE Access. <https://doi.org/10.1109/access.2023.3262138>
- **[S78]** Paleyes, A., Urma, R. G. y Lawrence, N. D. (2022). Challenges in Deploying Machine Learning: A Survey of Case Studies. ACM Computing Surveys. <https://doi.org/10.1145/3533378>
- **[S79]** Hutchinson, B., Smart, A., Hanna, A., Denton, R., Greer, C., Kjartansson, O. et al. (2021). Towards Accountability for Machine Learning Datasets: Practices from Software Engineering and Infrastructure. Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3442188.3445918>
- **[S80]** Giermndl, L. M., Strich, F., Christ, O., Leicht-Deobald, U. y Redzepi, A. (2021). The dark sides of people analytics: reviewing the perils for organisations and employees. European Journal of Information Systems. <https://doi.org/10.1080/0960085x.2021.1927213>
- **[S81]** Koenecke, A., Choi, A. S. G., Mei, K. X., Schellmann, H. y Sloane, M. (2024). Careless Whisper: Speech-to-Text Hallucination Harms. The 2024 ACM Conference on Fairness, Accountability, and Transparency. <https://doi.org/10.1145/3630106.3658996>
- **[S82]** Thompson, I., Koenig, N., Mracek, D. L. y Tonidandel, S. (2023). Deep Learning in Employee Selection: Evaluation of Algorithms to Automate the Scoring of Open-Ended Assessments. Journal of Business and Psychology. <https://doi.org/10.1007/s10869-023-09874-y>
- **[S83]** Armstrong, L., Liu, A., MacNeil, S. y Metaxa, D. (2024). The Silicon Ceiling: Auditing GPT's Race and Gender Biases in Hiring. Proceedings of the 4th ACM Conference on Equity and Access in Algorithms, Mechanisms, and Optimization. <https://doi.org/10.1145/3689904.3694699>
- **[S84]** Wilson, K., Sim, M., Gueorgieva, A. M. y Caliskan, A. (2025). No Thoughts Just AI: Biased LLM Hiring Recommendations Alter Human Decision Making and Limit Human Autonomy. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society. <https://doi.org/10.1609/aies.v8i3.36749>
- **[S85]** Booth, B. M., Hickman, L., Subburaj, S. K., Tay, L., Woo, S. E. y D'Mello, S. K. (2021). Bias and Fairness in Multimodal Machine Learning: A Case Study of Automated Video Interviews. Proceedings of the 2021 International Conference on Multimodal Interaction. <https://doi.org/10.1145/3462244.3479897>
- **[S86]** Van Iddekinge, C. H., Lievens, F. y Sackett, P. R. (2023). Personnel selection: A review of ways to maximize validity, diversity, and the applicant experience. Personnel Psychology. <https://doi.org/10.1111/peps.12578>

- **[S87]** Glazko, K., Mohammed, Y., Kosa, B., Potluri, V. y Mankoff, J. (2024). Identifying and Improving Disability Bias in GPT-Based Resume Screening. The 2024 ACM Conference on Fairness Accountability and Transparency. <https://doi.org/10.1145/3630106.3658933>
- **[S88]** Bredin, H. (2023). pyannote.audio 2.1 speaker diarization pipeline: principle, benchmark, and recipe. INTERSPEECH 2023. <https://doi.org/10.21437/interspeech.2023-105>
- **[S89]** Koenig, N., Tonidandel, S., Thompson, I., Albritton, B., Koohifar, F., Yankov, G. et al. (2023). Improving measurement and prediction in personnel selection through the application of machine learning. Personnel Psychology. <https://doi.org/10.1111/peps.12608>

Normas y documentos oficiales

- **[O01]** Parlamento Europeo y Consejo de la Unión Europea. (2024). Reglamento (UE) 2024/1689, por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de Inteligencia Artificial). Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj> (consultado el 2026-09-30)
- **[O02]** Parlamento Europeo y Consejo de la Unión Europea. (2016). Reglamento (UE) 2016/679, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (Reglamento general de protección de datos). Diario Oficial de la Unión Europea. <https://eur-lex.europa.eu/eli/reg/2016/679/oj> (consultado el 2026-09-30)
- **[O03]** Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology (U.S.). <https://doi.org/10.6028/NIST.AI.100-1>
- **[O04]** Schwartz, R., Vassilev, A., Greene, K., Perine, L., Burt, A. y Hall, P. (2022). Towards a standard for identifying and managing bias in artificial intelligence. National Institute of Standards and Technology (U.S.). <https://doi.org/10.6028/NIST.SP.1270>
- **[O05]** ISO/IEC. (2023). ISO/IEC 42001:2023 Information technology — Artificial intelligence — Management system. <https://www.iso.org/standard/42001> (consultado el 2026-09-30)
- **[O06]** ISO/IEC. (2023). ISO/IEC 23894:2023 Information technology — Artificial intelligence — Guidance on risk management. <https://www.iso.org/standard/77304.html> (consultado el 2026-09-30)
- **[O07]** OCDE. (s. f.). OECD AI Principles (Recomendación del Consejo sobre Inteligencia Artificial). <https://oecd.ai/en/ai-principles> (consultado el 2026-09-30)
- **[O08]** UNESCO. (2021). Recomendación sobre la ética de la inteligencia artificial. <https://www.unesco.org/en/artificial-intelligence/recommendation-ethics> (consultado el 2026-09-30)
- **[O09]** Ministerio de Justicia y Derechos Humanos. (2024). Decreto Supremo N.º 016-2024-JUS, que aprueba el Reglamento de la Ley N.º 29733, Ley de Protección de Datos Personales. <https://www.gob.pe/institucion/smv/normas-legales/6426760-016-2024-jus> (consultado el 2026-09-30)
- **[O10]** Congreso de la República del Perú. (2023). Ley N.º 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país. <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/4565760-31814> (consultado el 2026-09-30)
- **[O11]** Estados Unidos. 29 CFR Part 1607 — Uniform Guidelines on Employee Selection Procedures (1978). Code of Federal Regulations, edición 2017 (govinfo).

<https://www.govinfo.gov/content/pkg/CFR-2017-title29-vol4/xml/CFR-2017-title29-vol4-part1607.xml> (consultado el 2026-09-30)

- **[O12]** Ciudad de Nueva York, Department of Consumer and Worker Protection. (s. f.). Automated Employment Decision Tools (AEDT) (Local Law 144 of 2021). <https://www.nyc.gov/site/dca/about/automated-employment-decision-tools.page> (consultado el 2026-09-30)
- **[O13]** Presidencia del Consejo de Ministros. (2025). Decreto Supremo N.º 115-2025-PCM, que aprueba el Reglamento de la Ley N.º 31814. El Peruano, 9 de setiembre de 2025. <https://www.gob.pe/institucion/pcm/normas-legales/7133522-115-2025-pcm> (consultado el 2026-09-30)
- **[O14]** Ministerio de Educación del Perú. (2012). Marco de Buen Desempeño Docente (RM N.º 0547-2012-ED). <https://www.gob.pe/institucion/minedu/informes-publicaciones/3280180-marco-del-buen-desempeno-docente> (consultado el 2026-09-30)
- **[O15]** Congreso de la República del Perú. (2011). Ley N.º 29733, Ley de Protección de Datos Personales (3 de julio de 2011). <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733> (consultado el 2026-09-30)
- **[O16]** Parlamento Europeo y Consejo de la Unión Europea. (2026). Reglamento (UE) 2026/1744, de 8 de julio de 2026, por el que se modifican los Reglamentos (UE) 2024/1689, (UE) 2018/1139 y (UE) 2023/1230 en lo que respecta a la simplificación de la aplicación de normas armonizadas en materia de inteligencia artificial (Digital Omnibus on AI). Diario Oficial de la Unión Europea, serie L, 24 de julio de 2026. <https://eur-lex.europa.eu/eli/reg/2026/1744/oj> (consultado el 2026-09-30)

Fuentes secundarias

- **[X01]** EU Artificial Intelligence Act (sitio informativo, no oficial). (s. f.). Annex III: High-Risk AI Systems Referred to in Article 6(2). <https://artificialintelligenceact.eu/annex/3/> (consultado el 2026-09-30)
- **[X02]** Gibson Dunn. (s. f.). EU AI Act Omnibus Agreement — Postponed High-Risk Deadlines and Other Key Changes (análisis de un despacho de abogados). <https://www.gibsondunn.com/eu-ai-act-omnibus-agreement-postponed-high-risk-deadlines-and-other-key-changes/> (consultado el 2026-09-30)